補足資料

多変量正規分布（MVN）

第 11 章を読むための準備　ゼミ資料

1　なぜ必要か

第 11 章の階層回帰モデルでは

$$\boldsymbol{\beta}_1, \ldots, \boldsymbol{\beta}_m \overset{\text{i.i.d.}}{\sim} \mathrm{MVN}(\boldsymbol{\theta}, \Sigma)$$

という式が何度も出てくる．MVN は **Multivariate Normal distribution**（**多変量正規分布**）の略で，普通の正規分布を**ベクトル**（いくつかの数の組）に拡張したものである（教科書第 7 章）．

数学の点数の例では，学校 j の回帰係数は 2 つの数の組

$$\boldsymbol{\beta}_j = \begin{pmatrix} \beta_{1,j} \\ \beta_{2,j} \end{pmatrix} = \begin{pmatrix} \text{切片（学校の平均点）} \\ \text{傾き（SES の効果）} \end{pmatrix}$$

であり，「100 校の（切片，傾き）の組がどうばらついているか」を表すのに MVN を使う．

2　定義

多変量正規分布

p 次元の確率ベクトル $\boldsymbol{Y} = (Y_1, \ldots, Y_p)^\top$ の密度が

$$p(\boldsymbol{y} \mid \boldsymbol{\theta}, \Sigma) = (2\pi)^{-p/2} \, |\Sigma|^{-1/2} \exp\left\{ -\tfrac{1}{2} (\boldsymbol{y} - \boldsymbol{\theta})^\top \Sigma^{-1} (\boldsymbol{y} - \boldsymbol{\theta}) \right\}$$

で与えられるとき，$\boldsymbol{Y} \sim \mathrm{MVN}(\boldsymbol{\theta}, \Sigma)$ と書く．

- $\boldsymbol{\theta} = E[\boldsymbol{Y}]$：**平均ベクトル**（$p$ 次元）

- $\Sigma = \mathrm{Cov}[\boldsymbol{Y}]$：**共分散行列**（$p \times p$，対称・正定値）
- $|\Sigma|$ は Σ の行列式

2.1　1 次元の正規分布との対応

	正規分布	多変量正規分布
扱う量	数 y	ベクトル $\boldsymbol{y}$
中心	平均 θ	平均ベクトル $\boldsymbol{\theta}$
広がり	分散 σ^2	共分散行列 Σ
正規化定数	$(2\pi\sigma^2)^{-1/2}$	$(2\pi)^{-p/2}\lvert\Sigma\rvert^{-1/2}$
指数の中	$-\dfrac{(y-\theta)^2}{2\sigma^2}$	$-\frac{1}{2}(\boldsymbol{y}-\boldsymbol{\theta})^\top\Sigma^{-1}(\boldsymbol{y}-\boldsymbol{\theta})$

$p = 1$ とすると $\Sigma = \sigma^2$，$\Sigma^{-1} = 1/\sigma^2$，$|\Sigma| = \sigma^2$ なので，普通の正規分布の密度にぴったり戻る．「$1/\sigma^2$ で割る」が「Σ^{-1} を両側から挟む」に置き換わったと思えばよい．

2.2　共分散行列の中身

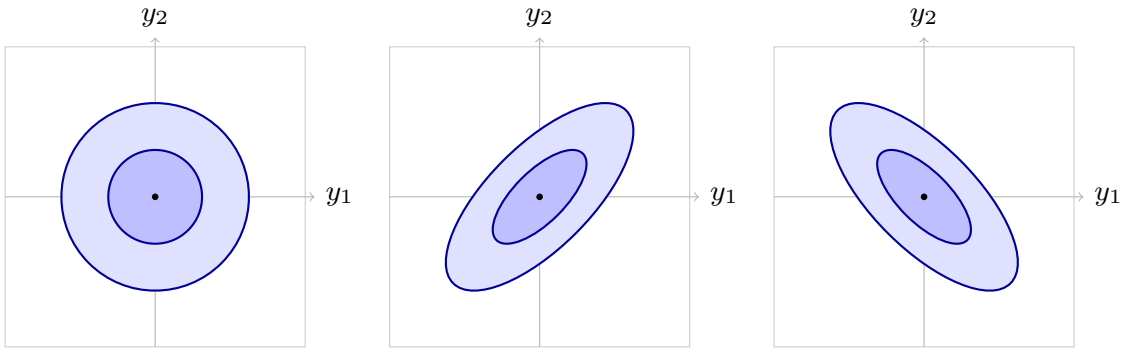
$p = 2$ の場合，

$$\Sigma = \begin{pmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{pmatrix} = \begin{pmatrix} \mathrm{Var}[Y_1] & \mathrm{Cov}[Y_1, Y_2] \\ \mathrm{Cov}[Y_1, Y_2] & \mathrm{Var}[Y_2] \end{pmatrix}, \qquad \rho = \frac{\sigma_{12}}{\sigma_1\sigma_2}\ \text{（相関係数）}.$$

- **対角成分**：各成分のばらつき
- **非対角成分**：2 つの成分が**一緒に動く傾向**（相関）

3　形のイメージ

2 次元の MVN の密度は「山」の形をしていて，等高線は**楕円**になる．下の図は $\boldsymbol{\theta} = (0, 0)$，$\sigma_1 = \sigma_2 = 1$ で相関 ρ だけを変えたときの等高線である（内側の楕円が $(\boldsymbol{y}-\boldsymbol{\theta})^\top\Sigma^{-1}(\boldsymbol{y}-\boldsymbol{\theta}) = 1$，外側が $= 4$）．



- $\rho = 0$：円．y_1 が大きくても y_2 について何もわからない．
- $\rho > 0$：右上がりの楕円．y_1 が大きいと y_2 も大きくなりやすい．
- $\rho < 0$：右下がりの楕円．y_1 が大きいと y_2 は小さくなりやすい．

例：第 11 章の $\beta_j \sim \mathrm{MVN}(\boldsymbol{\theta}, \Sigma)$

100 校の（切片 $\beta_{1,j}$，傾き $\beta_{2,j}$）を平面上の点として打つと，楕円形の雲になる，というモデル．

- $\boldsymbol{\theta} = (\theta_1, \theta_2)$：雲の中心＝学校全体の平均的な切片と傾き
- Σ_{11}, Σ_{22}：切片のばらつき，傾きのばらつき
- Σ_{12}：「平均点が高い学校ほど SES の効果が大きい（小さい）」といった**切片と傾きの関係**

切片と傾きに別々の 1 次元正規分布を当てると，Σ_{12} にあたる関係が表せない．だから MVN を使い，Σ ごと推定する．

4　よく使う性質

性質 1：線形変換しても MVN

$\boldsymbol{Y} \sim \mathrm{MVN}(\boldsymbol{\theta}, \Sigma)$，$A$ を定数行列，$\boldsymbol{c}$ を定数ベクトルとすると

$$A\boldsymbol{Y} + \boldsymbol{c} \sim \mathrm{MVN}(A\boldsymbol{\theta} + \boldsymbol{c},\ A\Sigma A^\top).$$

平均は $E[A\boldsymbol{Y} + \boldsymbol{c}] = A\boldsymbol{\theta} + \boldsymbol{c}$，共分散は $\mathrm{Cov}[A\boldsymbol{Y}] = E[A(\boldsymbol{Y} - \boldsymbol{\theta})(\boldsymbol{Y} - \boldsymbol{\theta})^\top A^\top] = A\Sigma A^\top$．1 次元の「$aY + c$ の分散は $a^2\sigma^2$」の行列版である．

性質 2：独立な MVN の和も MVN

$\boldsymbol{U} \sim \mathrm{MVN}(\boldsymbol{a}, \Sigma_U)$ と $\boldsymbol{V} \sim \mathrm{MVN}(\boldsymbol{b}, \Sigma_V)$ が独立なら

$$\boldsymbol{U} + \boldsymbol{V} \sim \mathrm{MVN}(\boldsymbol{a} + \boldsymbol{b},\ \Sigma_U + \Sigma_V).$$

例：第 11 章：同じ学校の生徒はなぜ相関するか

$\boldsymbol{\beta}_j = \boldsymbol{\theta} + \boldsymbol{\gamma}_j$，$\boldsymbol{\gamma}_j \sim \mathrm{MVN}(\boldsymbol{0}, \Sigma)$ とすると

$$\boldsymbol{Y}_j = X_j\boldsymbol{\theta} + \underbrace{X_j\boldsymbol{\gamma}_j}_{\text{性質 1 :}\mathrm{MVN}(\boldsymbol{0},\, X_j\Sigma X_j^\top)} + \underbrace{\boldsymbol{\epsilon}_j}_{\mathrm{MVN}(\boldsymbol{0},\, \sigma^2 I)}.$$

2 つは独立なので性質 2 より

$$\boldsymbol{Y}_j \sim \mathrm{MVN}\big(X_j\boldsymbol{\theta},\ X_j\Sigma X_j^\top + \sigma^2 I\big).$$

$\sigma^2 I$ は対角行列（生徒どうし独立）だが，$X_j\Sigma X_j^\top$ が非対角成分を持つので，$\boldsymbol{\beta}_j$ を知らない状態では**同じ学校の生徒の点数は相関する**.

性質 3：MVN では「無相関 ⇔ 独立」

$\boldsymbol{Y} \sim$ MVN で，Σ が対角行列（すべての共分散が 0）なら，各成分 $Y_1, \ldots, Y_p$ は**独立**.

対角なら Σ^{-1} も対角で，指数の中が $-\sum_k (y_k - \theta_k)^2/(2\sigma_k^2)$ と成分ごとの和に分かれ，密度が 1 次元正規密度の積になるからである.

注意

一般の分布では「無相関でも独立とは限らない」. これは MVN の特別な性質である. 例えば $\boldsymbol{Y}_j \sim \mathrm{MVN}(X_j\boldsymbol{\beta}_j, \sigma^2 I)$ は「$\boldsymbol{\beta}_j$ を条件にすれば学校 j の生徒の点数は互いに独立」という意味になる.

性質 4：周辺分布も正規分布

$\boldsymbol{Y} \sim \mathrm{MVN}(\boldsymbol{\theta}, \Sigma)$ の各成分は $Y_k \sim \mathrm{Normal}(\theta_k, \Sigma_{kk})$.

性質 1 で $A = (0, \ldots, 0, 1, 0, \ldots, 0)$（$k$ 番目だけ 1）とすればよい. 第 11 章で「傾き $\tilde{\beta}_2$ の事後予測分布」を考えるときは，$\mathrm{MVN}(\boldsymbol{\theta}, \Sigma)$ から $\tilde{\boldsymbol{\beta}}$ を引いて第 2 成分だけを見ている.

5　事後分布で MVN を見抜く方法（平方完成）

第 11 章の $\boldsymbol{\beta}_j$ や $\boldsymbol{\theta}$ の完全条件付き分布は，すべてこの方法で求めている．

MVN の核

ベクトル $\boldsymbol{\beta}$ の密度が

$$p(\boldsymbol{\beta}) \propto \exp\Big\{-\tfrac{1}{2}\boldsymbol{\beta}^\top A\boldsymbol{\beta} + \boldsymbol{\beta}^\top \boldsymbol{b}\Big\} \qquad (A \text{ は対称・正定値})$$

の形なら，$\boldsymbol{\beta} \sim \mathrm{MVN}(A^{-1}\boldsymbol{b},\ A^{-1})$.

導出

$\mathrm{MVN}(\boldsymbol{m}, V)$ の指数の中を展開すると

$$-\tfrac{1}{2}(\boldsymbol{\beta}-\boldsymbol{m})^\top V^{-1}(\boldsymbol{\beta}-\boldsymbol{m}) = -\tfrac{1}{2}\boldsymbol{\beta}^\top V^{-1}\boldsymbol{\beta} + \boldsymbol{\beta}^\top V^{-1}\boldsymbol{m} \ - \ \tfrac{1}{2}\boldsymbol{m}^\top V^{-1}\boldsymbol{m}.$$

最後の項は $\boldsymbol{\beta}$ を含まない定数なので，比例の範囲では無視できる．係数を見比べると $V^{-1} = A$，$V^{-1}\boldsymbol{m} = \boldsymbol{b}$，つまり $V = A^{-1}$，$\boldsymbol{m} = A^{-1}\boldsymbol{b}$．1 次元の「$\exp\{-\frac{a}{2}x^2 + bx\}$ なら $\mathrm{Normal}(b/a,\ 1/a)$」と全く同じ発想である．

ポイント

使い方：

1. 事後分布のうち $\boldsymbol{\beta}$ を含む因子だけを集める（尤度 $\times$ 事前分布）．
2. 指数の中を展開し，**$\boldsymbol{\beta}$ の 2 次の項**の係数行列を A，**1 次の項**の係数ベクトルを $\boldsymbol{b}$ として読み取る．
3. $\mathrm{MVN}(A^{-1}\boldsymbol{b},\ A^{-1})$ と答える．

A は「精度行列」（分散の逆）で，**精度は足し算**になる：事後の精度 ＝ 事前の精度 ＋ データの精度．

例：第 11 章の β_j の完全条件付き分布

$\boldsymbol{\beta}_j$ を含む因子は

$$\exp\Big\{-\tfrac{1}{2\sigma^2}\|\boldsymbol{y}_j - X_j\boldsymbol{\beta}_j\|^2\Big\} \times \exp\Big\{-\tfrac{1}{2}(\boldsymbol{\beta}_j-\boldsymbol{\theta})^\top \Sigma^{-1}(\boldsymbol{\beta}_j-\boldsymbol{\theta})\Big\}.$$

展開して 2 次と 1 次の項を集めると

$$A = \underbrace{\Sigma^{-1}}_{\text{事前（グループ間）の精度}} + \underbrace{X_j^\top X_j/\sigma^2}_{\text{データの精度}}, \qquad \boldsymbol{b} = \Sigma^{-1}\boldsymbol{\theta} + X_j^\top \boldsymbol{y}_j/\sigma^2.$$

よって $\boldsymbol{\beta}_j \mid \cdots \sim \mathrm{MVN}(A^{-1}\boldsymbol{b},\, A^{-1})$．これが第 11 章の $V_j = (\Sigma^{-1} + X_j^\top X_j/\sigma^2)^{-1}$，$\boldsymbol{m}_j = V_j(\Sigma^{-1}\boldsymbol{\theta} + X_j^\top \boldsymbol{y}_j/\sigma^2)$ である．

6　共分散行列 Σ の事前分布：逆ウィシャート分布

第 11 章では Σ も推定するので，Σ にも事前分布が必要になる．「行列の分布」として使うのが**逆ウィシャート分布**（inverse-Wishart）である（教科書 7.3 節）．

	1 次元の正規モデル	多変量正規モデル
推定する広がり	分散 σ^2	共分散行列 Σ
共役な事前分布	逆ガンマ分布	逆ウィシャート分布
事後での更新	平方和 $\sum(y_i-\theta)^2$ を足す	平方和行列 $\sum(\boldsymbol{y}_i-\boldsymbol{\theta})(\boldsymbol{y}_i-\boldsymbol{\theta})^\top$ を足す

逆ウィシャート分布（必要なところだけ）

$\Sigma \sim \text{inverse-Wishart}(\eta_0, S_0^{-1})$ のとき

$$E[\Sigma] = \frac{1}{\eta_0 - p - 1} S_0.$$

η_0 は「事前のサンプル数」，S_0 は「事前の平方和行列」のように働く．

第 11 章で $\eta_0 = p+2$ とするのは，$E[\Sigma] = S_0$ になり，しかも自由度が最小限で事前分布が拡散的になるからである．事後では $\eta_0 \to \eta_0 + m$，$S_0 \to S_0 + S_\theta$ と，「サンプル数」と「平方和行列」を足すだけで更新される．

7　まとめ

多変量正規分布のまとめ

1. $\mathrm{MVN}(\boldsymbol{\theta}, \Sigma)$ は正規分布のベクトル版．$\boldsymbol{\theta}$ が中心，Σ が広がりと**成分間の相関**を表す．
2. 2 次元では密度の等高線が楕円になり，相関 ρ の符号で楕円の傾きが決まる．
3. 線形変換・独立な和・周辺分布をとっても MVN のまま．MVN では無相関なら独立．
4. $\exp\{-\frac{1}{2}\boldsymbol{\beta}^\top A\boldsymbol{\beta} + \boldsymbol{\beta}^\top \boldsymbol{b}\}$ の形なら $\mathrm{MVN}(A^{-1}\boldsymbol{b}, A^{-1})$．第 11 章の完全条件付き分布はすべてこれで求まる．
5. 第 11 章の $\boldsymbol{\beta}_j \sim \mathrm{MVN}(\boldsymbol{\theta}, \Sigma)$ は，学校ごとの（切片，傾き）の組が楕円形の雲のようにばらつくというモデル．Σ は逆ウィシャート分布で推定する．