Hoff 第 5 章

5.4 Bias, Variance and Mean Squared Error

ゼミ資料

1　この節のモチベーション

前節までで，正規モデルにおける θ の事後平均（ベイズ推定量）

$$\hat{\theta}_b = \frac{\kappa_0}{\kappa_0 + n}\,\mu_0 + \frac{n}{\kappa_0 + n}\,\bar{y} = w\bar{y} + (1-w)\mu_0, \qquad w = \frac{n}{\kappa_0 + n}$$

を導いた．これは事前平均 μ_0 と標本平均 $\bar{y}$ の加重平均になっている．

素朴な疑問：推定量として「標本平均 $\hat{\theta}_e = \bar{y}$」と「ベイズ推定量 $\hat{\theta}_b$」のどちらが良いのか？

この問いに答えるために，**バイアス・分散・平均二乗誤差（MSE）**という枠組みを使う．

2　推定量の標本特性

点推定量（Point Estimator）

未知パラメータ θ の**点推定量**とは，データ $(y_1, \ldots, y_n)$ をパラメータ空間 Θ の一点に変換する関数のことである．

推定量はデータの関数なので，**それ自体が確率変数**である．データを無限回集め直したとしたら，推定値はどのように分布するか？—これが**標本特性（sampling properties）**の考え方である．

今回比較する 2 つの推定量：

$$\hat{\theta}_e = \bar{y} \qquad \text{（標本平均）}$$

$$\hat{\theta}_b = w\bar{y} + (1-w)\mu_0 \qquad \text{（ベイズ推定量：事後平均）}$$

真の母平均を θ_0，母分散を σ^2（既知と仮定）とおく．

3　バイアス（偏り）

バイアス（Bias）

推定量 $\hat{\theta}$ のバイアスを次で定義する：

$$\mathrm{Bias}[\hat{\theta} \mid \theta_0] = E[\hat{\theta} \mid \theta_0] - \theta_0.$$

バイアスが 0 の推定量を**不偏推定量（unbiased estimator）**と呼ぶ．

各推定量のバイアスを計算する

■標本平均 $\hat{\theta}_e$ のバイアス

$$E[\hat{\theta}_e \mid \theta_0] = E\left[\frac{1}{n}\sum_{i=1}^{n} y_i \,\middle|\, \theta_0\right] = \frac{1}{n}\sum_{i=1}^{n}\theta_0 = \theta_0$$

$$\therefore \quad \mathrm{Bias}[\hat{\theta}_e \mid \theta_0] = 0 \qquad \Rightarrow \quad \hat{\theta}_e \text{ は}\textbf{不偏}$$

■ベイズ推定量 $\hat{\theta}_b$ のバイアス

$$E[\hat{\theta}_b \mid \theta_0] = w\,E[\bar{y} \mid \theta_0] + (1-w)\mu_0 = w\theta_0 + (1-w)\mu_0$$

$$\therefore \quad \mathrm{Bias}[\hat{\theta}_b \mid \theta_0] = w\theta_0 + (1-w)\mu_0 - \theta_0 = (1-w)(\mu_0 - \theta_0)$$

$\mu_0 \neq \theta_0$ のとき，$\hat{\theta}_b$ は**偏りあり（biased）**．

ポイント

不偏性は一見良さそうだが，それだけで推定量の良さは語れない．たとえば y_1 だけも θ_0 の不偏推定量だが，$\bar{y}$ より真値から遠い．「バイアスがゼロ＝良い推定量」ではない！

4　平均二乗誤差（MSE）

推定量 $\hat{\theta}$ が真値 θ_0 にどれだけ近いかを総合的に評価するために，**平均二乗誤差（Mean Squared Error; MSE）**を用いる．

MSE（Mean Squared Error）

$$\mathrm{MSE}[\hat{\theta} \mid \theta_0] = E\Big[(\hat{\theta} - \theta_0)^2 \;\Big|\; \theta_0\Big]$$

MSE の分解

$m = E[\hat{\theta} \mid \theta_0]$ とおいて式を展開する：

$$\begin{aligned}
\mathrm{MSE}[\hat{\theta} \mid \theta_0] &= E[(\hat{\theta} - \theta_0)^2 \mid \theta_0] \\
&= E\big[(\hat{\theta} - m + m - \theta_0)^2 \mid \theta_0\big] \\
&= E[(\hat{\theta} - m)^2 \mid \theta_0] + 2\,\underbrace{E[(\hat{\theta} - m) \mid \theta_0]}_{=0}(m - \theta_0) + (m - \theta_0)^2.
\end{aligned}$$

$E[\hat{\theta} - m \mid \theta_0] = 0$ より第 2 項は消えるので，

MSE の分解定理

$$\mathrm{MSE}[\hat{\theta} \mid \theta_0] \;=\; \underbrace{\mathrm{Var}[\hat{\theta} \mid \theta_0]}_{\text{分散}} \;+\; \underbrace{\mathrm{Bias}^2[\hat{\theta} \mid \theta_0]}_{\text{バイアスの 2 乗}}$$

ポイント

MSE は「分散」と「バイアスの 2 乗」のトレードオフで決まる．
バイアスがあっても，分散を十分小さくできれば MSE を改善できる可能性がある．

5　2 つの推定量の MSE 比較

分散の比較

$$\mathrm{Var}[\hat{\theta}_e \mid \theta_0, \sigma^2] = \mathrm{Var}[\bar{y}] = \frac{\sigma^2}{n}$$

$$\mathrm{Var}[\hat{\theta}_b \mid \theta_0, \sigma^2] = \mathrm{Var}[w\bar{y}] = w^2 \frac{\sigma^2}{n} < \frac{\sigma^2}{n}$$

$w < 1$ なので，**ベイズ推定量の方が分散は常に小さい**.

MSE の比較

$$\mathrm{MSE}[\hat{\theta}_e \mid \theta_0] = \frac{\sigma^2}{n} + 0 = \frac{\sigma^2}{n}$$

$$\mathrm{MSE}[\hat{\theta}_b \mid \theta_0] = w^2 \frac{\sigma^2}{n} + (1-w)^2(\mu_0 - \theta_0)^2$$

どちらが良いか？

代数計算により，$\mathrm{MSE}[\hat{\theta}_b] < \mathrm{MSE}[\hat{\theta}_e]$ となる条件は

$$\boxed{(\mu_0 - \theta_0)^2 < \sigma^2 \left(\frac{1}{n} + \frac{2}{\kappa_0} \right)}$$

■導出の概略　$\mathrm{MSE}[\hat{\theta}_b] < \mathrm{MSE}[\hat{\theta}_e]$ を整理すると

$$\begin{aligned} w^2 \frac{\sigma^2}{n} + (1-w)^2(\mu_0 - \theta_0)^2 &< \frac{\sigma^2}{n} \\ (1-w)^2(\mu_0 - \theta_0)^2 &< (1-w^2)\frac{\sigma^2}{n} = (1-w)(1+w)\frac{\sigma^2}{n} \\ (1-w)(\mu_0 - \theta_0)^2 &< (1+w)\frac{\sigma^2}{n} \end{aligned}$$

$w = n/(\kappa_0 + n)$ を代入すると，

$$\frac{1+w}{1-w} = \frac{1 + \dfrac{n}{\kappa_0 + n}}{1 - \dfrac{n}{\kappa_0 + n}} = \frac{\kappa_0 + 2n}{\kappa_0},$$

よって

$$(\mu_0 - \theta_0)^2 < \frac{\sigma^2}{n} \cdot \frac{\kappa_0 + 2n}{\kappa_0} = \sigma^2 \left(\frac{1}{n} + \frac{2}{\kappa_0} \right).$$

ポイント

解釈：事前平均 μ_0 が真値 θ_0 から「$\sigma^2(1/n + 2/\kappa_0)$ 以内に近い」なら，ベイズ推定量の方が MSE の意味で優れる．

事前情報が多少でもあれば（つまり μ_0 が大きく外れていなければ），ベイズ推定量は標本平均よりも良い推定を与えることができる．

6　例：IQ スコアによる比較

例：IQ スコア

IQ テストは一般母集団で $\mu = 100$，$\sigma = 15$ になるよう設計されている．ある町の住民から n 人をサンプリングして，その町の平均 IQ スコア θ を推定する．

設定：

- 事前分布：$\mu_0 = 100$（一般母集団の平均を使う）
- 真のパラメータ（未知）：$\theta_0 = 112$，$\sigma^2 = 169$
- 実はこの町は非常に優秀で，真の平均が 100 よりずっと高い！

各推定量の MSE：

$$\mathrm{MSE}[\hat{\theta}_e \mid \theta_0] = \frac{169}{n}$$

$$\mathrm{MSE}[\hat{\theta}_b \mid \theta_0] = w^2 \frac{169}{n} + (1-w)^2 \times (112 - 100)^2 = w^2 \frac{169}{n} + (1-w)^2 \times 144$$

図 1：相対 MSE（n の関数として）

$w = n/(\kappa_0 + n)$ とおくと，相対 MSE は

$$\frac{\mathrm{MSE}[\hat{\theta}_b]}{\mathrm{MSE}[\hat{\theta}_e]} = w^2 + (1-w)^2 \cdot \frac{144\,n}{169}$$

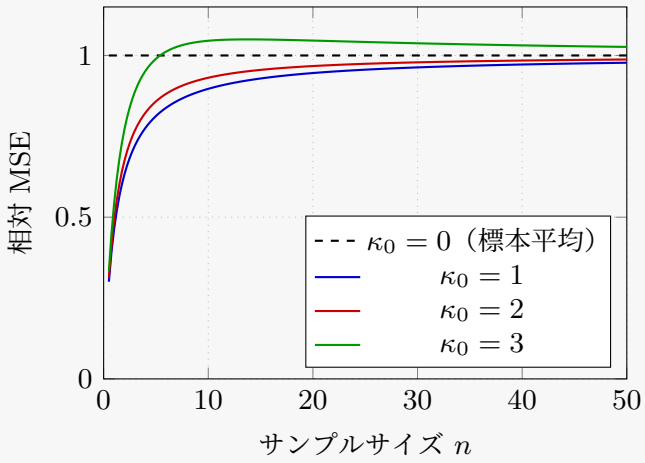
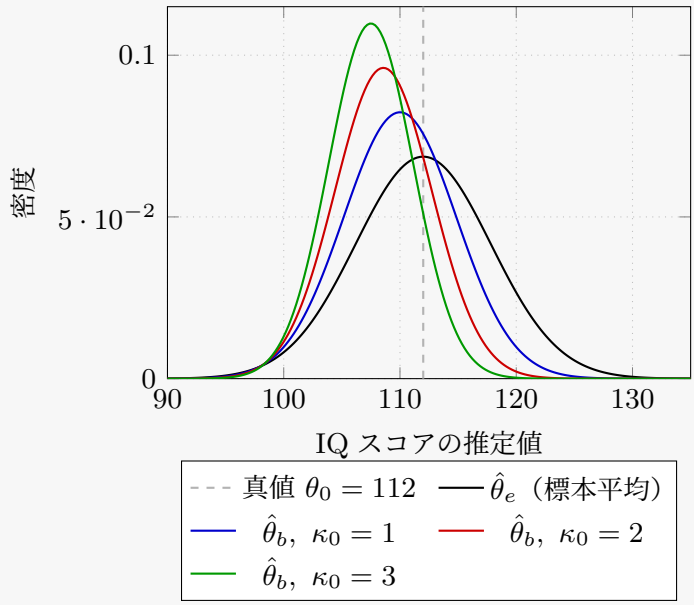


図 2：推定量の標本分布（$n = 5$ のとき）

$n = 5$, $\sigma^2 = 169$, $\mu_0 = 100$, $\theta_0 = 112$ として，各推定量は以下の正規分布に従う：

推定量	期待値	標準偏差
$\hat{\theta}_e$	112	$\sqrt{169/5} \approx 5.81$
$\hat{\theta}_b$ $(\kappa_0 = 1)$	110.0	≈ 4.84
$\hat{\theta}_b$ $(\kappa_0 = 2)$	108.6	≈ 4.15
$\hat{\theta}_b$ $(\kappa_0 = 3)$	107.5	≈ 3.63



読み取れること：

- **図 1**：n が小さいほどベイズ推定量の相対 MSE が低い（事前情報が効く）．$n \to \infty$ でどの曲線も 1 に収束する（データが増えれば差がなくなる）．
- **図 2**：κ_0 が大きいほど分布が左（$\mu_0 = 100$ 寄り）にシフトし，かつ分布が狭くなる（分散減少）．$\hat{\theta}_e$ は真値 $\theta_0 = 112$ に中心があるが分散が最大．
- バイアス（中心のズレ）と分散（幅）のトレードオフが視覚的に確認できる．

7　まとめ

5.4 節のまとめ

1. **バイアス**は推定量の期待値と真値のズレ．不偏性は良い推定量の必要条件ではない．
2. **MSE ＝ 分散 ＋ バイアス** ^{2} というトレードオフがある．
3. ベイズ推定量 $\hat{\theta}_b$ は標本平均 $\hat{\theta}_e$ よりバイアスがあるが分散が小さい．
4. $(\mu_0 - \theta_0)^2 < \sigma^2(1/n + 2/\kappa_0)$ が成立するとき，ベイズ推定量は MSE の意味で標本平均より優れる．
5. 事前情報が多少でもあれば（μ_0 が大きく外れていなければ），特に n が小さい場合にベイズ推定量は有利になる．