Hoff 第 5 章

5.5 Prior Specification Based on Expectations

ゼミ資料

1 この節のモチベーション

前節までで正規モデルの共役事前分布として

$$\theta|\sigma^2 \sim \text{Normal}(\mu_0,\, \sigma^2/\kappa_0), \qquad 1/\sigma^2 \sim \text{Gamma}(\nu_0/2,\, \nu_0\sigma_0^2/2)$$

を使ってきた．ここでのハイパーパラメータ $(\mu_0, \kappa_0, \nu_0, \sigma_0^2)$ は「事前サンプルサイズ」などと解釈されてきたが，実際に設定しようとすると難しい．

自然な疑問：「Y の期待値は μ_0 くらい，分散は σ_0^2 くらい」という形で事前情報を持っているとき，それをどうハイパーパラメータに変換するのか？

この節では，**観測量の期待値**（$E[Y]$ と $E[Y^2]$）を指定することでハイパーパラメータを自然に決める方法を導く．

2 p 次元指数型分布族

p 次元指数型分布族

密度が次の形で書けるモデルを p 次元指数型分布族と呼ぶ：

$$p(y|\phi) = h(y)\, c(\phi) \exp\{\phi^\top t(y)\},$$

ここで

- $\phi = (\phi_1, \ldots, \phi_p)$：自然パラメータ
- $t(y) = (t_1(y), \ldots, t_p(y))$：十分統計量
- $c(\phi)$：正規化定数

正規モデルは 2 次元指数型分布族

$Y \sim \mathrm{Normal}(\theta, \sigma^2)$ の密度を整理すると，

$$p(y|\theta,\sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{(y-\theta)^2}{2\sigma^2}\right\} = \frac{1}{\sqrt{2\pi}} \exp\left\{\frac{\theta}{\sigma^2}y - \frac{1}{2\sigma^2}y^2 - \frac{\theta^2}{2\sigma^2} - \frac{1}{2}\log\sigma^2\right\}$$

なので，各成分は次のようになる：

$$t(y) = \begin{pmatrix} y \\ y^2 \end{pmatrix}, \qquad \phi = \begin{pmatrix} \theta/\sigma^2 \\ -1/(2\sigma^2) \end{pmatrix}, \qquad c(\phi) = |\phi_2|^{1/2} \exp\left\{\frac{\phi_1^2}{4\phi_2}\right\}.$$

ポイント

十分統計量が $t(y) = (y,\, y^2)$ なので，$(\bar{y},\, s^2)$ を知ることは $\left(\sum y_i,\, \sum y_i^2\right)$ を知ることと同値であり，推論に十分な情報が得られる．

3　自然パラメータ ϕ による共役事前分布

第 3 章（1 次元指数型分布族）と同様に，p 次元でも共役事前分布は ϕ の関数として次の形で書ける：

$$p(\phi \mid n_0, t_0) \propto c(\phi)^{n_0} \exp\bigl\{n_0\, t_0^{\top} \phi\bigr\},$$

ここで $t_0 = (t_{01}, t_{02})$ は事前的な Y の期待十分統計量，すなわち

$$t_{01} = E[Y], \qquad t_{02} = E[Y^2].$$

n_0 は「事前サンプルサイズ」に相当するハイパーパラメータである．

4　(θ, σ^2) へのパラメータ変換

自然パラメータ ϕ による共役事前分布を (θ, σ^2) で書き直すと，大括弧内の指数部分は次の 2 つの因子に分解できる：

$$p(\theta, \sigma^2 \mid n_0, t_0) \propto (\sigma^2)^{-1/2} \exp\left\{-\frac{n_0(\theta - t_{01})^2}{2\sigma^2}\right\} \times (\sigma^2)^{-(n_0+5)/2} \exp\left\{-\frac{n_0(t_{02} - t_{01}^2)}{2\sigma^2}\right\}.$$

これはそれぞれ標準的な分布の核と一致する：

因子	分布の形	対応する分布
第 1 因子	$\exp\left\{-\frac{n_0(\theta - t_{01})^2}{2\sigma^2}\right\}$	$\theta \mid \sigma^2 \sim \text{Normal}\left(t_{01},\ \frac{\sigma^2}{n_0}\right)$
第 2 因子	$(\sigma^2)^{-(n_0+5)/2} \exp\left\{-\frac{n_0(t_{02} - t_{01}^2)}{2\sigma^2}\right\}$	$\sigma^2 \sim \text{Inv-Gamma}\left(\frac{n_0+3}{2},\ \frac{n_0(t_{02} - t_{01}^2)}{2}\right)$

5　準備：反復期待値の法則と反復分散の法則

以降の導出で繰り返し使う 2 つの法則を先にまとめる．

反復期待値の法則（Law of Total Expectation）

確率変数 X, Y に対して，

$$E[Y] = E\big[E[Y \mid X]\big].$$

右辺の内側 $E[Y|X]$ は「X を固定したときの Y の平均」（X の関数），外側の $E[\cdot]$ はそれをさらに X について平均したもの．

直感的な理解：クラス全体のテスト平均点 $E[Y]$ を求めたいとき，「勉強した/しない」でグループに分けて各グループの平均を出し，それをグループの割合で加重平均しても同じ答えが出る，ということ．

具体例：テストの点数 Y，「勉強したか」X（1=した，0=しない）

グループ	グループ内平均	割合
勉強した（$X=1$）	$E[Y\|X=1]=80$	$P(X=1)=0.7$
しなかった（$X=0$）	$E[Y\|X=0]=50$	$P(X=0)=0.3$

$$E\big[E[Y|X]\big] = 0.7\times 80 + 0.3\times 50 = 71 = E[Y].$$

反復分散の法則（Law of Total Variance）

$$\mathrm{Var}[Y] = \underbrace{E\big[\mathrm{Var}[Y\mid X]\big]}_{\text{グループ内分散の平均}} + \underbrace{\mathrm{Var}\big[E[Y\mid X]\big]}_{\text{グループ平均どうしの分散}}.$$

直感的な理解：クラス全体の点数のバラつきは，「各グループ内のバラつき（X を固定したときの Y の散らばり）」と「グループ平均どうしのズレ（$E[Y|X=1]=80$ と $E[Y|X=0]=50$ の差）」の 2 つが合わさったものである．

5.5 節での使い方：

使う式	意味
$E[Y]=E[E[Y\|\theta]]=E[\theta]$	θ が不明でも，θ の平均が Y の平均になる
$E[Y^2]=E[E[Y^2\|\theta,\sigma^2]]$	Y^2 の全体平均を，内側で (θ,σ^2) を固定して計算
$\mathrm{Var}[\theta]=E[\mathrm{Var}[\theta\|\sigma^2]]$	θ の分散を σ^2 の不確かさで積分して求める

6　事前期待値から t_{01}，t_{02} を決める

「期待する」とはどういう意味か

ハイパーパラメータを直接決めるのは難しい．μ_0, σ_0^2 はモデル内部の量で，観測できる Y と直接対応していないからである．

発想の転換

ハイパーパラメータを直接決める代わりに，「**まだ見ていない新しい観測値 Y に対して何を期待するか**」を先に決め，それからハイパーパラメータを逆算する．

具体的には：

- **「Y の平均はだいたい μ_0 だろう」**
  （例：女性 1 人の IQ は平均 100 程度 $\to E[Y] = 100$）
- **「Y は真の平均 θ の周りに σ_0^2 程度バラつくだろう」**
  （例：個人の IQ は母平均から ± 15 点程度 $\to E[\mathrm{Var}[Y|\theta, \sigma^2]] = 225$）

この「期待する」は，θ と σ^2 の不確かさをすべて積分した**周辺分布 $p(Y)$ での期待値**である．つまり「θ の値を知らない状態で，$\theta \sim$ 事前分布，$Y|\theta, \sigma^2 \sim \mathrm{Normal}(\theta, \sigma^2)$ という 2 段階の確率の流れを通じた期待値」を意味する．

正規モデルの条件付き期待値・分散

導出で繰り返し使う事実をまとめる．正規モデル $Y|\theta, \sigma^2 \sim \mathrm{Normal}(\theta, \sigma^2)$，事前分布 $\theta|\sigma^2 \sim \mathrm{Normal}(\mu_0, \sigma^2/n_0)$ から直接読める：

条件付き量	値	根拠
$E[Y\|\theta, \sigma^2]$	θ	正規分布の平均はパラメータ θ
$\mathrm{Var}[Y\|\theta, \sigma^2]$	σ^2	正規分布の分散はパラメータ σ^2
$E[\theta\|\sigma^2]$	μ_0	正規分布の平均はパラメータ μ_0
$\mathrm{Var}[\theta\|\sigma^2]$	σ^2/n_0	正規分布の分散はパラメータ σ^2/n_0

これらは「正規分布だから条件付き期待値・分散はパラメータそのもの」という単純な事実であり，法則ではなくモデルの定義から直接来る．

t_{01} の決め方

「Y の平均が μ_0」すなわち $E[Y] = \mu_0$ を期待するとき：

$$E[Y] \underset{\text{反復期待値の法則}}{=} E\big[E[Y|\theta]\big] \underset{E[Y|\theta]=\theta}{=} E[\theta] = \mu_0.$$

ゆえに $t_{01} = \mu_0$.

t_{02} の決め方

「Y の θ 周りのバラつきが σ_0^2」すなわち $E[\mathrm{Var}[Y|\theta,\sigma^2]] = \sigma_0^2$ を期待するとき：

$$E\big[\mathrm{Var}[Y|\theta,\sigma^2]\big] \underset{\mathrm{Var}[Y|\theta,\sigma^2]=\sigma^2}{=} E[\sigma^2] = \sigma_0^2.$$

これは法則ではなく，正規分布の分散がパラメータ σ^2 そのものであることを使った代入である．

$t_{02} = E[Y^2]$ を求める．まず $E[Y^2|\theta,\sigma^2]$ を整理する：

$$E[Y^2|\theta,\sigma^2] = \underbrace{\mathrm{Var}[Y|\theta,\sigma^2]}_{\sigma^2} + \underbrace{(E[Y|\theta,\sigma^2])^2}_{\theta^2} = \sigma^2 + \theta^2.$$

導出

$$t_{02} = E[Y^2] \underset{\text{反復期待値の法則}}{=} E\big[E[Y^2|\theta,\sigma^2]\big] \underset{\text{上の結果を代入}}{=} E[\sigma^2+\theta^2] = \underbrace{E[\sigma^2]}_{\sigma_0^2} + E[\theta^2].$$

$E[\theta^2] = \mathrm{Var}[\theta] + \mu_0^2$ であり，$\mathrm{Var}[\theta]$ は反復分散の法則と $E[\theta|\sigma^2] = \mu_0$，$\mathrm{Var}[\theta|\sigma^2] = \sigma^2/n_0$ から：

$$\mathrm{Var}[\theta] = E\big[\underbrace{\mathrm{Var}[\theta|\sigma^2]}_{\sigma^2/n_0}\big] + \mathrm{Var}\big[\underbrace{E[\theta|\sigma^2]}_{\mu_0=\text{定数}}\big] = \frac{\sigma_0^2}{n_0} + 0 = \frac{\sigma_0^2}{n_0}.$$

したがって：

$$t_{02} = \sigma_0^2 + \frac{\sigma_0^2}{n_0} + \mu_0^2 = \sigma_0^2 \cdot \frac{n_0+1}{n_0} + \mu_0^2, \qquad n_0(t_{02} - t_{01}^2) = (n_0+1)\sigma_0^2.$$

ポイント

どちらの導出も同じ構造：

1. **反復期待値（分散）の法則**で (θ,σ^2) についての積分を分割する
2. **正規分布の性質**（条件付き期待値・分散 = パラメータそのもの）を代入して計算する

「期待する」という主観的な量（μ_0，σ_0^2）は，この 2 ステップを経てハイパーパラメータ t_{01}, t_{02} に翻訳される．

7　得られる事前分布

以上をまとめると，事前期待値 $\mu_0 = E[Y]$，$\sigma_0^2 = E[\mathrm{Var}[Y|\theta, \sigma^2]]$ を指定したとき，対応する共役事前分布は

事前分布（期待値ベースのパラメータ化）

$$\theta \,|\, \sigma^2 \sim \mathrm{Normal}\left(\mu_0,\ \frac{\sigma^2}{n_0}\right)$$

$$\sigma^2 \sim \text{Inv-Gamma}\left(\frac{n_0+3}{2},\ \frac{(n_0+1)\sigma_0^2}{2}\right)$$

共役事前分布の一般形は κ_0（θ の事前精度）と ν_0（σ^2 の自由度）を**独立に**設定できるが，5.5 節のアプローチはこれらを n_0 ひとつに縛る：

	一般の共役事前分布	5.5 節のパラメータ化
θ の事前精度	κ_0（自由）	n_0
σ^2 の自由度	ν_0（自由）	$n_0 + 3$

暗黙に $\nu_0 = \kappa_0 + 3$ という制約が入るため，自由度は (κ_0, ν_0) の 2 つから n_0 の 1 つに減る．

ポイント

トレードオフ：

- **利点**：n_0「事前サンプルサイズ」として直感的に解釈できる
- **欠点**：「θ への確信は強いが σ^2 への確信は弱い」という非対称な設定ができない

解釈しやすさのために柔軟性を 1 自由度分だけ犠牲にした設計である．

弱い事前分布の場合：$n_0 = 1$

事前情報が少ない場合は $n_0 = 1$ とする：

$$\theta|\sigma^2 \sim \mathrm{Normal}(\mu_0,\ \sigma^2), \qquad 1/\sigma^2 \sim \mathrm{Gamma}\big(2,\ \sigma_0^2\big)\,.$$

この設定のもとで，事前期待値が正しく再現されていることを確認できる：

$$E[Y] = E[E[Y|\theta]] = E[\theta] = \mu_0 \quad \checkmark$$
$$E[\mathrm{Var}[Y|\theta, \sigma^2]] = E[\sigma^2] = \sigma_0^2 \quad \checkmark$$

8　事後分布

$n_0 = 1$ の事前分布のもとで n 個の i.i.d. サンプルを得たとき，事後分布は次のようになる：

事後分布（$n_0 = 1$ の場合）

$$\{\theta \,|\, \sigma^2, y_1, \ldots, y_n\} \sim \mathrm{Normal}\left(\frac{\mu_0/\sigma^2 + n\bar{y}}{1/\sigma^2 + n},\ \ \frac{\sigma^2}{n+1}\right)$$

$$\{\sigma^2 \,|\, y_1, \ldots, y_n\} \sim \text{Inv-Gamma}\left(2 + \frac{n}{2},\ \ \sigma_0^2 + (n-1)s^2 + \frac{n}{n+1}(\bar{y} - \mu_0)^2\right)$$

事後平均の解釈

θ の事後平均は

$$\frac{\mu_0/\sigma^2 + n\bar{y}}{1/\sigma^2 + n} = \underbrace{\frac{1/\sigma^2}{1/\sigma^2 + n}}_{\text{事前の重み}}\mu_0 + \underbrace{\frac{n}{1/\sigma^2 + n}}_{\text{データの重み}}\bar{y}.$$

第 5.3 節の公式と同じく，事前平均とデータの加重平均になっている．$n \to \infty$ でデータの重みが 1 に収束し，事前情報の影響が消える．

σ^2 の事後スケールパラメータの解釈

スケールパラメータ $\sigma_0^2 + (n-1)s^2 + \dfrac{n}{n+1}(\bar{y} - \mu_0)^2$ の各項：

項	意味
σ_0^2	事前のスケール（事前サンプルサイズ相当の分散）
$(n-1)s^2$	データの変動（サンプル内の散らばり）
$\dfrac{n}{n+1}(\bar{y}-\mu_0)^2$	事前平均とデータ平均のズレ

3 つ目の項は，事前平均とデータの乖離が大きいほど σ^2 が大きい方向に更新されることを意味する（「想定外にズレているなら分散も大きいはず」という情報）．

9　まとめ

5.5 節のまとめ

1. 正規モデルは 2 次元指数型分布族であり，十分統計量は $t(y) = (y, y^2)$，すなわち $(\bar{y}, s^2)$ に相当する．
2. 共役事前分布を自然パラメータ ϕ で書くと，ハイパーパラメータ t_0 が観測量 Y の**事前期待値**（$E[Y]$，$E[Y^2]$）として解釈できる．
3. 「Y の期待値は μ_0，分散の期待値は σ_0^2」という**解釈しやすい量**を指定するだけで，(t_{01}, t_{02}) が自動的に決まる．
4. 事前サンプルサイズ n_0 だけが調整パラメータとして残り，「事前情報の強さ」を表す．
5. 得られた事前・事後分布は第 5.3 節の共役モデルと同じ構造を持ち，事後平均は事前平均とデータ平均の加重平均になる．