Hoff 第 6 章

6.2 Discrete Approximations

（離散近似）ゼミ資料

1　この節の位置づけ

6.1 節で，半共役事前分布のもとでは σ^2 の**周辺**事後分布 $p(\sigma^2 \mid y_1, \ldots, y_n)$ が標準的な分布にならず，直接サンプリングできないことを見た．

そこで本節では，まず**最も素朴な解決策**を試す：

> 「θ と σ^2 の値を細かい**格子（グリッド）**の上に並べて，各格子点での事後確率を全部計算してしまえばよいのではないか？」

これが**離散近似**（discrete approximation）である．2 パラメータの場合には実際にうまくいく．しかし最後に見るように，パラメータ数が増えると一瞬で破綻する——この破綻が，6.3 節以降でギブスサンプラーへ向かう本当の動機になる．

なお本節以降，Hoff は**精度**（precision）

$$\tilde{\sigma}^2 \;=\; \frac{1}{\sigma^2}$$

を主役のパラメータとして扱う．事前分布を $1/\sigma^2 \sim \text{Gamma}$ とおいていたので，精度で書いたほうが式が素直になるためである．

2　鍵となる事実：正規化定数は知らなくてよい

ベイズの定理より，同時事後分布は

$$p(\theta, \tilde{\sigma}^2 \mid y_1, \ldots, y_n) = \frac{p(\theta, \tilde{\sigma}^2, y_1, \ldots, y_n)}{p(y_1, \ldots, y_n)}$$

であり，分母の $p(y_1, \ldots, y_n)$（周辺尤度）は**パラメータに依存しない**定数である．したがって，2 組のパラメータ値 $\{\theta_1, \tilde{\sigma}_1^2\}$ と $\{\theta_2, \tilde{\sigma}_2^2\}$ の事後確率の**比**を取ると分母が約分される：

$$\begin{aligned}\frac{p(\theta_1, \tilde{\sigma}_1^2 \mid y_1, \ldots, y_n)}{p(\theta_2, \tilde{\sigma}_2^2 \mid y_1, \ldots, y_n)} &= \frac{p(\theta_1, \tilde{\sigma}_1^2,\, y_1, \ldots, y_n) \,/\, p(y_1, \ldots, y_n)}{p(\theta_2, \tilde{\sigma}_2^2,\, y_1, \ldots, y_n) \,/\, p(y_1, \ldots, y_n)} \\ &= \frac{p(\theta_1, \tilde{\sigma}_1^2,\, y_1, \ldots, y_n)}{p(\theta_2, \tilde{\sigma}_2^2,\, y_1, \ldots, y_n)}.\end{aligned}$$

ポイント

事後分布の計算が難しいのは，ほとんどの場合**正規化定数 $p(y_1, \ldots, y_n)$ の積分ができない**からであって，事後分布の「形」が分からないからではない．

相対確率だけ分かれば十分な場面（グリッド近似，MCMC）では，この一番難しい部分を**丸ごと回避できる**．6.2 節の離散近似も，6.4 節以降のギブスサンプラーも，この同じ一点を利用している．

そして同時分布 $p(\theta, \tilde{\sigma}^2, y_1, \ldots, y_n)$ のほうは，標準的な事前分布と標本分布を掛けただけなので**簡単に計算できる**：

$$\begin{aligned}p(\theta, \tilde{\sigma}^2,\, y_1, \ldots, y_n) &= p(\theta, \tilde{\sigma}^2) \times p(y_1, \ldots, y_n \mid \theta, \tilde{\sigma}^2) \\ &= \underbrace{\mathrm{dnorm}(\theta,\, \mu_0,\, \tau_0)}_{\theta \text{ の事前分布}} \times \underbrace{\mathrm{dgamma}\left(\tilde{\sigma}^2,\, \tfrac{\nu_0}{2},\, \tfrac{\nu_0 \sigma_0^2}{2}\right)}_{\tilde{\sigma}^2 \text{ の事前分布}} \\ &\quad \times \underbrace{\prod_{i=1}^{n} \mathrm{dnorm}\left(y_i,\, \theta,\, 1/\sqrt{\tilde{\sigma}^2}\right)}_{\text{尤度}}.\end{aligned}$$

ここで事前分布が積に分解できているのは，6.1 節で θ と $\tilde{\sigma}^2$ を**事前独立**にしたおかげである（$p(\theta, \tilde{\sigma}^2) = p(\theta) \times p(\tilde{\sigma}^2)$）．

ポイント

記法の注意（R 流の書き方）

Hoff は密度関数を R の関数名でそのまま書く．

- $\mathrm{dnorm}(\theta, \mu_0, \tau_0)$：第 3 引数は**標準偏差**（分散ではない）
- $\mathrm{dnorm}(y_i, \theta, 1/\sqrt{\tilde{\sigma}^2})$：精度 $\tilde{\sigma}^2$ の平方根の逆数 $= \sigma$ が標準偏差

- $\mathrm{dgamma}(\tilde{\sigma}^2, \nu_0/2, \nu_0\sigma_0^2/2)$：第 3 引数は**レート**パラメータ（スケールではない）

ガンマ分布のパラメータ化は「ガンマ分布・カイ二乗分布補足」の資料を参照.

3　離散近似の構成

離散近似（discrete approximation）

$\{\theta_1, \ldots, \theta_G\}$ と $\{\tilde{\sigma}_1^2, \ldots, \tilde{\sigma}_H^2\}$ を等間隔に並べたパラメータ値の列とする．各格子点 $\{\theta_k, \tilde{\sigma}_l^2\}$ に次の事後確率を割り当てる：

$$
\begin{aligned}
p_D(\theta_k, \tilde{\sigma}_l^2 \mid y_1, \ldots, y_n) &= \frac{p(\theta_k, \tilde{\sigma}_l^2 \mid y_1, \ldots, y_n)}{\sum_{g=1}^{G} \sum_{h=1}^{H} p(\theta_g, \tilde{\sigma}_h^2 \mid y_1, \ldots, y_n)} \\
&= \frac{p(\theta_k, \tilde{\sigma}_l^2,\, y_1, \ldots, y_n) \,/\, p(y_1, \ldots, y_n)}{\sum_g \sum_h p(\theta_g, \tilde{\sigma}_h^2,\, y_1, \ldots, y_n) \,/\, p(y_1, \ldots, y_n)} \\
&= \frac{p(\theta_k, \tilde{\sigma}_l^2,\, y_1, \ldots, y_n)}{\sum_g \sum_h p(\theta_g, \tilde{\sigma}_h^2,\, y_1, \ldots, y_n)}.
\end{aligned}
$$

最後の等式で $p(y_1, \ldots, y_n)$ が約分されているのが要点である．つまり**計算できる同時分布をグリッド上で評価して，総和が 1 になるように割るだけ**でよい.

$\theta \in \{\theta_1, \ldots, \theta_G\}$，$\tilde{\sigma}^2 \in \{\tilde{\sigma}_1^2, \ldots, \tilde{\sigma}_H^2\}$ 上で総和が 1 になるので，これは**本物の同時確率分布**である.

ポイント

さらに強い解釈がある：もし $\{\theta, \tilde{\sigma}^2\}$ の同時**事前**分布がこのグリッド上の離散分布だったとすれば，p_D は近似ではなく**厳密な事後分布そのもの**である.

つまり「連続事前分布のもとでの事後分布の近似」と見ることも，「離散事前分布のもとでの正確な事後分布」と見ることもできる.

■周辺分布は足し算だけで出る　同時分布が表の形で手に入れば，周辺分布は**単に足し合わせる**だけでよい：

$$
p_D(\theta_k \mid y_1, \ldots, y_n) = \sum_{h=1}^{H} p_D(\theta_k, \tilde{\sigma}_h^2 \mid y_1, \ldots, y_n).
$$

6.1 節で「積分できない」と嘆いていた周辺化が，離散化してしまえば**ただの行・列の合計**になる．条件付き分布も同様に，1 行（1 列）を取り出してその和で割るだけで得られる．

ポイント

なぜヤコビアンを気にしなくてよいか
連続分布なら $\sigma^2 \to \tilde{\sigma}^2 = 1/\sigma^2$ の変数変換でヤコビアン $|d\sigma^2/d\tilde{\sigma}^2| = 1/\tilde{\sigma}^4$ が必要になる．しかし離散近似では各格子点に**確率（質量）**を割り当てているので，点にラベルを付け替えるだけであり，ヤコビアンは出てこない．σ^2 側の分布が欲しければ格子点のラベルを $1/\tilde{\sigma}_h^2$ に読み替えればよい．

4　なぜこれが「サンプリングできない」問題の解決になるのか

ここで一度立ち止まって考えたい．6.1 節の問題は「$p(\sigma^2 \mid y_1, \ldots, y_n)$ が標準的な分布でない」ことだった．離散近似はその分布に名前を与えたわけではない．それなのに，なぜ解決になっているのか．

■そもそも何のためにサンプリングしたかったのか　$p(\sigma^2 \mid y_1, \ldots, y_n)$ が標準的な分布でないと困るのは，`rgamma()` のような**乱数生成関数が使えない**からである．ではなぜ乱数が欲しかったかというと，最終的に知りたいのは

$$E[\theta \mid \boldsymbol{y}], \quad \mathrm{Var}[\theta \mid \boldsymbol{y}], \quad \Pr(\theta > 1.8 \mid \boldsymbol{y}), \quad 95\%\ \text{事後区間}, \quad \ldots$$

といった**事後分布についての量**だからである．これらはすべて事後分布についての**積分**であり，モンテカルロ法はその積分を計算するための**一つの手段**にすぎない．

ポイント

離散近似は「サンプリングする方法」ではなく「サンプリングせずに済ませる方法」
パラメータの値を有限個に制限してしまえば，積分はすべて**有限和**になる．有限和の計算に「分布の名前」は要らない．足し算は常にできる．

$$E[\theta \mid \boldsymbol{y}] \approx \sum_{g=1}^{G} \theta_g \, p_D(\theta_g \mid y_1, \ldots, y_n),$$

$$\Pr(\theta > 1.8 \mid \boldsymbol{y}) \approx \sum_{g:\, \theta_g > 1.8} p_D(\theta_g \mid y_1, \ldots, y_n).$$

6.1 節で行き詰まった 2 つの積分が，どちらも足し算に化けていることを確認したい：

	連続のまま（6.1 節）	離散化したあと（6.2 節）
正規化定数	$p(\boldsymbol{y}) = \iint p(\theta, \sigma^2, \boldsymbol{y})\, d\theta\, d\sigma^2$	全セルの和で割るだけ
周辺化	$\int p(\theta, \sigma^2 \mid \boldsymbol{y})\, d\theta$	表の列の足し算
期待値	$\int \theta\, p(\theta \mid \boldsymbol{y})\, d\theta$	重み付き和

■どうしても標本が欲しければ，それも出せる　さらに言えば，文字通りの「サンプリング」も可能になっている．確率の表が手に入っているので，**セル番号をその確率に従って引けばよい**（R なら `sample()` 一発）．カテゴリカル分布からの乱数生成は常に実行できるので，もとの分布が逆ガンマだったかどうかはもはや関係ない．

解決の中身

離散近似は「非標準的な分布からサンプリングする方法を発明した」のではない．パラメータ空間を有限集合に置き換えることで，**分布が標準的である必要そのものをなくした**のである．

その代償が，次節で見る 2 つの問題——**グリッドをどこに置くか**と**次元の呪い**——である．6.3 節以降でサンプリングの路線に戻るのは，この代償が高すぎるからである．

5　例：ユスリカ（midge）データ

例：第 5 章のユスリカの翅長データ

データは $n = 9$，$\bar{y} = 1.804$，$s^2 = 0.017$.

事前分布の設定：

- θ について：$\mu_0 = 1.9$，$\tau_0 = 0.95$（$\theta > 0$ であることは分かっているので，事前質量の大部分が正になるように）
- σ^2 について：$\nu_0 = 1$，$\sigma_0^2 = 0.01$

第 5 章の共役事前分布との違い：共役事前では θ の事前分散が σ^2/κ_0，つまり標本分散に比例することを要求された．標本分散が小さい（このデータでは $s^2 = 0.017$ と

非常に小さい）と，θ の事前不確実性まで勝手に小さくされてしまうという望ましくない副作用がある．半共役事前分布はこの制約から我々を解放し，$\tau_0 = 0.95$ という「広い」事前不確実性を独立に指定できる．

グリッドは 100×100 とし，

$$\theta \in \{1.505, 1.510, \ldots, 1.995, 2.00\}, \qquad \tilde{\sigma}^2 \in \{1.75, 3.5, \ldots, 173.25, 175.0\}$$

の上で $p(\theta, \tilde{\sigma}^2 \mid y_1, \ldots, y_n)$ を評価する．

```
mu0 <- 1.9 ; t20 <- 0.95^2 ; s20 <- .01 ; nu0 <- 1
y <- c(1.64, 1.70, 1.72, 1.74, 1.82, 1.82, 1.82, 1.90, 2.08)

G <- 100 ; H <- 100
mean.grid <- seq(1.505, 2.00, length = G)
prec.grid <- seq(1.75, 175, length = H)
post.grid <- matrix(nrow = G, ncol = H)

for(g in 1:G) {
  for(h in 1:H) {
    post.grid[g,h] <-
      dnorm(mean.grid[g], mu0, sqrt(t20)) *
      dgamma(prec.grid[h], nu0/2, s20*nu0/2) *
      prod(dnorm(y, mean.grid[g], 1/sqrt(prec.grid[h])))
  }
}

post.grid <- post.grid / sum(post.grid)
```

最後の 1 行 `post.grid/sum(post.grid)` が「正規化定数を積分で求める代わりに，グリッド上の和で代用する」部分である．

図の読み取り：

- 同時事後分布は $\theta \approx 1.80$，$\tilde{\sigma}^2 \approx 50$（すなわち $\sigma^2 \approx 0.02$）あたりに集中している
- θ の周辺事後分布はほぼ対称な山型
- $\tilde{\sigma}^2$ の周辺事後分布は右に裾を引いた非対称な形

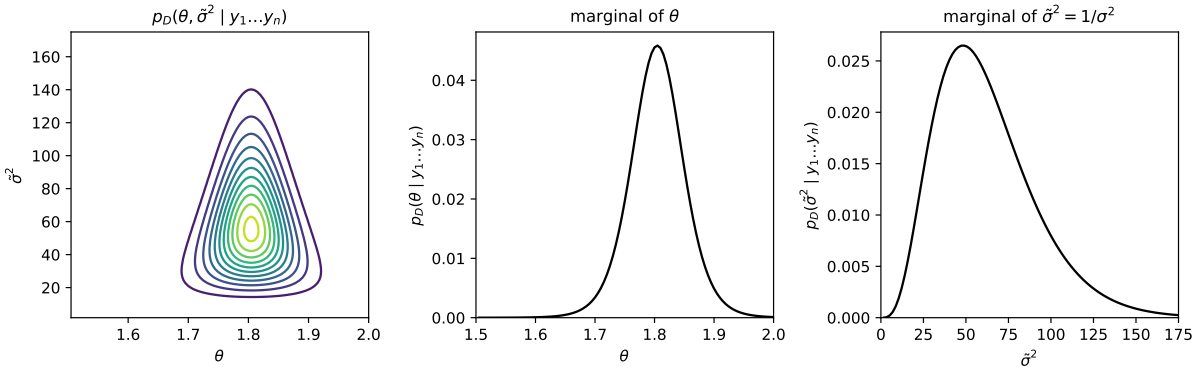


図 1　離散近似による同時事後分布（左）と周辺事後分布（中・右）．Hoff の Figure 6.1 に対応．

弱点その 1：グリッドの範囲を自分で決めなければならない

上の R コードで `prec.grid <- seq(1.75, 175, length=H)` と書いたが，この **1.75 と 175 という数字はどこから来たのか**．データからも事前分布からも導かれていない．Hoff が決め打ちしただけである．

グリッドとは，計算を始める前に自分で指定する**有限の箱**である．箱の置き方を変えると結果がどう変わるかを実際に計算してみる（θ 側は固定して $\tilde{\sigma}^2$ の上限だけ動かし，点数は $H = 100$ のまま）：

$\tilde{\sigma}^2$ の範囲	$E[\tilde{\sigma}^2 \mid \boldsymbol{y}]$	2.5% 点	97.5% 点	格子幅	上端の質量
1.75–60（狭すぎ）	**40.87**	15.87	**59.41**	0.59	**1.5e-02**
1.75–175（Hoff）	61.78	19.25	129.50	1.75	2.5e-04
1.75–3000（広すぎ）	61.93	**32.04**	122.89	**30.29**	9.6e-88

■範囲が狭すぎると（上限 60）　箱の外にある事後質量は単純に**捨てられる**．事後平均が 61.78 → 40.87 とずれ，97.5% 点は 59.41，つまり**箱の上端に貼り付いている**．分布の右の裾がハサミで切られているのだから当然である．

■範囲が広すぎると（上限 3000）　格子点の数 H は 100 のままなので，同じ 100 点を広い範囲に**ばらまく**ことになる．格子幅が 1.75 → 30.29 と粗くなり，事後分布の本体（$\tilde{\sigma}^2 \in [30, 100]$ あたり）に入る格子点は 40 点から**わずか 3 点**に減る．事後平均は 61.93 とそれらしい値が出るが，2.5% 点は 32.04（正しくは 19.25）とデタラメであり，密度のプ

ロットもカクカクになる．

注意

怖いのは，失敗しても出力が正常に見えること

範囲が狭すぎた場合でも，`post.grid/sum(post.grid)` が**箱の中に残った分を 1 に規格化し直してしまう**．したがって得られるのは「総和が 1 の，見た目は立派な確率分布」であり，エラーも警告も一切出ない．上の 40.87 という誤った事後平均は，何の警告もなく出てくる．

点検方法：箱の端（最初と最後の行・列）の確率質量を見ればよい．上限 175 では 2.5×10^{-4} と十分小さいが，上限 60 では 1.5×10^{-2} あり，明らかに切れていると分かる．

ポイント

循環があることに注意

よい箱は「質量をほぼ全部含むくらい広く，かつ 100 点で解像できるくらい狭く」なければならない．ところが質量がどこにあるかは**事後分布を見ないと分からず**，事後分布を見るにはグリッドが要る．

2 パラメータなら「置く $\rightarrow$ 端の質量を見る $\rightarrow$ 広げてやり直す」という試行錯誤で抜け出せる．しかし 10 次元では，その試行錯誤を 1 回まわすこと自体ができない（次節の次元の呪い）．

6　弱点その 2：次元の呪い

グリッドの範囲は，2 次元なら試行錯誤でなんとかなった．しかし計算量を見ると，もっと深刻な問題がある．

2 パラメータで各パラメータを 100 点に区切ると，格子点の数は $100 \times 100 = 100^2 = 10{,}000$ 個であった．一般に p 次元の事後分布について同じ細かさの近似を作るには，100^p 個の事後確率を含む p 次元グリッドが必要になる．

パラメータ数 p	格子点数 100^p	備考
1	10^2	一瞬
2	10^4	本節の例．一瞬
3	10^6	まだ可能
5	10^{10}	かなり苦しい
10	10^{20}	事実上不可能

注意

結論：離散近似は**パラメータ数が少ない密度に対してのみ実行可能**である．

しかもベイズ統計で本当に困るのは，第 8 章の階層モデルや第 9 章の回帰のようにパラメータが数十〜数百個ある状況である．そこでは離散近似は最初から選択肢に入らない．

ポイント

問題の本質

グリッド近似は，事後分布の質量がどこにあるかに関係なく**パラメータ空間を一様に総なめ**する．高次元では，事後分布が実際に意味のある確率を持つ領域は空間全体のごく一部でしかないので，計算のほぼすべてが「確率ほぼ 0 の点を評価する」ことに費やされる．

これに対し次節以降のサンプリング法は，**確率の高いところを優先的に訪れる**ように点を打つ．これが高次元で効く理由である．

7　まとめと次節への橋渡し

6.2 節のまとめ

1. 事後分布の**相対的な**大きさは，同時分布 $p(\theta, \tilde{\sigma}^2, y_1, \ldots, y_n)$ の比として**計算可能**である（正規化定数 $p(y_1, \ldots, y_n)$ が約分されるため）．
2. この事実を使い，パラメータ空間のグリッド上で同時分布を評価して総和で割れば，事後分布の**離散近似** p_D が得られる．これはグリッド上の正当な確率分布であり，離散事前分布を置いたと思えば**厳密な**事後分布でもある．
3. 周辺分布・条件付き分布は，表の行や列を**足す**／**取り出す**だけで得られる．6.1 節で問題だった「積分できない周辺化」が有限和に置き換わる．
4. しかし p 次元には 100^p 個の格子点が必要で，**パラメータが少数の場合にしか使えない**．

■次節へ　離散近似の失敗から，方針を変える必要があることが分かった．6.3 節では，もう一度**完全条件付き分布**に戻る：

- $p(\theta \mid \sigma^2, \boldsymbol{y})$ は正規分布（6.1 節で確認済み）
- $p(\sigma^2 \mid \theta, \boldsymbol{y})$ は——θ を既知として扱えば——逆ガンマ分布になる（6.3 節で導出）

どちらも簡単にサンプリングできる．問題は「両方を同時に扱う方法」だけである．6.3 節ではこの 2 つを**交互に使う**アイデアに到達し，6.4 節でそれが**ギブスサンプラー**として定式化される．