Hoff 第 6 章

6.3 Sampling from the Conditional Distributions

（条件付き分布からのサンプリング）ゼミ資料

1　この節の狙い

6.2 節の離散近似は，グリッドの置き場所と次元の呪いという代償が大きすぎた．そこで**サンプリングの路線に戻る**．ただし作戦を変える．

第 5 章・6.1 節の作戦は「**周辺**分布 $p(\sigma^2 \mid \boldsymbol{y})$ から引いて，次に条件付き分布 $p(\theta \mid \sigma^2, \boldsymbol{y})$ から引く」であった．これは半共役事前分布のもとで **1 段目が破綻した**．

本節の作戦は**周辺分布を一切使わない**：

完全条件付き分布だけを使って，同時分布からの標本を作れないか？

そのために，まず相方である $p(\sigma^2 \mid \theta, \boldsymbol{y})$ を求める．

2　σ^2 の完全条件付き分布

■設定　いま θ **の値を知っている**と仮定する（もちろん本当は知らないが，一時的にそう仮定する）．このとき精度 $\tilde{\sigma}^2 = 1/\sigma^2$ の条件付き分布を求めたい．

出発点は，条件付き分布が同時分布に比例するという事実である（θ と $\boldsymbol{y}$ を固定しているので，$\tilde{\sigma}^2$ に依存しないものはすべて定数として無視できる）：

$$
\begin{aligned}
p(\tilde{\sigma}^2 \mid \theta, y_1, \ldots, y_n) &\propto p(y_1, \ldots, y_n, \theta, \tilde{\sigma}^2) \\
&= p(y_1, \ldots, y_n \mid \theta, \tilde{\sigma}^2)\, p(\theta \mid \tilde{\sigma}^2)\, p(\tilde{\sigma}^2).
\end{aligned}
$$

ポイント

ここで事前独立が効く

θ と $\tilde{\sigma}^2$ が事前独立（半共役事前分布）なら $p(\theta \mid \tilde{\sigma}^2) = p(\theta)$ となり，これは $\tilde{\sigma}^2$ に**依存しない定数**なので落とせる：

$$p(\tilde{\sigma}^2 \mid \theta, y_1, \ldots, y_n) \;\propto\; p(y_1, \ldots, y_n \mid \theta, \tilde{\sigma}^2)\, p(\tilde{\sigma}^2).$$

第 5 章の**共役**事前分布だったら，$p(\theta \mid \sigma^2)$ は Normal$(\mu_0, \sigma^2/\kappa_0)$ であって σ^2 に依存するので**落とせない**．6.1 節で「半共役は計算を難しくする」と見たが，完全条件付き分布に関しては**むしろ簡単にしている**．

■計算　右辺の 2 つの因子を，$\tilde{\sigma}^2$ の関数として書き下す．

尤度（Normal$(\theta, 1/\tilde{\sigma}^2)$ の積）：

$$\begin{aligned} p(y_1, \ldots, y_n \mid \theta, \tilde{\sigma}^2) &= \prod_{i=1}^{n} \left(\frac{\tilde{\sigma}^2}{2\pi}\right)^{1/2} \exp\left\{-\frac{\tilde{\sigma}^2 (y_i - \theta)^2}{2}\right\} \\ &\propto (\tilde{\sigma}^2)^{n/2} \exp\left\{-\tilde{\sigma}^2 \sum_{i=1}^{n} (y_i - \theta)^2 / 2\right\}. \end{aligned}$$

事前分布（Gamma$(\nu_0/2,\ \nu_0\sigma_0^2/2)$，第 2 引数はレート）：

$$p(\tilde{\sigma}^2) \;\propto\; (\tilde{\sigma}^2)^{\nu_0/2-1} \exp\left\{-\tilde{\sigma}^2\, \nu_0\sigma_0^2/2\right\}.$$

掛け合わせると，$\tilde{\sigma}^2$ の**べき**と**指数の肩**がそれぞれ足し算になる：

$$\begin{aligned} p(\tilde{\sigma}^2 \mid \theta, y_1, \ldots, y_n) &\propto \underbrace{(\tilde{\sigma}^2)^{n/2} \exp\left\{-\tilde{\sigma}^2 \textstyle\sum (y_i - \theta)^2/2\right\}}_{\text{尤度}} \times \underbrace{(\tilde{\sigma}^2)^{\nu_0/2-1} \exp\left\{-\tilde{\sigma}^2 \nu_0\sigma_0^2/2\right\}}_{\text{事前分布}} \\ &= (\tilde{\sigma}^2)^{(\nu_0+n)/2-1} \times \exp\left\{-\tilde{\sigma}^2 \times \left[\nu_0\sigma_0^2 + \textstyle\sum (y_i - \theta)^2\right]/2\right\}. \end{aligned}$$

これは $x^{a-1}e^{-bx}$ の形，すなわち**ガンマ密度のカーネル**である．係数を読み取れば

$$a = \frac{\nu_0 + n}{2}, \qquad b = \frac{\nu_0\sigma_0^2 + \sum (y_i - \theta)^2}{2}.$$

σ^2 の完全条件付き分布

半共役事前分布のもと，

$$\{\tilde{\sigma}^2 \mid \theta, y_1, \ldots, y_n\} \sim \text{Gamma}\left(\frac{\nu_n}{2}, \frac{\nu_n \sigma_n^2(\theta)}{2}\right),$$

すなわち $\{\sigma^2 \mid \theta, y_1, \ldots, y_n\} \sim \text{inverse-gamma}\left(\frac{\nu_n}{2}, \frac{\nu_n \sigma_n^2(\theta)}{2}\right)$

ただし

$$\nu_n = \nu_0 + n, \qquad \sigma_n^2(\theta) = \frac{1}{\nu_n}\left[\nu_0 \sigma_0^2 + n s_n^2(\theta)\right], \qquad s_n^2(\theta) = \frac{1}{n}\sum_{i=1}^{n}(y_i - \theta)^2.$$

■読み方　$\nu_n = \nu_0 + n$ は「事前の標本サイズ ν_0 ＋実際の標本サイズ n」であり，$\sigma_n^2(\theta)$ は事前の分散 σ_0^2 とデータから計算した分散 $s_n^2(\theta)$ を**自由度で重み付けした加重平均**である：

$$\sigma_n^2(\theta) = \frac{\nu_0}{\nu_0 + n}\sigma_0^2 + \frac{n}{\nu_0 + n} s_n^2(\theta).$$

θ の場合（6.1 節）は**精度**で重み付けした加重平均だったが，ここでは**自由度**で重み付けした加重平均になっている．どちらも「事前情報とデータ情報を足し合わせる」という同じ構図である．

ポイント

$s_n^2(\theta)$ の分母が n であって $n-1$ でないのはなぜか

通常の標本分散 $s^2 = \sum(y_i - \bar{y})^2/(n-1)$ で $n-1$ で割るのは，中心 $\bar{y}$ をデータから推定したぶん自由度を 1 つ失うからである．ここでは θ **を既知として条件付けている**ので，中心を推定する必要がなく自由度は失われない．だから $s_n^2(\theta) = \sum(y_i - \theta)^2/n$ が（θ が既知なら）σ^2 の不偏推定量になる．

通常の標本分散との関係は，平方和を分解すると見える：

$$\sum_{i=1}^{n}(y_i - \theta)^2 = \underbrace{\sum_{i=1}^{n}(y_i - \bar{y})^2}_{(n-1)s^2} + \underbrace{n(\bar{y} - \theta)^2}_{\theta \text{ が } \bar{y} \text{ からずれた分}}.$$

つまり条件付けた θ が $\bar{y}$ から遠いほど $s_n^2(\theta)$ は大きくなり，σ^2 の条件付き事後分布は**大きい値のほうへ引っぱられる**．データのばらつきを「本当のばらつき」と「中心のずれ」の両方で説明するからである．

3　役者がそろった

これで 2 つの**完全条件付き分布**（full conditional distribution）——「その 1 つ以外のすべてを条件にした分布」——が手に入った：

	分布	サンプリング
$p(\theta \mid \sigma^2, \boldsymbol{y})$	Normal(μ_n, τ_n^2)（6.1 節）	`rnorm()` で可能
$p(\sigma^2 \mid \theta, \boldsymbol{y})$	inverse-gamma$(\nu_n/2,\ \nu_n\sigma_n^2(\theta)/2)$（本節）	`rgamma()` で可能
$p(\theta, \sigma^2 \mid \boldsymbol{y})$	標準的な分布ではない	**直接は不可能**
$p(\sigma^2 \mid \boldsymbol{y})$	標準的な分布ではない（6.1 節）	**直接は不可能**

部品は 2 つとも簡単に引けるのに，欲しい同時分布からは引けない．そこで Hoff の問いはこうなる：

Can we use the full conditional distributions to sample from the joint posterior distribution?
（完全条件付き分布を使って，同時事後分布からサンプリングできないだろうか？）

4　連鎖のアイデア

議論の土台になるのは，確率の**乗法定理**を言い換えただけの次の原理である．

サンプリングの合成（composition）

X を周辺分布 $p(x)$ からの標本とし，それを条件として Y を条件付き分布 $p(y \mid X)$ から引く．このとき，ペア $\{X, Y\}$ は**同時分布 $p(x, y)$ からの標本**である．

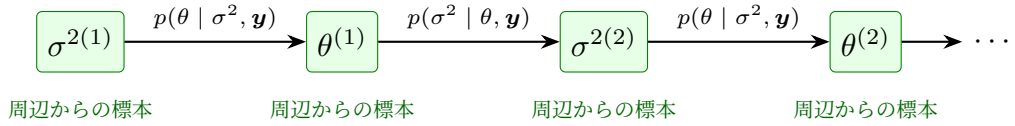
$$p(x, y) = p(x) \times p(y \mid x)$$

そして同時分布からの標本は，片方だけ取り出せば**その周辺分布からの標本**である．

この 2 つの事実（合成と周辺化）を交互に適用していく．

■いま $\sigma^{2(1)}$ が手元にあると仮定する　すなわち，周辺事後分布 $p(\sigma^2 \mid \boldsymbol{y})$ からの標本が 1 つだけ与えられたとする．すると：

1. $\theta^{(1)} \sim p(\theta \mid \sigma^{2(1)}, \boldsymbol{y})$ を引く．
   合成の原理より，$\{\theta^{(1)}, \sigma^{2(1)}\}$ は**同時分布からの標本**である．
2. ペアが同時分布からの標本なら，片割れ $\theta^{(1)}$ は**周辺分布 $p(\theta \mid \boldsymbol{y})$ からの標本**である．
3. そこで $\sigma^{2(2)} \sim p(\sigma^2 \mid \theta^{(1)}, \boldsymbol{y})$ を引く．
   $\theta^{(1)}$ が周辺分布からの標本で，$\sigma^{2(2)}$ がそれを条件とする条件付き分布からの標本なのだから，合成の原理より $\{\theta^{(1)}, \sigma^{2(2)}\}$ も**同時分布からの標本**である．
4. ならば $\sigma^{2(2)}$ は**周辺分布 $p(\sigma^2 \mid \boldsymbol{y})$ からの標本**である．これは出発点と同じ状況なので，1 に戻って繰り返せる．



一度この連鎖に乗ってしまえば，**完全条件付き分布を交互に使うだけで**，周辺分布からの標本・同時分布からの標本がいくらでも作れることになる．隣り合うどのペアを取っても同時事後分布からの標本である．

5　残った問題：最初の 1 個をどうするか

注意

議論が循環している

上の議論は「$\sigma^{2(1)}$ が周辺事後分布 $p(\sigma^2 \mid \boldsymbol{y})$ からの標本として与えられたとすれば」から始まっていた．ところが**その周辺分布から引けないこと**こそ，6.1 節で判明した出発点の問題である．

Hoff の原文も *"if only we had a $\sigma^{2(1)}$ from which to start"*（出発点となる $\sigma^{2(1)}$ さえあれば）と，条件法のまま節を終えている．

ポイント

この議論が本当に示したこと

厳密に言えば，本節が示したのは「同時事後分布からスタートすれば，交互サンプリングを続けても**同時事後分布から外れない**」ということである．これは**同時事後分布がこの手続きの不動点（定常分布）である**という主張であって，**任意の出発点から同時事後分布に近づく**という主張ではない．

後者こそが本当に必要な性質であり，それが成り立つ（したがって $\sigma^{2(1)}$ を適当に決めてよい）ことは，6.4 節でアルゴリズムを定義したうえで，6.6 節のマルコフ連鎖の理論で保証される．

■**6.4 節での解決**　結論を先取りすると，答えは**「適当な値から始めてよい」**である．出発点が正しくなくても，交互サンプリングを繰り返すうちに分布は同時事後分布に収束する．この手続きを**ギブスサンプラー**と呼ぶ．ただし初期の数回分は出発点の影響を引きずるので，実務上はそれを捨てる（burn-in）ことになる．

6　まとめ

6.3 節のまとめ

1. θ を既知として条件付けると，$\{\sigma^2 \mid \theta, \boldsymbol{y}\} \sim \text{inverse-gamma}(\nu_n/2,\ \nu_n\sigma_n^2(\theta)/2)$ と**標準的な分布**になる．導出の鍵は，事前独立のおかげで $p(\theta \mid \tilde{\sigma}^2) = p(\theta)$ が定数として落ち，残りがガンマ密度のカーネルになること．
2. これで **2 つの完全条件付き分布** $p(\theta \mid \sigma^2, \boldsymbol{y})$（正規）と $p(\sigma^2 \mid \theta, \boldsymbol{y})$（逆ガンマ）がどちらも簡単にサンプリングできるようになった．一方，同時分布と周辺分布からは相変わらず直接引けない．
3. **合成の原理**（$X \sim p(x)$ かつ $Y \mid X \sim p(y \mid x)$ ならば $\{X, Y\} \sim p(x, y)$）を交互に適用すると，完全条件付き分布だけで同時分布からの標本が次々と作れる．
4. ただしこの議論は，出発点に**周辺分布からの標本 $\sigma^{2(1)}$ を要求する**という循環を含む．示せたのは「同時事後分布が手続きの不動点である」ことまでであり，任意の出発点からの収束は 6.4 節・6.6 節に委ねられる．