Hoff 第 6 章

6.4 Gibbs Sampling

（ギブスサンプリング）ゼミ資料

1　6.3 節の宿題

6.3 節で，2 つの完全条件付き分布

$$p(\theta \mid \sigma^2, \boldsymbol{y}) = \text{Normal}(\mu_n, \tau_n^2), \qquad p(\sigma^2 \mid \theta, \boldsymbol{y}) = \text{inverse-gamma}\left(\frac{\nu_n}{2}, \frac{\nu_n \sigma_n^2(\theta)}{2}\right)$$

を交互に使えば同時事後分布からの標本が作れる，という見通しが立った．ただし議論は**出発点 $\sigma^{2(1)}$ を周辺分布から引けること**を仮定しており，そこが循環していた．

本節での答えは身も蓋もない：

出発点は適当に決めてよい．そのまま繰り返せばよい．

これを手続きとして定義したものが**ギブスサンプラー**である．

2　ギブスサンプラーの定義

完全条件付き分布（full conditional distribution）

$p(\theta \mid \sigma^2, y_1, \ldots, y_n)$ と $p(\sigma^2 \mid \theta, y_1, \ldots, y_n)$ を，それぞれ θ と σ^2 の**完全条件付き分布**と呼ぶ．「完全」とは，**そのパラメータ以外のすべて**を条件にしている，という意味である．

ギブスサンプラー（Gibbs sampler）

パラメータの現在の状態を $\phi^{(s)} = \{\theta^{(s)}, \tilde{\sigma}^{2(s)}\}$ とする．次の状態を以下の手順で生成する：

1. $\theta^{(s+1)} \sim p(\theta \mid \tilde{\sigma}^{2(s)}, y_1, \ldots, y_n)$ を引く
2. $\tilde{\sigma}^{2(s+1)} \sim p(\tilde{\sigma}^2 \mid \theta^{(s+1)}, y_1, \ldots, y_n)$ を引く
3. $\phi^{(s+1)} = \{\theta^{(s+1)}, \tilde{\sigma}^{2(s+1)}\}$ とおく

これを繰り返して得られる列 $\{\phi^{(1)}, \phi^{(2)}, \ldots, \phi^{(S)}\}$ をギブスサンプラーの出力とする．

ポイント

手順 2 で $\tilde{\sigma}^{2(s)}$ ではなく $\theta^{(s+1)}$ を使うこと

σ^2 を更新するときに条件とするのは，**いま引いたばかりの** $\theta^{(s+1)}$ であって，1 つ前の $\theta^{(s)}$ ではない．6.3 節の連鎖の議論がまさにこの形（引いた値をただちに次の条件にする）だったことを思い出したい．

注意

得られる列は独立ではない

Hoff は *“generates a **dependent** sequence of our parameters”* と明記している．$\phi^{(s+1)}$ は $\phi^{(s)}$ を使って作られるので，隣り合う標本は相関する．

第 4 章までの**独立な**モンテカルロ標本とはここが決定的に違う．標本平均が事後平均に近づくこと自体は成り立つが，「標本の数 S 個ぶんの情報がある」とは言えなくなる．どれだけ情報が目減りするかを測るのが 6.6 節の話題（自己相関・有効標本サイズ）である．

■6.3 節との違いは一点だけ　6.3 節の議論は「$\sigma^{2(1)}$ が**周辺事後分布からの標本**であるとき」という条件付きだった．ギブスサンプラーはその要求を**単に取り下げる**．出発点はどこでもよいことにして，あとは同じ操作を繰り返す．

これで「正しい出発点が要る」という循環は消えるが，代わりに**「適当な出発点から始めて本当に正しい分布に行き着くのか」**という問題が生じる．本節ではそれを**実例で確かめる**にとどめ，理論的な保証は 6.6 節に委ねる．

3　R による実装

```
### data
mean.y <- mean(y) ; var.y <- var(y) ; n <- length(y)

### starting values
S <- 1000
PHI <- matrix(nrow = S, ncol = 2)
PHI[1,] <- phi <- c(mean.y, 1/var.y)

### Gibbs sampling
set.seed(1)
for(s in 2:S) {

  # generate a new theta value from its full conditional
  mun <- (mu0/t20 + n*mean.y*phi[2]) / (1/t20 + n*phi[2])
  t2n <- 1/(1/t20 + n*phi[2])
  phi[1] <- rnorm(1, mun, sqrt(t2n))

  # generate a new 1/sigma^2 value from its full conditional
  nun <- nu0 + n
  s2n <- (nu0*s20 + (n-1)*var.y + n*(mean.y - phi[1])^2) / nun
  phi[2] <- rgamma(1, nun/2, nun*s2n/2)

  PHI[s,] <- phi
}
```

■出発点　phi <- c(mean.y, 1/var.y)，すなわち $\theta^{(1)} = \bar{y}$, $\tilde{\sigma}^{2(1)} = 1/s^2$ である．事後分布からの標本などではなく，**ただの標本統計量**を置いているだけ——「適当に決めてよい」を実際にやっている．

■phi[1] の更新直後に phi[1] を使っている　3 行目で phi[1] を上書きし，その下の s2n の計算でその新しい phi[1] を参照している．これが定義の手順 2（$\theta^{(s+1)}$ で条件付ける）に対応している．

■使っている恒等式　コード中の `s2n` は，定義の $\sigma_n^2(\theta) = [\nu_0\sigma_0^2 + ns_n^2(\theta)]/\nu_n$ を，次の平方和の分解で書き換えたものである：

$$\begin{aligned} ns_n^2(\theta) = \sum_{i=1}^{n}(y_i-\theta)^2 &= \sum_{i=1}^{n}(y_i-\bar{y}+\bar{y}-\theta)^2 \\ &= \sum_{i=1}^{n}\left[(y_i-\bar{y})^2 + 2(y_i-\bar{y})(\bar{y}-\theta) + (\bar{y}-\theta)^2\right] \\ &= \sum_{i=1}^{n}(y_i-\bar{y})^2 + \underbrace{2(\bar{y}-\theta)\sum_{i=1}^{n}(y_i-\bar{y})}_{=0} + \sum_{i=1}^{n}(\bar{y}-\theta)^2 \\ &= (n-1)s^2 + n(\bar{y}-\theta)^2. \end{aligned}$$

交差項が消えるのは $\sum(y_i-\bar{y}) = 0$ だからである．

ポイント

なぜわざわざこう書くのか

$\bar{y}$ と s^2 は**反復のたびに変わらない**（データだけで決まる）ので，ループの外で一度計算しておけばよい．反復の中で必要なのは $n(\bar{y}-\theta)^2$ という**スカラーの計算 1 回**だけになる．素直に $\sum_{i=1}^{n}(y_i-\theta)^2$ を毎回計算すると n 個の引き算と二乗が毎反復で発生する．

$n = 9$ では差は出ないが，n が大きく S が数万回になると効いてくる．「十分統計量をループの外に出す」のは MCMC 実装の定石である．

4　実行結果

ユスリカのデータと 6.2 節と同じ事前分布のもとで，1000 反復のギブスサンプラーを走らせる．

軌跡を見る

動きの特徴：

- 1 反復で**横→縦**と直角に動く．2 つのパラメータを**同時にではなく交互に**更新しているため．

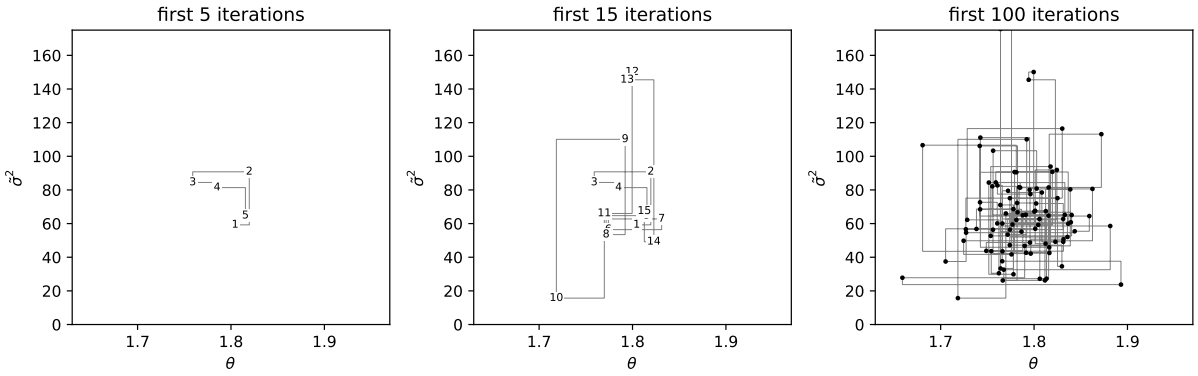


図 1　ギブスサンプラーの最初の 5，15，100 反復．番号は反復の順番．Hoff の Figure 6.2 に対応．各状態を結ぶ線が**階段状**になっているのは，θ の更新が横移動，$\tilde{\sigma}^2$ の更新が縦移動だからである．

- 最初の数回で，出発点 $(\bar{y}, 1/s^2) = (1.804,\ 59.4)$ の周辺から事後分布の広がり全体へ散っていく．
- 100 反復も回すと，点が事後分布の形をなぞるように溜まっていく．

1000 標本と事後分布

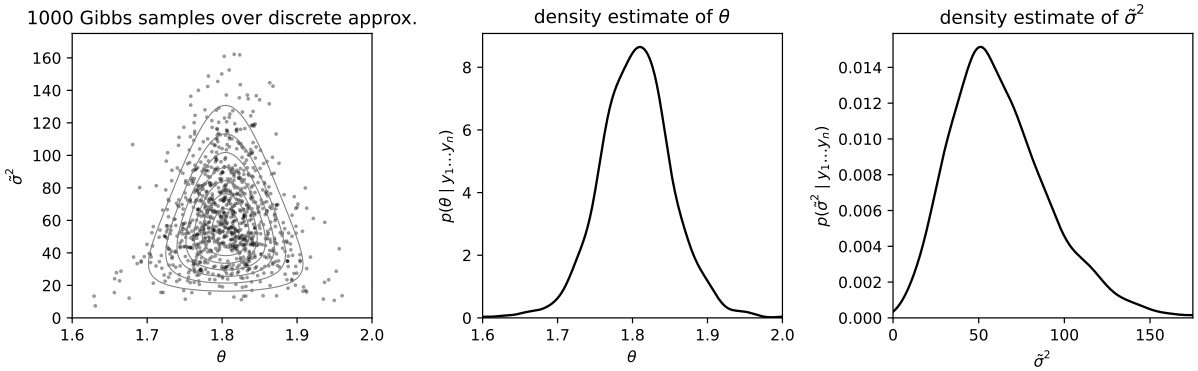


図 2　左：1000 個のギブス標本を，6.2 節の離散近似の等高線に重ねたもの．中・右：標本から推定した θ と $\tilde{\sigma}^2$ の周辺事後密度．Hoff の Figure 6.3 に対応．

ポイント

この例の意義：答え合わせができる

6.2 節の離散近似（図 6.1）と，本節のギブス標本（図 6.3）は，**同じ事後分布を別々の方法で求めたもの**である．2 つがほぼ重なるという事実が，ギブスサンプラーが正しく動いていることの**証拠**になる．

もっとも，この 2 パラメータの問題ではそもそもギブスサンプラーは**必要ない**——離散近似で十分だからである．ギブスサンプラーが本当に必要なのは離散近似が使えない高次元の問題であり，そこでは**この答え合わせができない**．だからこそ，手法の正しさを理論的に保証することと，収束を診断する道具を持つこと（6.6 節）が重要になる．

事後分位点

標本が手に入れば，事後区間は `quantile()` を呼ぶだけである．

```
### CI for population mean
> quantile(PHI[,1], c(.025, .5, .975))
    2.5%     50%    97.5%
1.707282 1.804348 1.901129

### CI for population precision
> quantile(PHI[,2], c(.025, .5, .975))
    2.5%     50%    97.5%
17.48020 53.62511 129.20020

### CI for population standard deviation
> quantile(1/sqrt(PHI[,2]), c(.025, .5, .975))
      2.5%       50%     97.5%
0.08797701 0.13655763 0.23918408
```

		2.5%	50%	97.5%
母平均 θ	Hoff（R）	1.707	1.804	1.901
	再現（Python）	1.708	1.805	1.900
母精度 $\tilde{\sigma}^2$	Hoff（R）	17.48	53.63	129.20
	再現（Python）	16.89	58.02	129.18
母標準偏差 σ	Hoff（R）	0.0880	0.1366	0.2392
	再現（Python）	0.0880	0.1313	0.2433

乱数の種・生成器が違うので完全一致はしないが，よく一致している．一致の精度（たとえば $\tilde{\sigma}^2$ の中央値が 53.6 対 58.0）が**この手法の誤差の目安**でもある．

ポイント

標準偏差の区間が「変換するだけ」で出ること

3 つ目の `quantile(1/sqrt(PHI[,2]), ...)` に注目したい．$\tilde{\sigma}^2$ の標本を $1/\sqrt{\tilde{\sigma}^2} = \sigma$ に **1 つずつ変換して分位点を取っただけ**である．σ の事後分布を解析的に求める必要も，ヤコビアンを考える必要もない．

これは標本に基づく方法の一般的な強みで，θ/σ でも $\Pr(\theta > 1.8 \mid \boldsymbol{y})$ でも，**パラメータの任意の関数**の事後分布が同じやり方で得られる．

5　何が解決して，何が残ったか

6.4 節のまとめ

1. **ギブスサンプラー**は，完全条件付き分布から $\theta \to \sigma^2 \to \theta \to \cdots$ と交互に引くだけの手続きである．6.3 節の循環は「出発点は適当でよい」と**要求を取り下げる**ことで断ち切った．
2. 実装上は，平方和の分解 $\sum(y_i - \theta)^2 = (n-1)s^2 + n(\bar{y} - \theta)^2$ を使って $\bar{y}$ と s^2 をループの外に出す．
3. ユスリカのデータで 1000 反復回すと，得られた標本の分布は 6.2 節の離散近似と**ほぼ一致**した．標本さえあれば，σ のような変換後の量の事後区間も変換

するだけで得られる．

注意

残っている問題

1. **正しさは証明されていない．** Hoff の書き方も *“This gives some indication that the Gibbs sampling procedure is a valid method”*（妥当であることの**示唆**を与える）であって，証明ではない．一般的な保証は 6.5 節・6.6 節で与えられる．
2. **標本が独立でない．** 隣り合う標本は相関するので，$S = 1000$ 個あっても独立な 1000 標本ぶんの情報はない．
3. **出発点の影響がいつ消えるか分からない．** 図 6.2 の最初の数反復は明らかに出発点の近くにいる．実務では初期の一定回数を捨てる（burn-in）が，何回捨てればよいかは自明でない．

これら 3 つが，6.5 節（一般的な性質）と 6.6 節（MCMC 診断）の主題になる．