Hoff 第 6 章

6.5 General Properties of the Gibbs Sampler

（ギブスサンプラーの一般的性質）ゼミ資料

1　この節の位置づけ

6.4 節では，2 パラメータの具体例でギブスサンプラーを走らせ，結果が離散近似とほぼ一致することを見た．しかしそれは **1 つの例でうまくいった**というだけで，

- なぜ適当な出発点から始めてよいのか
- パラメータが 2 個でなく p 個でも同じことが言えるのか
- そもそも何が保証されているのか

には答えていない．本節はその整理にあてられる．

内容は大きく 2 つに分かれる：**(1) 一般形と収束の主張**，**(2)「推定」と「近似」を区別せよという概念的な注意**．後半は数式こそ出てこないが，第 7 章以降をずっと支える考え方である．

2　一般の p パラメータへの拡張

パラメータベクトルを $\phi = \{\phi_1, \ldots, \phi_p\}$ とし，関心のある確率分布を $p(\phi) = p(\phi_1, \ldots, \phi_p)$ とする．正規モデルなら $\phi = \{\theta, \sigma^2\}$，$p(\phi)$ は事後分布 $p(\theta, \sigma^2 \mid y_1, \ldots, y_n)$ である．

ギブスサンプラー（一般形）

出発点 $\phi^{(0)} = \{\phi_1^{(0)}, \ldots, \phi_p^{(0)}\}$ を与え，$\phi^{(s-1)}$ から $\phi^{(s)}$ を次のように生成する：

$$
\begin{aligned}
&1. \quad \phi_1^{(s)} \sim p\left(\phi_1 \mid \phi_2^{(s-1)}, \phi_3^{(s-1)}, \ldots, \phi_p^{(s-1)}\right) \\
&2. \quad \phi_2^{(s)} \sim p\left(\phi_2 \mid \phi_1^{(s)}, \phi_3^{(s-1)}, \ldots, \phi_p^{(s-1)}\right) \\
&\qquad \vdots \\
&p. \quad \phi_p^{(s)} \sim p\left(\phi_p \mid \phi_1^{(s)}, \phi_2^{(s)}, \ldots, \phi_{p-1}^{(s)}\right)
\end{aligned}
$$

ポイント

条件の中身が途中で入れ替わっていく

j 番目を引くときに条件とするのは，**すでに更新済みの** $\phi_1, \ldots, \phi_{j-1}$ **は新しい値** (s)，**まだ更新していない** $\phi_{j+1}, \ldots, \phi_p$ **は古い値** $(s-1)$ である．

1 ステップ進むごとに「新しい値」の領域が左から右へ 1 つずつ伸びていき，p 番目まで終わると全部が新しい値になって $\phi^{(s)}$ が完成する．2 パラメータの場合（6.4 節）に σ^2 の更新で $\theta^{(s)}$（新しいほう）を使ったのと同じ規則である．

3　マルコフ連鎖であること

この手続きが生成するのは，ベクトルの従属列である：

$$
\phi^{(1)} = \{\phi_1^{(1)}, \ldots, \phi_p^{(1)}\}, \quad \phi^{(2)} = \{\phi_1^{(2)}, \ldots, \phi_p^{(2)}\}, \quad \ldots, \quad \phi^{(S)} = \{\phi_1^{(S)}, \ldots, \phi_p^{(S)}\}.
$$

マルコフ性とマルコフ連鎖

この列において，$\phi^{(s)}$ が $\phi^{(0)}, \ldots, \phi^{(s-1)}$ に依存するのは $\phi^{(s-1)}$ **を通じてのみ**である．言い換えれば，$\phi^{(s-1)}$ を与えたとき $\phi^{(s)}$ は $\phi^{(0)}, \ldots, \phi^{(s-2)}$ と条件付き独立である．

この性質を**マルコフ性**（Markov property）といい，これを持つ列を**マルコフ連鎖**（Markov chain）と呼ぶ．

ポイント

なぜマルコフ性が成り立つのか

アルゴリズムを見れば明らかである：$\phi^{(s)}$ を作るのに使う情報は，$\phi^{(s-1)}$ の成分とデータだけであって，それより前の履歴はどこにも現れない．

これは「記憶がない」ということであり，実装上は**直前の状態だけ保持すればよい**ことを意味する（6.4 節の R コードが `phi` という長さ 2 のベクトル 1 本を使い回していたのはこのためである）．

4　収束についての 2 つの主張

Hoff は「本書で扱うすべてのモデルで満たされるいくつかの条件のもとで」と前置きしたうえで，次の 2 つを述べる．

主張 1：分布の収束

パラメータ空間の任意の集合 A について

$$\Pr(\phi^{(s)} \in A) \longrightarrow \int_A p(\phi)\, d\phi \qquad (s \to \infty).$$

すなわち，$\phi^{(s)}$ の**標本分布は目標分布に近づく．出発点 $\phi^{(0)}$ が何であってもよい**（ただし出発点によって，目標に達するまでの速さは違う）．

主張 2：平均の収束（式 6.1）

関心のあるたいていの関数 g について

$$\frac{1}{S}\sum_{s=1}^{S} g(\phi^{(s)}) \longrightarrow E[g(\phi)] = \int g(\phi)\, p(\phi)\, d\phi \qquad (S \to \infty).$$

ポイント

6.3 節の宿題が片づいた

6.3 節で示せたのは「同時事後分布から始めれば，そこから外れない」（不動点であること）までだった．**主張 1 はそれより強く，どこから始めても目標に近づく**と言っている．これがあってはじめて，6.4 節の「出発点は適当でよい」が正当化される．

注意

「いくつかの条件」の中身は書かれていない

Hoff は *"Under some conditions that will be met for all of the models discussed in this text"* と述べるだけで，条件を明示していない．

教科書の範囲を出るが，大まかには**連鎖がパラメータ空間のどこへでも到達できること**（既約性）と，**周期的な振動に陥らないこと**（非周期性）が要る．たとえば完全条件付き分布の台が分断されていて連鎖が片側から出られないような場合には，主張 1 は成り立たない．

なお，条件が満たされていても**収束が実用的な時間内に起きるとは限らない**．$s \to \infty$ の「∞」がどれほど遠いかは別問題であり，それが 6.6 節の主題になる．

■MCMC **という名前**　主張 2 は「標本平均で期待値を近似してよい」と言っており，これは第 4 章の**モンテカルロ近似とまったく同じ使い方**である．違いは，標本が独立ではなく**マルコフ連鎖**として生成される点だけ．そこでこの種の近似を**マルコフ連鎖モンテカルロ（Markov chain Monte Carlo, MCMC）近似**，手続きを **MCMC アルゴリズム**と呼ぶ．

例：ユスリカデータへの適用

6.4 節の 1000 個のギブス標本について，式 (6.1) は $\{(\theta^{(1)}, \sigma^{2(1)}), \ldots, (\theta^{(1000)}, \sigma^{2(1000)})\}$ の同時分布が $p(\theta, \sigma^2 \mid y_1, \ldots, y_n)$ に近いことを意味し，

$$E[\theta \mid y_1, \ldots, y_n] \approx \frac{1}{1000} \sum_{s=1}^{1000} \theta^{(s)} = 1.804,$$

$$\Pr(\theta \in [1.71,\ 1.90] \mid y_1, \ldots, y_n) \approx 0.95.$$

5　「推定」と「近似」を区別する

ここからは数式のない，しかし重要な話である．

ベイズのデータ解析をモンテカルロ法で行っていると，サンプリング手続きと確率分布が入り乱れて混乱しやすい．そこで，解析のうち**統計的な部分**と**数値的な近似の部分**を分けて考えることが助けになる．

ベイズのデータ解析の 3 要素（第 1 章）

1. **モデルの指定**：データの標本分布を表すと考えられる確率分布の族 $\{p(y \mid \phi),\ \phi \in \Phi\}$
2. **事前分布の指定**：どのパラメータ値がもっともらしいかについての事前情報を表す確率分布 $p(\phi)$
3. **事後分布の要約**：事後分布 $p(\phi \mid y)$ を，事後平均・中央値・最頻値・予測確率・信用域といった関心のある量で記述すること

1 と 2 を決め，データを集めた時点で，事後分布は

$$p(\phi \mid y) = \frac{p(\phi)\, p(y \mid \phi)}{p(y)} = \frac{p(\phi)\, p(y \mid \phi)}{\int p(\phi)\, p(y \mid \phi)\, d\phi}$$

として**完全に決まってしまう**．ある意味で，そこから先にモデリングも推定も残っていない．残っているのは 3 の「要約」だけである．

ところが多くのモデルで $p(\phi \mid y)$ は複雑で書き下すのも難しい．そこで，$p(\phi \mid y)$ を「**眺める**」ための便利な方法としてそこからのモンテカルロ標本を調べる．

注意

モンテカルロ法・MCMC 法は何でないか

- **モデルではない**
- y と $p(\phi)$ に含まれる以上の**「情報」を生み出しはしない**
- 単に $p(\phi \mid y)$ を**「眺める方法」にすぎない**

たとえば $\phi^{(1)}, \ldots, \phi^{(S)}$ が $p(\phi \mid y)$ からの近似的な標本であるとき，これらは事後分布を記述するのに役立つ：

$$\frac{1}{S}\sum_s \phi^{(s)} \approx \int \phi\, p(\phi \mid y)\, d\phi,$$

$$\frac{1}{S}\sum_s \mathbf{1}(\phi^{(s)} \le c) \approx \Pr(\phi \le c \mid y) = \int_{-\infty}^{c} p(\phi \mid y)\, d\phi.$$

用語の使い分け

この区別を忘れないために，次のように語を使い分けるとよい：

- **推定**（estimation）：$p(\phi \mid y)$ を使って ϕ について推論すること
- **近似**（approximation）：モンテカルロ的な手続きで積分を近似すること

ポイント

なぜこの区別が大事か

標本サイズ S を増やして改善されるのは**近似**のほうだけである．S を 1000 から 100,000 にすれば事後平均の数値は精密になるが，**事後分布そのものは 1 ミリも変わらない**．$p(\phi \mid y)$ はデータと事前分布だけで決まっているからである．

逆に，事後分布に不満があるなら（たとえば区間が広すぎるなら），直すべきなのはモデルか事前分布かデータであって，MCMC の反復回数ではない．

また 6.6 節で出てくる **MCMC 標準誤差**は，「ϕ がどれだけ不確実か」ではなく「**われわれの数値計算がどれだけ雑か**」を測る量である．事後標準偏差と MCMC 標準誤差を混同しないこと．

6　まとめ

6.5 節のまとめ

1. ギブスサンプラーは p 個のパラメータに自然に拡張される．j 番目を引くときは，更新済みの成分には新しい値を，未更新の成分には古い値を使う．
2. 生成される列は**マルコフ連鎖**である（$\phi^{(s)}$ は $\phi^{(s-1)}$ を通じてのみ過去に依存する）．
3. ある条件のもとで，**出発点によらず**標本分布は目標分布に収束し（主張 1），標本平均は期待値に収束する（主張 2，式 6.1）．これで 6.3 節の循環が正式に解消される．この種の近似を **MCMC 近似**と呼ぶ．
4. モンテカルロ法と MCMC 法は**モデルでも情報源でもなく**，すでに決まっている事後分布を「眺める方法」にすぎない．$p(\phi \mid y)$ による推論を**推定**，積分の数値計算を**近似**と呼び分けて区別する．

■次節へ　本節の主張 1・2 はいずれも $s \to \infty$，$S \to \infty$ の話である．現実には有限回しか回せない．

有限の S で，その近似はどれくらい信用できるのか？ 収束したかどうかをどう判断する

のか？——これが 6.6 節の問題である.