The Multivariate Normal Model

Hoff 第7章 — 多変量正規モデルのベイズ推論

目次

1. 7.1 多変量正規分布
2. 7.2 平均ベクトルの半共役事前分布
3. 7.3 逆ウィシャート分布
4. 7.4 ギブスサンプラー
5. 7.5 欠損データと代入法
6. まとめ

7.1 多変量正規分布

なぜ多変量正規分布か？

第 5・6 章：1 変数 $y \in \mathbb{R}$ → 正規分布

現実のデータは複数の変数を同時に持つ：

- 血圧・体重・年齢
- 読解テストの時間 1・時間 2 のスコア
- 遺伝子発現量の複数遺伝子

第 7 章のテーマ

正規分布のベイズ推論を**ベクトル**に拡張する

平均 θ	→	平均ベクトル $\boldsymbol{\theta}$
分散 σ^2	→	共分散行列 Σ
inverse-gamma	→	inverse-**Wishart**

多変量正規分布の定義

定義：$\boldsymbol{Y} \sim \mathrm{MVN}(\boldsymbol{\theta}, \Sigma)$

p 次元確率ベクトル $\boldsymbol{Y}$ の密度：

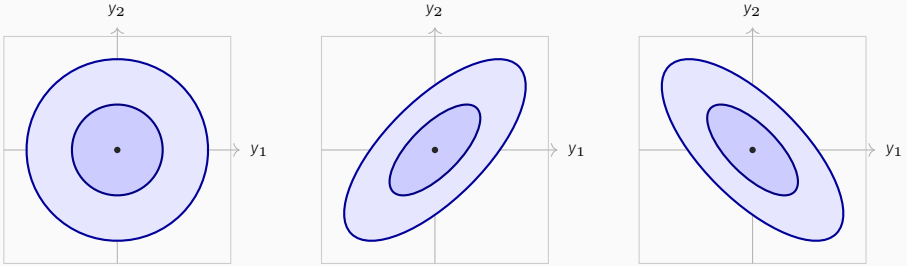
$$p(\boldsymbol{y} \mid \boldsymbol{\theta}, \Sigma) = (2\pi)^{-p/2} |\Sigma|^{-1/2} \exp\left\{ -\frac{1}{2} (\boldsymbol{y} - \boldsymbol{\theta})^\top \Sigma^{-1} (\boldsymbol{y} - \boldsymbol{\theta}) \right\}$$

- $\boldsymbol{\theta}$：**平均ベクトル**（p 次元）
- Σ：$p \times p$ **共分散行列**（対称・正定値）
- $(\boldsymbol{y} - \boldsymbol{\theta})^\top \Sigma^{-1} (\boldsymbol{y} - \boldsymbol{\theta})$：**マハラノビス距離の 2 乗**

1 次元との対応：$p = 1$ のとき $\Sigma = \sigma^2$ → 通常の正規分布に帰着

等高線は楕円

$$\{y : (\boldsymbol{y} - \boldsymbol{\theta})^\top \Sigma^{-1} (\boldsymbol{y} - \boldsymbol{\theta}) = c\} \to \text{楕円}$$



$\rho = 0$ $\rho = 0.7$ $\rho = -0.7$

- $\rho = 0$：円（変数間に相関なし）
- $\rho > 0$：右上がり楕円（正の相関）

1次元との比較表

	正規分布	多変量正規分布
データ	$y \in \mathbb{R}$	$\boldsymbol{y} \in \mathbb{R}^p$
中心	平均 θ	平均ベクトル $\boldsymbol{\theta}$
広がり	分散 σ^2	共分散行列 Σ
精度	$1/\sigma^2$	精度行列 Σ^{-1}
距離	$(y-\theta)^2/\sigma^2$	$(\boldsymbol{y}-\boldsymbol{\theta})^\top \Sigma^{-1}(\boldsymbol{y}-\boldsymbol{\theta})$
標本平均	$\bar{Y} \sim N(\theta, \sigma^2/n)$	$\bar{\boldsymbol{Y}} \sim \mathrm{MVN}(\boldsymbol{\theta}, \Sigma/n)$

7.2 平均ベクトルの半共役事前分布

モデル設定

階層モデル

$$
\begin{aligned}
Y_1, \ldots, Y_n \mid \boldsymbol{\theta}, \Sigma &\overset{\text{i.i.d.}}{\sim} \mathrm{MVN}(\boldsymbol{\theta}, \Sigma) \quad \text{（尤度）} \\
\boldsymbol{\theta} &\sim \mathrm{MVN}(\boldsymbol{\mu}_0, \Lambda_0) \qquad \text{（事前分布）}
\end{aligned}
$$

- Σ：この節では**既知**として扱う（7.3 節で未知に拡張）
- 「半共役」：$\boldsymbol{\theta}$ の事前分布は Σ を条件に共役だが，$(\boldsymbol{\theta}, \Sigma)$ の同時分布としては共役でない

事後分布の導出（概要）

$$p(\boldsymbol{\theta} \mid \boldsymbol{Y}, \Sigma) \propto \underbrace{p(\boldsymbol{Y} \mid \boldsymbol{\theta}, \Sigma)}_{\text{尤度}} \cdot \underbrace{p(\boldsymbol{\theta})}_{\text{事前}}$$

指数の中をまとめると（$\boldsymbol{\theta}$ に関して）：

$$-\frac{1}{2}\left[\boldsymbol{\theta}^\top \underbrace{\left(\Lambda_0^{-1} + n\Sigma^{-1}\right)}_{=\Lambda_n^{-1}} \boldsymbol{\theta} - 2\underbrace{\left(\Lambda_0^{-1}\boldsymbol{\mu}_0 + n\Sigma^{-1}\bar{\boldsymbol{y}}\right)^\top}_{=\boldsymbol{\mu}_n^\top \Lambda_n^{-1}} \boldsymbol{\theta}\right]$$

これは $\mathrm{MVN}(\boldsymbol{\mu}_n, \Lambda_n)$ の**核（kernel）**

事後分布の結果

定理：θ の事後分布

$$\boldsymbol{\theta} \mid Y, \Sigma \sim \mathrm{MVN}(\boldsymbol{\mu}_n, \Lambda_n)$$

$$\Lambda_n = \left(\Lambda_0^{-1} + n\Sigma^{-1}\right)^{-1}$$

$$\boldsymbol{\mu}_n = \Lambda_n \left(\Lambda_0^{-1}\boldsymbol{\mu}_0 + n\Sigma^{-1}\bar{\boldsymbol{y}}\right)$$

精度行列の加算

$$\Lambda_n^{-1} = \Lambda_0^{-1} + n\Sigma^{-1}$$

（事後の精度）＝（事前の精度）＋（データの精度）

1次元との完全な対応

	1 次元（5.2 節）	多変量（7.2 節）
精度の加算	$\dfrac{1}{\tau_n^2} = \dfrac{1}{\tau_0^2} + \dfrac{n}{\sigma^2}$	$\Lambda_n^{-1} = \Lambda_0^{-1} + n\Sigma^{-1}$
事後平均	$\mu_n = \tau_n^2\left(\dfrac{\mu_0}{\tau_0^2} + \dfrac{n\bar{y}}{\sigma^2}\right)$	$\boldsymbol{\mu}_n = \Lambda_n\left(\Lambda_0^{-1}\boldsymbol{\mu}_0 + n\Sigma^{-1}\bar{\boldsymbol{y}}\right)$
事後分布	$\theta \sim N(\mu_n, \tau_n^2)$	$\boldsymbol{\theta} \sim \mathrm{MVN}(\boldsymbol{\mu}_n, \Lambda_n)$

スカラー → 行列 に置き換えるだけ

7.3 逆ウィシャート分布

逆ウィシャート分布とは

定義：$\Sigma \sim \text{inverse-Wishart}(\nu_0, S_0^{-1})$

$$p(\Sigma) \propto |\Sigma|^{-(\nu_0+p+1)/2} \exp\left\{-\frac{1}{2}\text{tr}(S_0\Sigma^{-1})\right\}$$

- $\nu_0 > p-1$：自由度
- S_0：スケール行列（$p \times p$ 正定値）
- $E[\Sigma] = \dfrac{S_0}{\nu_0 - p - 1}$ （$\nu_0 > p+1$）

逆ガンマ（1 次元）→ 逆ウィシャート（多次元）

1次元との対応表

	1 次元正規モデル	多変量正規モデル
推定する広がり	分散 $\sigma^2 > 0$	共分散行列 Σ（正定値）
共役事前分布	$\text{inverse-gamma}(\nu_0/2, \nu_0\sigma_0^2/2)$	$\text{inverse-Wishart}(\nu_0, S_0^{-1})$
指数の中	$-\nu_0\sigma_0^2/(2\sigma^2)$	$-\frac{1}{2}\text{tr}(S_0\Sigma^{-1})$
べき乗	$(\sigma^2)^{-(\nu_0/2+1)}$	$\lvert\Sigma\rvert^{-(\nu_0+p+1)/2}$
更新	平方和 $\sum(y_i-\theta)^2$ を足す	平方和行列 S_θ を足す

トレース恒等式：なぜ tr が出るか

スカラー：$a^\top B a = \mathrm{tr}(B a a^\top)$（スカラーのトレースは自身）

この恒等式を使うと：

$$\sum_{i=1}^{n} (\boldsymbol{y}_i - \boldsymbol{\theta})^\top \Sigma^{-1} (\boldsymbol{y}_i - \boldsymbol{\theta}) = \sum_{i=1}^{n} \mathrm{tr}\left(\Sigma^{-1} (\boldsymbol{y}_i - \boldsymbol{\theta})(\boldsymbol{y}_i - \boldsymbol{\theta})^\top \right)$$

$$= \mathrm{tr}\left(\Sigma^{-1} \underbrace{\sum_{i=1}^{n} (\boldsymbol{y}_i - \boldsymbol{\theta})(\boldsymbol{y}_i - \boldsymbol{\theta})^\top}_{S_\theta} \right)$$

$$= \mathrm{tr}(S_\theta \Sigma^{-1})$$

$S_\theta = \sum_i (\boldsymbol{y}_i - \boldsymbol{\theta})(\boldsymbol{y}_i - \boldsymbol{\theta})^\top$：平方和行列（$p \times p$）

Σ の条件付き事後分布

$\boldsymbol{\theta}$ を条件としたとき：

$$
\begin{aligned}
\text{尤度} &\propto |\Sigma|^{-n/2} \exp\{-\tfrac{1}{2}\mathrm{tr}(S_\theta \Sigma^{-1})\} \\
\text{事前} &\propto |\Sigma|^{-(\nu_0+p+1)/2} \exp\{-\tfrac{1}{2}\mathrm{tr}(S_0 \Sigma^{-1})\}
\end{aligned}
$$

掛け合わせると

$$
p(\Sigma \mid \boldsymbol{Y}, \boldsymbol{\theta}) \propto |\Sigma|^{-(\nu_0+n+p+1)/2} \exp\left\{ -\frac{1}{2}\mathrm{tr}\big((S_0 + S_\theta)\Sigma^{-1}\big) \right\}
$$

定理：Σ の条件付き事後分布

$$
\Sigma \mid \boldsymbol{Y}, \boldsymbol{\theta} \ \sim\ \text{inverse-Wishart}\big(\nu_0 + n,\ (S_0 + S_\theta)^{-1}\big)
$$

更新則の直感

更新前		更新後
自由度 ν_0	$+n$	$\nu_0 + n$
スケール行列 S_0	$+S_\theta$	$S_0 + S_\theta$

- ν_0：事前の「仮想サンプル数」
- S_0：事前の「仮想平方和行列」
- $S_\theta = \sum(\boldsymbol{y}_i - \boldsymbol{\theta})(\boldsymbol{y}_i - \boldsymbol{\theta})^\top$：データの平方和行列

7.4 ギブスサンプラー

なぜ MCMC が必要か

問題：$(\boldsymbol{\theta}, \Sigma)$ の**同時**事後分布は解析的に求められない

しかし**条件付き**事後分布は両方とも既知：

$$\begin{aligned}\boldsymbol{\theta} \mid \boldsymbol{Y}, \Sigma &\sim \mathrm{MVN}(\boldsymbol{\mu}_n, \Lambda_n) \\ \Sigma \mid \boldsymbol{Y}, \boldsymbol{\theta} &\sim \text{inverse-Wishart}(\nu_0 + n, (S_0 + S_\theta)^{-1})\end{aligned}$$

解決策：ギブスサンプラー

条件付き分布から交互にサンプリングすることで，同時事後分布からのサンプルが得られる

ギブスサンプラーのアルゴリズム

初期値： $\Sigma^{(0)}$ を標本共分散行列などに設定

$s = 1, 2, \ldots, S$ **の繰り返し：**

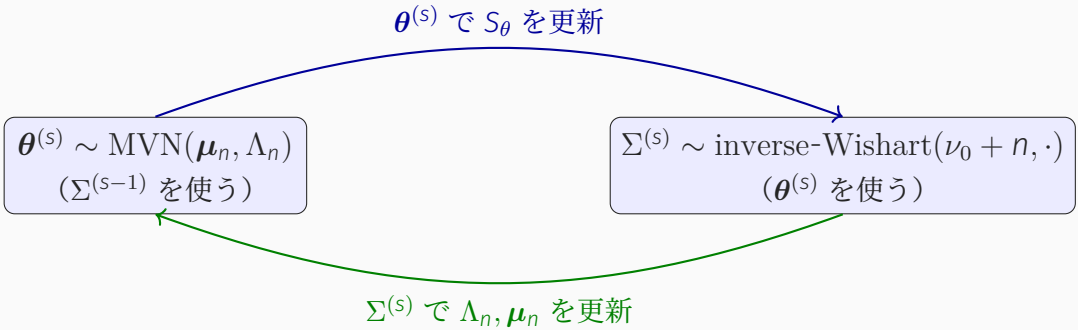
① $\Lambda_n = (\Lambda_0^{-1} + n(\Sigma^{(s-1)})^{-1})^{-1}$, $\boldsymbol{\mu}_n = \Lambda_n(\Lambda_0^{-1}\boldsymbol{\mu}_0 + n(\Sigma^{(s-1)})^{-1}\bar{\boldsymbol{y}})$

$\boldsymbol{\theta}^{(s)} \sim \mathrm{MVN}(\boldsymbol{\mu}_n, \Lambda_n)$

② $S_\theta^{(s)} = \sum_i (\boldsymbol{y}_i - \boldsymbol{\theta}^{(s)})(\boldsymbol{y}_i - \boldsymbol{\theta}^{(s)})^\top$

$\Sigma^{(s)} \sim \text{inverse-Wishart}(\nu_0 + n, (S_0 + S_\theta^{(s)})^{-1})$

ギブスサンプラーのフロー



- バーンイン後のサンプル $\{(\boldsymbol{\theta}^{(s)}, \Sigma^{(s)})\}$ は $p(\boldsymbol{\theta}, \Sigma \mid \boldsymbol{Y})$ に近似収束
- サンプルから事後平均・区間推定・確率計算がすべて可能

R での実装（概要）

```
# 事前分布パラメータ
mu0 <- c(50, 50)
L0  <- matrix(c(625,312.5,312.5,625), 2, 2)
nu0 <- 4
S0  <- matrix(c(625,312.5,312.5,625), 2, 2)

Sigma <- cov(Y)  # 初期値

for (s in 1:5000) {
  # theta のサンプリング
  Ln  <- solve(solve(L0) + n * solve(Sigma))
  mun <- Ln %*% (solve(L0) %*% mu0 +
                 n * solve(Sigma) %*% ybar)
  theta <- mvrnorm(1, mun, Ln)

  # Sigma のサンプリング
```

読解力データの例（$n = 22$，$p = 2$）

データ：22 名の生徒，2 回のテストスコア

事前分布：$\boldsymbol{\mu}_0 = (50, 50)^\top$，$\Lambda_0 = S_0 = \begin{pmatrix} 625 & 312.5 \\ 312.5 & 625 \end{pmatrix}$，$\nu_0 = 4$

標本統計量：

$$\bar{\boldsymbol{y}} = \begin{pmatrix} 47.18 \\ 53.77 \end{pmatrix}, \quad S_{\bar{y}} = \begin{pmatrix} 87.0 & 56.9 \\ 56.9 & 75.1 \end{pmatrix}$$

事後分布の要約（MCMC）：

$$E[\theta_1 \mid \boldsymbol{Y}] \approx 47.5, \quad E[\theta_2 \mid \boldsymbol{Y}] \approx 53.5, \quad E[\rho \mid \boldsymbol{Y}] \approx 0.70$$

データからは 2 回のテストに強い正の相関が示唆される

MCMC サンプルを使った事後推論

ギブスサンプラーのサンプル $\{(\boldsymbol{\theta}^{(s)}, \Sigma^{(s)})\}$ から：

- **事後平均：** $E[\theta_1 \mid Y] \approx \frac{1}{S}\sum_s \theta_1^{(s)}$
- **事後区間：** θ_1 の 95% 信用区間 → サンプルの 2.5%/97.5% 分位点
- **確率計算：** $P(\theta_1 < \theta_2 \mid Y) \approx \frac{1}{S}\sum_s \mathbf{1}[\theta_1^{(s)} < \theta_2^{(s)}]$
- **相関係数：** $\rho^{(s)} = \Sigma_{12}^{(s)} / \sqrt{\Sigma_{11}^{(s)}\Sigma_{22}^{(s)}}$

ベイズ MCMC の強み

同時事後分布のサンプルがあれば，あらゆる関数の事後分布が計算できる

7.5 欠損データと代入法

欠損データの問題

設定：y_i の一部の成分が観測されていない

$$y_i = \begin{pmatrix} y_{i,\text{obs}} \\ y_{i,\text{miss}} \end{pmatrix}$$

古典的なアプローチ：欠損のある行を削除（complete-case analysis）

- サンプルサイズの損失
- バイアスの危険（欠損が無作為でない場合）

ベイズ的アプローチ：y_{miss} を未知パラメータとして推論する

MVN の条件付き分布（補完の理論的根拠）

定理：MVN の条件付き分布

$Y = (Y_1^\top, Y_2^\top)^\top \sim \mathrm{MVN}(\boldsymbol{\theta}, \Sigma)$ のとき

$$Y_1 \mid Y_2 = y_2 \;\sim\; \mathrm{MVN}\big(\boldsymbol{\theta}_1 + \Sigma_{12}\Sigma_{22}^{-1}(y_2 - \boldsymbol{\theta}_2),\; \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}\big)$$

直感：

- 条件付き平均：Y_2 の観測値で修正された $\boldsymbol{\theta}_1$
- 条件付き分散：Σ_{11} から相関で説明できた分を差し引いた不確実性

欠損値を含むギブスサンプラー

各イテレーションで3ステップ：

1. **欠損値のサンプリング（データ拡大）**
   各 i について

$$y_{i,\text{miss}}^{(s)} \mid y_{i,\text{obs}}, \theta^{(s-1)}, \Sigma^{(s-1)} \sim \text{MVN}(\cdots)$$

2. **θ のサンプリング**
   完全なデータ $(y_{i,\text{obs}}, y_{i,\text{miss}}^{(s)})$ で $\theta \mid Y, \Sigma$ からサンプリング
3. **Σ のサンプリング**
   $\Sigma \mid Y, \theta$ からサンプリング

データ拡大（Data Augmentation）

欠損値の不確実性を正しく伝播させながら推論できる

Pima インディアン女性のデータ例

データ：200 名の Pima インディアン女性

- BMI，血糖値，糖尿病遺伝因子など複数の健康指標
- 一部の変数に欠損あり

分析の流れ：

1. 欠損値を含むギブスサンプラーを実行
2. 各イテレーションで欠損値を条件付き MVN から補完
3. $(\boldsymbol{\theta}, \Sigma)$ の事後分布を推定

利点：

- 欠損値を削除しないためサンプルサイズを保てる
- 欠損の不確実性が事後分布に反映される

まとめ

第 7 章のまとめ

理論

- MVN 密度 → 楕円型の等高線
- 精度行列の加算で事後分布
- inverse-Wishart = 逆ガンマの多変量版
- トレース恒等式：$\sum(\cdots)^\top \Sigma^{-1}(\cdots) = \mathrm{tr}(S_\theta \Sigma^{-1})$

計算

- $\boldsymbol{\theta} \mid \boldsymbol{Y}, \Sigma \sim \mathrm{MVN}(\boldsymbol{\mu}_n, \Lambda_n)$
- $\Sigma \mid \boldsymbol{Y}, \boldsymbol{\theta} \sim \text{inverse-Wishart}(\nu_0 + n, (S_0 + S_\theta)^{-1})$
- ギブスサンプラーで交互サンプリング
- 欠損値はデータ拡大で処理

第 7 章が第 8・11 章の土台

- 第 8 章：グループ比較・階層モデル（$\boldsymbol{Y}_j$ が MVN）
- 第 11 章：階層回帰（$\boldsymbol{\beta}_j \sim \mathrm{MVN}(\boldsymbol{\theta}, \Sigma)$）

Key Formulas

