Hoff 第 7 章

The Multivariate Normal Model

（多変量正規モデル）ゼミ資料（和訳＋計算補足）

1　この章のモチベーション

第 5・6 章では 1 次元のデータ $y_i \in \mathbb{R}$ を扱った．しかし現実のデータはしばしば**複数の変数**を同時に持つ．例えば血圧・BMI・年齢は別々に見るより，**相関まで含めてまとめてモデル化**すべきである．

ポイント

第 7 章のテーマは，1 次元の正規分布に基づくベイズ推論を**多変量に拡張**することである．

- 平均 θ → 平均**ベクトル** $\boldsymbol{\theta}$
- 分散 σ^2 → 共分散**行列** Σ
- inverse-gamma 事前分布 → inverse-**Wishart** 事前分布
- 積分（スカラー）→ 積分（行列式・トレース）

2　7.1 多変量正規分布（The Multivariate Normal Density）

多変量正規分布（Multivariate Normal, MVN）

p 次元の確率ベクトル $\boldsymbol{Y} = (Y_1, \ldots, Y_p)^\top$ が

$$\boldsymbol{Y} \mid \boldsymbol{\theta}, \Sigma \sim \mathrm{MVN}(\boldsymbol{\theta}, \Sigma)$$

であるとは，その確率密度が

$$p(\boldsymbol{y} \mid \boldsymbol{\theta}, \Sigma) = (2\pi)^{-p/2} |\Sigma|^{-1/2} \exp\left\{ -\frac{1}{2} (\boldsymbol{y} - \boldsymbol{\theta})^\top \Sigma^{-1} (\boldsymbol{y} - \boldsymbol{\theta}) \right\}$$

で与えられることをいう．ここで

- $\boldsymbol{\theta} \in \mathbb{R}^p$：**平均ベクトル**（$E[\boldsymbol{Y}] = \boldsymbol{\theta}$）
- Σ：$p \times p$ の**共分散行列**（対称・正定値，$\Sigma_{jk} = \mathrm{Cov}[Y_j, Y_k]$）
- $|\Sigma|$：Σ の行列式（体積スケーリング因子）
- Σ^{-1}：精度行列（Σ の逆行列）

2.1　1 次元との対応

$p = 1$ のとき $\Sigma = \sigma^2$（スカラー），$\Sigma^{-1} = 1/\sigma^2$，$|\Sigma|^{1/2} = \sigma$ となり，

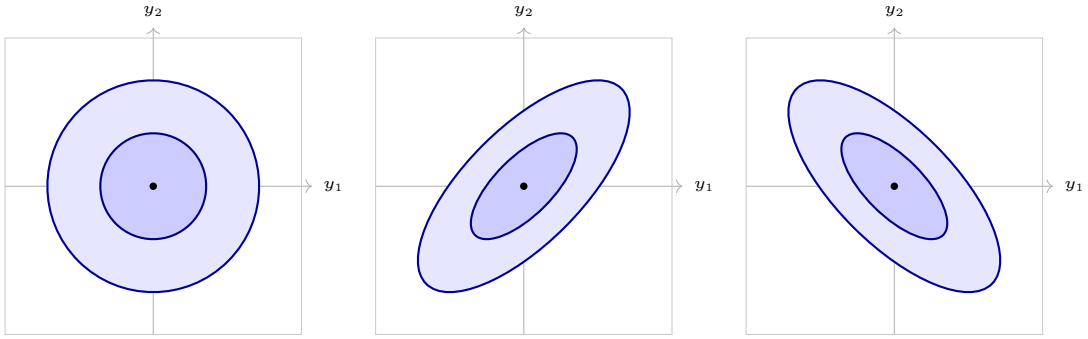
$$p(y \mid \theta, \sigma^2) = (2\pi)^{-1/2} \sigma^{-1} \exp\left\{ -\frac{(y - \theta)^2}{2\sigma^2} \right\}$$

と通常の正規分布に帰着する．

	正規分布（1 次元）	多変量正規分布（p 次元）
データ	数 $y \in \mathbb{R}$	ベクトル $\boldsymbol{y} \in \mathbb{R}^p$
中心	平均 θ	平均ベクトル $\boldsymbol{\theta}$
広がり	分散 σ^2	共分散行列 Σ（$p \times p$）
精度	$1/\sigma^2$	精度行列 Σ^{-1}（$p \times p$）
正規化定数	$(2\pi\sigma^2)^{-1/2}$	$(2\pi)^{-p/2}\lvert\Sigma\rvert^{-1/2}$
二乗距離	$(y-\theta)^2/\sigma^2$	$(\boldsymbol{y}-\boldsymbol{\theta})^\top\Sigma^{-1}(\boldsymbol{y}-\boldsymbol{\theta})$（マハラノビス距離の 2 乗）

2.2 二次形式（マハラノビス距離）の幾何学的意味

スカラーの場合，$(y-\theta)^2/\sigma^2$ が「θ から y が何標準偏差離れているか」を測る．多変量の場合，$(\boldsymbol{y}-\boldsymbol{\theta})^\top\Sigma^{-1}(\boldsymbol{y}-\boldsymbol{\theta})$ が**マハラノビス距離の 2 乗**で，各方向の**ばらつきと相関を考慮した距離**である．



$\rho = 0$（円）　$\rho = 0.7$（右上がり楕円）　$\rho = -0.7$（右下がり楕円）

等高線（$(\boldsymbol{y}-\boldsymbol{\theta})^\top\Sigma^{-1}(\boldsymbol{y}-\boldsymbol{\theta}) = c$ の集合）は**楕円**になる．

2.3 共分散行列の読み方

$p = 2$ のとき

$$\Sigma = \begin{pmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{pmatrix}, \qquad \rho = \frac{\sigma_{12}}{\sigma_1\sigma_2}.$$

- σ_1^2, σ_2^2：各変数のばらつき（対角成分）

- σ_{12}：2 変数が**一緒に動く傾向**（非対角成分）
- $\rho \in (-1, 1)$：相関係数

2.4 よく使う性質

性質（1 次元の拡張）

$\boldsymbol{Y}_1, \ldots, \boldsymbol{Y}_n \overset{\text{i.i.d.}}{\sim} \mathrm{MVN}(\boldsymbol{\theta}, \Sigma)$ のとき

1. **標本平均も MVN**：$\bar{\boldsymbol{Y}} = \frac{1}{n}\sum_i \boldsymbol{Y}_i \sim \mathrm{MVN}(\boldsymbol{\theta},\, \Sigma/n)$
2. **線形変換**：$A\boldsymbol{Y} + \boldsymbol{c} \sim \mathrm{MVN}(A\boldsymbol{\theta} + \boldsymbol{c},\, A\Sigma A^\top)$
3. **周辺分布**：各成分 $Y_k \sim \mathrm{Normal}(\theta_k, \Sigma_{kk})$
4. **MVN では「無相関 $\Leftrightarrow$ 独立」**（一般の分布では成立しない）

計算補足：標本平均が $\mathrm{MVN}(\boldsymbol{\theta},\, \Sigma/n)$ になること

$\boldsymbol{Y}_i \overset{\text{i.i.d.}}{\sim} \mathrm{MVN}(\boldsymbol{\theta}, \Sigma)$ のとき，独立な和の性質より

$$\sum_{i=1}^{n} \boldsymbol{Y}_i \sim \mathrm{MVN}(n\boldsymbol{\theta},\, n\Sigma).$$

ここに線形変換 $A = \frac{1}{n} I$ を適用すると

$$\bar{\boldsymbol{Y}} = \frac{1}{n}\sum_i \boldsymbol{Y}_i \sim \mathrm{MVN}\left(\frac{1}{n}\cdot n\boldsymbol{\theta},\ \frac{1}{n^2}\cdot n\Sigma\right) = \mathrm{MVN}\left(\boldsymbol{\theta},\ \frac{\Sigma}{n}\right).$$

スカラーの「$\bar{Y} \sim N(\theta, \sigma^2/n)$」の行列版である．

3 7.2 平均ベクトルの半共役事前分布（A Semiconjugate Prior for the Mean）

3.1 モデル設定

$$\boldsymbol{Y}_1, \ldots, \boldsymbol{Y}_n \mid \boldsymbol{\theta}, \Sigma \overset{\text{i.i.d.}}{\sim} \mathrm{MVN}(\boldsymbol{\theta},\, \Sigma), \qquad \boldsymbol{\theta} \sim \mathrm{MVN}(\boldsymbol{\mu}_0,\, \Lambda_0).$$

Σ は**既知**として $\boldsymbol{\theta}$ を推論する（7.3 節で Σ も推論する）．

ポイント

「**半共役**（semiconjugate）」とは，$\boldsymbol{\theta}$ の事前分布が Σ を条件とした場合に共役であるが，$(\boldsymbol{\theta}, \Sigma)$ の**同時**分布としては共役でない，という意味である（第 6 章の 1 次元版の拡張）．

3.2　事後分布の導出

目標：$p(\boldsymbol{\theta} \mid \boldsymbol{y}_1, \ldots, \boldsymbol{y}_n, \Sigma)$ を求める．

$$
\begin{aligned}
p(\boldsymbol{\theta} \mid \boldsymbol{Y}, \Sigma) &\propto p(\boldsymbol{Y} \mid \boldsymbol{\theta}, \Sigma)\, p(\boldsymbol{\theta}) \\
&= \left[\prod_{i=1}^{n} p(\boldsymbol{y}_i \mid \boldsymbol{\theta}, \Sigma) \right] p(\boldsymbol{\theta}).
\end{aligned}
$$

ステップ 1：尤度の指数部分を整理する．

$$
\log p(\boldsymbol{Y} \mid \boldsymbol{\theta}, \Sigma) + \text{const} = -\frac{1}{2} \sum_{i=1}^{n} (\boldsymbol{y}_i - \boldsymbol{\theta})^\top \Sigma^{-1} (\boldsymbol{y}_i - \boldsymbol{\theta}).
$$

計算補足：二次形式の展開：$\sum_i (\boldsymbol{y}_i - \boldsymbol{\theta})^\top \Sigma^{-1} (\boldsymbol{y}_i - \boldsymbol{\theta})$

各項を展開すると

$$
(\boldsymbol{y}_i - \boldsymbol{\theta})^\top \Sigma^{-1} (\boldsymbol{y}_i - \boldsymbol{\theta}) = \boldsymbol{y}_i^\top \Sigma^{-1} \boldsymbol{y}_i - 2 \boldsymbol{y}_i^\top \Sigma^{-1} \boldsymbol{\theta} + \boldsymbol{\theta}^\top \Sigma^{-1} \boldsymbol{\theta}.
$$

i について和をとり，$\boldsymbol{\theta}$ に依存しない第 1 項を定数として落とすと

$$
\begin{aligned}
\sum_{i=1}^{n} (\boldsymbol{y}_i - \boldsymbol{\theta})^\top \Sigma^{-1} (\boldsymbol{y}_i - \boldsymbol{\theta}) &= \boldsymbol{\theta}^\top (n\Sigma^{-1}) \boldsymbol{\theta} - 2 \left(\sum_i \boldsymbol{y}_i \right)^\top \Sigma^{-1} \boldsymbol{\theta} + \text{const} \\
&= \boldsymbol{\theta}^\top (n\Sigma^{-1}) \boldsymbol{\theta} - 2 (n\bar{\boldsymbol{y}})^\top \Sigma^{-1} \boldsymbol{\theta} + \text{const}.
\end{aligned}
$$

つまり尤度の指数部分に出てくる $\boldsymbol{\theta}$ に関わる二次と一次の係数は

$$
A_\ell = n\Sigma^{-1}, \quad \boldsymbol{b}_\ell = n\Sigma^{-1} \bar{\boldsymbol{y}}.
$$

ステップ 2：事前分布の指数部分を整理する．

$$
\log p(\boldsymbol{\theta}) + \text{const} = -\frac{1}{2} (\boldsymbol{\theta} - \boldsymbol{\mu}_0)^\top \Lambda_0^{-1} (\boldsymbol{\theta} - \boldsymbol{\mu}_0).
$$

計算補足：事前分布の展開

$$(\boldsymbol{\theta}-\boldsymbol{\mu}_0)^\top\Lambda_0^{-1}(\boldsymbol{\theta}-\boldsymbol{\mu}_0)=\boldsymbol{\theta}^\top\Lambda_0^{-1}\boldsymbol{\theta}-2\boldsymbol{\mu}_0^\top\Lambda_0^{-1}\boldsymbol{\theta}+\boldsymbol{\mu}_0^\top\Lambda_0^{-1}\boldsymbol{\mu}_0.$$

よって事前分布の係数は

$$A_0=\Lambda_0^{-1},\quad \boldsymbol{b}_0=\Lambda_0^{-1}\boldsymbol{\mu}_0.$$

ステップ 3：指数をまとめて事後分布の型を読み取る．

尤度 × 事前分布の指数全体を $\boldsymbol{\theta}$ について整理すると

$$-\frac{1}{2}\Big[\boldsymbol{\theta}^\top(A_0+A_\ell)\boldsymbol{\theta}-2(\boldsymbol{b}_0+\boldsymbol{b}_\ell)^\top\boldsymbol{\theta}\Big]+\text{const.}$$

これは MVN の核（kernel）の形

$$-\frac{1}{2}(\boldsymbol{\theta}-\boldsymbol{m})^\top V^{-1}(\boldsymbol{\theta}-\boldsymbol{m})\ \propto\ \exp\left\{-\frac{1}{2}\boldsymbol{\theta}^\top V^{-1}\boldsymbol{\theta}+\boldsymbol{\theta}^\top V^{-1}\boldsymbol{m}\right\}$$

と対応させると，$V^{-1}=A_0+A_\ell$，$V^{-1}\boldsymbol{m}=\boldsymbol{b}_0+\boldsymbol{b}_\ell$ なので：

7.2 節の事後分布（定理）

$$\boldsymbol{\theta}\mid\boldsymbol{Y},\Sigma\ \sim\ \mathrm{MVN}(\boldsymbol{\mu}_n,\,\Lambda_n),$$

$$\Lambda_n=\left(\Lambda_0^{-1}+n\Sigma^{-1}\right)^{-1},\tag{1}$$
$$\boldsymbol{\mu}_n=\Lambda_n\left(\Lambda_0^{-1}\boldsymbol{\mu}_0+n\Sigma^{-1}\bar{\boldsymbol{y}}\right).\tag{2}$$

計算補足：MVN の核の識別（行列版の平方完成）

1 次元の場合，$e^{-ax^2/2+bx}\propto\exp\{-\frac{a}{2}(x-b/a)^2\}$ なので $\mathrm{Normal}(b/a,\,1/a)$ と読み取った．

多変量では，対称正定値行列 A に対して

$$\exp\left\{-\frac{1}{2}\boldsymbol{\theta}^\top A\boldsymbol{\theta}+\boldsymbol{\theta}^\top\boldsymbol{b}\right\}=\exp\left\{-\frac{1}{2}(\boldsymbol{\theta}-A^{-1}\boldsymbol{b})^\top A(\boldsymbol{\theta}-A^{-1}\boldsymbol{b})\right\}\cdot\exp\left\{\frac{1}{2}\boldsymbol{b}^\top A^{-1}\boldsymbol{b}\right\}.$$

最後の因子は $\boldsymbol{\theta}$ に依存しないので比例の意味では定数．したがって $\boldsymbol{\theta}\ \sim\ \mathrm{MVN}(A^{-1}\boldsymbol{b},\,A^{-1})$，すなわち精度行列が A，平均が $A^{-1}\boldsymbol{b}$．

今の場合 $A=\Lambda_0^{-1}+n\Sigma^{-1}$，$\boldsymbol{b}=\Lambda_0^{-1}\boldsymbol{\mu}_0+n\Sigma^{-1}\bar{\boldsymbol{y}}$ なので，

$$\Lambda_n=A^{-1}=\left(\Lambda_0^{-1}+n\Sigma^{-1}\right)^{-1},\qquad \boldsymbol{\mu}_n=A^{-1}\boldsymbol{b}=\Lambda_n\left(\Lambda_0^{-1}\boldsymbol{\mu}_0+n\Sigma^{-1}\bar{\boldsymbol{y}}\right).$$

3.3　1 次元との対応

	1 次元（5.2 節）	多変量（7.2 節）
精度の加算	$1/\tau_n^2 = 1/\tau_0^2 + n/\sigma^2$	$\Lambda_n^{-1} = \Lambda_0^{-1} + n\Sigma^{-1}$
事後平均	$\mu_n = \tau_n^2(\mu_0/\tau_0^2 + n\bar{y}/\sigma^2)$	$\boldsymbol{\mu}_n = \Lambda_n(\Lambda_0^{-1}\boldsymbol{\mu}_0 + n\Sigma^{-1}\bar{\boldsymbol{y}})$
事後分布	$\theta \mid \boldsymbol{y}, \sigma^2 \sim N(\mu_n, \tau_n^2)$	$\boldsymbol{\theta} \mid \boldsymbol{Y}, \Sigma \sim \mathrm{MVN}(\boldsymbol{\mu}_n, \Lambda_n)$

1 次元でも多変量でも，**精度（精度行列）は加算される**，という構造は全く同じである．

3.4　事後平均の重み付き平均解釈

事後平均 $\boldsymbol{\mu}_n$ を書き直すと

$$\begin{aligned}\boldsymbol{\mu}_n &= \Lambda_n\Lambda_0^{-1}\boldsymbol{\mu}_0 + \Lambda_n \cdot n\Sigma^{-1}\bar{\boldsymbol{y}} \\ &= (I - \Lambda_n n\Sigma^{-1})\boldsymbol{\mu}_0 + \Lambda_n n\Sigma^{-1}\bar{\boldsymbol{y}}.\end{aligned}$$

$W = \Lambda_n n\Sigma^{-1} = (\Lambda_0^{-1} + n\Sigma^{-1})^{-1} \cdot n\Sigma^{-1}$ とおくと

$$\boldsymbol{\mu}_n = (I - W)\boldsymbol{\mu}_0 + W\bar{\boldsymbol{y}}.$$

これは $\boldsymbol{\mu}_0$（事前平均）と $\bar{\boldsymbol{y}}$（標本平均）の**行列重み付き平均**である．$n \to \infty$ のとき $W \to I$ なので $\boldsymbol{\mu}_n \to \bar{\boldsymbol{y}}$（データに引き寄せられる）．

4　7.3 逆ウィシャート分布（The Inverse-Wishart Distribution）

4.1　ガンマ分布との類比

ウィシャート分布はガンマ分布の多変量版である（z が平均ゼロの一変量正規確率変数であれば z^2 はガンマ確率変数になることを思い出されたい）．一変量正規モデルでは，精度 $1/\sigma^2$ に対する事前分布はガンマ分布であり，分散の完全条件付き分布は逆ガンマ分布であった．同様に，**ウィシャート分布は精度行列 Σ^{-1} に対する半共役事前分布**となることがわかる．したがって，**逆ウィシャート分布が共分散行列 Σ に対する半共役事前分布**となる．

	1 次元正規モデル	多変量正規モデル
推定する広がり	分散 $\sigma^2 > 0$	共分散行列 Σ（正定値対称）
精度パラメータ	$1/\sigma^2$	精度行列 Σ^{-1}
精度の事前分布	gamma$(\nu_0/2,\, \nu_0\sigma_0^2/2)$	Wishart$(\nu_0,\, S_0^{-1})$
広がりの事前分布	$(\nu_0/2,\, \nu_0\sigma_0^2/2)$	inverse-Wishart$(\nu_0,\, S_0^{-1})$

4.2 ウィシャート分布の構成：$Z^\top Z$ を用いたランダム共分散行列

ウィシャート分布がどのような分布かを理解するために，まず標本共分散行列の構造を確認する．

$\boldsymbol{z}_1, \ldots, \boldsymbol{z}_n$ が平均ゼロの母集団からのサンプルであるとき，行列 $\boldsymbol{z}_i \boldsymbol{z}_i^\top / n$ は，ベクトル $\boldsymbol{z}_i$ が全観測値の共分散行列の推定に対して寄与する部分と考えることができる．この平均ゼロの場合，$Z^\top Z$ を n で割ると**標本共分散行列**（不偏推定量）が得られる：

$$\frac{1}{n}[Z^\top Z]_{j,j} = \frac{1}{n}\sum_{i=1}^{n} z_{i,j}^2 = s_{j,j} = s_j^2, \qquad \frac{1}{n}[Z^\top Z]_{j,k} = \frac{1}{n}\sum_{i=1}^{n} z_{i,j} z_{i,k} = s_{j,k}.$$

$n > p$ かつ $\boldsymbol{z}_i$ たちが線形独立であれば，$Z^\top Z$ は正定値かつ対称になる．このことから，「ランダムな」共分散行列を構成する以下の方法が示唆される：

ウィシャート分布（Wishart distribution）

正の整数 ν_0 と $p \times p$ 正定値対称行列 Φ_0 が与えられたとき，以下の手順で $Z^\top Z$ を生成すると，$Z^\top Z \sim \text{Wishart}(\nu_0, \Phi_0)$ となる：

1. $\boldsymbol{z}_1, \ldots, \boldsymbol{z}_{\nu_0} \overset{\text{i.i.d.}}{\sim} \text{MVN}(\boldsymbol{0}, \Phi_0)$ をサンプリングする；
2. $Z^\top Z = \sum_{i=1}^{\nu_0} \boldsymbol{z}_i \boldsymbol{z}_i^\top$ を計算する．

期待値は $E[Z^\top Z] = \nu_0 \Phi_0$（1 次元の $E[z^2] = \sigma^2$ の行列版）．

計算補足：$E[Z^\top Z] = \nu_0 \Phi_0$ の確認

$\boldsymbol{z}_i \sim \text{MVN}(\boldsymbol{0}, \Phi_0)$ のとき，$E[\boldsymbol{z}_i \boldsymbol{z}_i^\top] = \text{Cov}[\boldsymbol{z}_i] = \Phi_0$（平均ゼロなので共分散＝ 2 次モーメント）．

したがって

$$E\left[Z^\top Z\right] = E\left[\sum_{i=1}^{\nu_0} \boldsymbol{z}_i \boldsymbol{z}_i^\top\right] = \sum_{i=1}^{\nu_0} E[\boldsymbol{z}_i \boldsymbol{z}_i^\top] = \nu_0 \Phi_0.$$

1 次元では $z \sim N(0, \sigma^2)$ のとき $E[z^2] = \sigma^2$ であったから，$E[Z^\top Z] = \nu_0 \Phi_0$ はその直接の行列版である．

4.3　逆ウィシャート分布の定義とサンプリング手順

わずかに再パラメータ化すると，逆ウィシャート分布から共分散行列 Σ をサンプリングするには以下の 3 ステップを踏む：

逆ウィシャート分布からのサンプリング手順

1. $\boldsymbol{z}_1, \ldots, \boldsymbol{z}_{\nu_0} \overset{\text{i.i.d.}}{\sim} \mathrm{MVN}(\mathbf{0}, S_0^{-1})$ をサンプリングする；
2. $Z^\top Z = \sum_{i=1}^{\nu_0} \boldsymbol{z}_i \boldsymbol{z}_i^\top$ を計算する；
3. $\Sigma = (Z^\top Z)^{-1}$ とおく．

このとき精度行列 $\Sigma^{-1} = Z^\top Z \sim \mathrm{Wishart}(\nu_0, S_0^{-1})$ であり，共分散行列 $\Sigma \sim$ inverse-Wishart(ν_0, S_0^{-1}) となる．

ポイント

直感：$\boldsymbol{z}_i \sim \mathrm{MVN}(\mathbf{0}, S_0^{-1})$ の標本共分散の逆行列を取ったものが，inverse-Wishart(ν_0, S_0^{-1}) からのサンプルである．ν_0 が大きい（サンプル数が多い）ほど，標本共分散は母共分散 S_0^{-1} に近くなり，$\Sigma = (Z^\top Z)^{-1}$ は $(S_0^{-1})^{-1} = S_0$（を ν_0 で割ったもの）の周りに集中する．

逆ウィシャート分布（inverse-Wishart distribution）

正定値対称行列 Σ が inverse-Wishart(ν_0, S_0^{-1}) に従うとは，密度が

$$p(\Sigma) \propto |\Sigma|^{-(\nu_0+p+1)/2} \exp\left\{-\frac{1}{2}\mathrm{tr}\left(S_0 \Sigma^{-1}\right)\right\}$$

で与えられることをいう．パラメータは

- $\nu_0 > p-1$：**自由度**（degrees of freedom），「事前のサンプル数」
- S_0：$p \times p$ 正定値対称行列（**スケール行列**）

精度行列 Σ^{-1} および共分散行列 Σ の期待値は

$$E[\Sigma^{-1}] = \nu_0 S_0^{-1},$$
$$E[\Sigma] = \frac{1}{\nu_0 - p - 1}(S_0^{-1})^{-1} = \frac{S_0}{\nu_0 - p - 1} \qquad (\nu_0 > p + 1).$$

計算補足：$E[\Sigma^{-1}] = \nu_0 S_0^{-1}$ の確認

サンプリング手順より $\Sigma^{-1} = Z^\top Z = \sum_{i=1}^{\nu_0} \boldsymbol{z}_i \boldsymbol{z}_i^\top$，$\boldsymbol{z}_i \sim \mathrm{MVN}(\boldsymbol{0}, S_0^{-1})$.
先ほどと同様，$E[\boldsymbol{z}_i \boldsymbol{z}_i^\top] = S_0^{-1}$ なので

$$E[\Sigma^{-1}] = E\left[\sum_{i=1}^{\nu_0} \boldsymbol{z}_i \boldsymbol{z}_i^\top\right] = \nu_0 S_0^{-1}.$$

1 次元での「$E[1/\sigma^2] = \nu_0/(\nu_0\sigma_0^2) = 1/\sigma_0^2$（倍数）」に相当する．

	1 次元	多変量
密度の指数部分	$\exp\{-\nu_0\sigma_0^2/(2\sigma^2)\}$	$\exp\{-\frac{1}{2}\mathrm{tr}(S_0\Sigma^{-1})\}$
密度のべき乗部分	$(\sigma^2)^{-(\nu_0/2+1)}$	$\lvert\Sigma\rvert^{-(\nu_0+p+1)/2}$
事後での更新	$\nu_0\sigma_0^2$ に $\sum(y_i-\theta)^2$ を足す	S_0 に $\sum(\boldsymbol{y}_i-\boldsymbol{\theta})(\boldsymbol{y}_i-\boldsymbol{\theta})^\top$ を足す
E[広がり]	σ_0^2（$\nu_0 \gg 0$ のとき）	$S_0/(\nu_0 - p - 1)$

4.4 トレース恒等式：tr がなぜ出てくるか

逆ウィシャート密度の指数の中に $\mathrm{tr}(S_0\Sigma^{-1})$ が出るのは，多変量正規の尤度を Σ の関数として書き直したときに自然に生じる．

計算補足：トレース恒等式：$\sum_i(\boldsymbol{y}_i-\boldsymbol{\theta})^\top\Sigma^{-1}(\boldsymbol{y}_i-\boldsymbol{\theta}) = \mathrm{tr}(S_\theta\Sigma^{-1})$

使う事実：任意のスカラー c に対して $c = \mathrm{tr}(c)$，および $\mathrm{tr}(AB) = \mathrm{tr}(BA)$（サイクリック性）．

各 i について，$(\boldsymbol{y}_i-\boldsymbol{\theta})^\top\Sigma^{-1}(\boldsymbol{y}_i-\boldsymbol{\theta})$ はスカラーなので

$$\begin{aligned}(\boldsymbol{y}_i-\boldsymbol{\theta})^\top\Sigma^{-1}(\boldsymbol{y}_i-\boldsymbol{\theta}) &= \mathrm{tr}\big((\boldsymbol{y}_i-\boldsymbol{\theta})^\top\Sigma^{-1}(\boldsymbol{y}_i-\boldsymbol{\theta})\big) \quad (\text{スカラー} = \mathrm{tr}(\text{スカラー}))\\ &= \mathrm{tr}\big(\Sigma^{-1}(\boldsymbol{y}_i-\boldsymbol{\theta})(\boldsymbol{y}_i-\boldsymbol{\theta})^\top\big). \quad (\mathrm{tr}(ABC)=\mathrm{tr}(CAB)\ \text{でサイクル})\end{aligned}$$

$i=1,\dots,n$ について和をとると

$$\begin{aligned}\sum_{i=1}^n(\boldsymbol{y}_i-\boldsymbol{\theta})^\top\Sigma^{-1}(\boldsymbol{y}_i-\boldsymbol{\theta}) &= \sum_{i=1}^n\mathrm{tr}\big(\Sigma^{-1}(\boldsymbol{y}_i-\boldsymbol{\theta})(\boldsymbol{y}_i-\boldsymbol{\theta})^\top\big)\\ &= \mathrm{tr}\left(\Sigma^{-1}\sum_{i=1}^n(\boldsymbol{y}_i-\boldsymbol{\theta})(\boldsymbol{y}_i-\boldsymbol{\theta})^\top\right) \quad (\text{トレースの線形性})\\ &= \mathrm{tr}\big(\Sigma^{-1}S_\theta\big) = \mathrm{tr}\big(S_\theta\Sigma^{-1}\big). \quad (\mathrm{tr}(AB)=\mathrm{tr}(BA))\end{aligned}$$

ここで

$$S_\theta=\sum_{i=1}^n(\boldsymbol{y}_i-\boldsymbol{\theta})(\boldsymbol{y}_i-\boldsymbol{\theta})^\top$$

を**平方和行列**（sum-of-squares matrix）という．$p\times p$ 正半定値行列で，1 次元の $\sum(y_i-\theta)^2$ の行列版である．

4.5　Σ の条件付き事後分布

$\boldsymbol{\theta}$ を条件としたとき，Σ の事後分布を導出する．

$$p(\Sigma\mid\boldsymbol{Y},\boldsymbol{\theta})\propto p(\boldsymbol{Y}\mid\boldsymbol{\theta},\Sigma)\,p(\Sigma).$$

尤度部分：

$$p(\boldsymbol{Y}\mid\boldsymbol{\theta},\Sigma)=\prod_{i=1}^n(2\pi)^{-p/2}|\Sigma|^{-1/2}\exp\left\{-\frac{1}{2}(\boldsymbol{y}_i-\boldsymbol{\theta})^\top\Sigma^{-1}(\boldsymbol{y}_i-\boldsymbol{\theta})\right\}.$$

$(2\pi)^{-p/2}$ は Σ に依存しないので定数として落とす．トレース恒等式を使うと，Σ に関わる部分のみ

$$\propto|\Sigma|^{-n/2}\exp\left\{-\frac{1}{2}\mathrm{tr}(S_\theta\Sigma^{-1})\right\}.$$

事前分布部分：$\Sigma\sim\text{inverse-Wishart}(\nu_0,S_0^{-1})$ より

$$p(\Sigma)\propto|\Sigma|^{-(\nu_0+p+1)/2}\exp\left\{-\frac{1}{2}\mathrm{tr}(S_0\Sigma^{-1})\right\}.$$

事後分布：2 つを掛け合わせ，$|\Sigma|$ のべき乗をまとめ，指数の中のトレースを合算する：

$$
\begin{aligned}
p(\Sigma \mid \boldsymbol{Y}, \boldsymbol{\theta}) &\propto |\Sigma|^{-n/2} \exp\left\{ -\frac{1}{2}\mathrm{tr}(S_\theta \Sigma^{-1}) \right\} \cdot |\Sigma|^{-(\nu_0+p+1)/2} \exp\left\{ -\frac{1}{2}\mathrm{tr}(S_0 \Sigma^{-1}) \right\} \\
&= |\Sigma|^{-\{(\nu_0+n)+p+1\}/2} \exp\left\{ -\frac{1}{2}\mathrm{tr}\big((S_0 + S_\theta)\Sigma^{-1}\big) \right\}.
\end{aligned}
$$

これは inverse-Wishart$(\nu_0 + n,\ (S_0 + S_\theta)^{-1})$ の密度の核と一致する．

Σ の条件付き事後分布（定理）

$$
\Sigma \mid \boldsymbol{Y},\ \boldsymbol{\theta} \ \sim\ \text{inverse-Wishart}\Big(\nu_0 + n,\ (S_0 + S_\theta)^{-1}\Big), \qquad S_\theta = \sum_{i=1}^{n} (\boldsymbol{y}_i - \boldsymbol{\theta})(\boldsymbol{y}_i - \boldsymbol{\theta})^\top.
$$

更新則：自由度に n を足し，スケール行列に S_θ を足すだけ．

ポイント

更新則の対応（1 次元との類比）：

	1 次元（逆ガンマ）	多変量（逆ウィシャート）
自由度の更新	$\nu_0 \to \nu_0 + n$	$\nu_0 \to \nu_0 + n$
「平方和」の更新	$\nu_0\sigma_0^2 \to \nu_0\sigma_0^2 + \sum(y_i - \theta)^2$	$S_0 \to S_0 + S_\theta$

スカラーの平方和 $\sum(y_i - \theta)^2$ が，行列の平方和 $S_\theta = \sum(\boldsymbol{y}_i - \boldsymbol{\theta})(\boldsymbol{y}_i - \boldsymbol{\theta})^\top$ に置き換わっただけ．

4.6 自由度とスケール行列の意味

- ν_0 が大きいほど，Σ の事後分布は事前に強く縛られる（「事前の仮想サンプル数」）．
- $E[\Sigma] = S_0/(\nu_0 - p - 1)$ なので，$S_0 = (\nu_0 - p - 1)\Sigma_0$ とすれば $E[\Sigma] = \Sigma_0$，つまり Σ_0 を事前の「典型的な共分散行列」として指定できる．
- $\nu_0 = p + 2$ は $E[\Sigma] = S_0$ を保ちつつ分布を最も拡散的（情報量が最小）にする最小の自由度．

5　7.4 ギブスサンプラー（Gibbs Sampling of the Mean and Covariance）

5.1　なぜ同時事後分布が求まらないか

$(\boldsymbol{\theta}, \Sigma)$ の**同時**事後分布 $p(\boldsymbol{\theta}, \Sigma \mid \boldsymbol{Y})$ を解析的に求めることは困難である．これは半共役（semiconjugate）な設定の本質的な制約であり，第 6 章の MCMC の多変量版の動機づけとなる．

しかし各々の**条件付き**事後分布は既知の分布形を持つ：

$$\boldsymbol{\theta} \mid \boldsymbol{Y}, \Sigma \sim \text{MVN}(\boldsymbol{\mu}_n, \Lambda_n), \qquad \Sigma \mid \boldsymbol{Y}, \boldsymbol{\theta} \sim \text{inverse-Wishart}(\nu_0 + n, (S_0 + S_\theta)^{-1}).$$

これを利用した**ギブスサンプラー**が有効である．

5.2　ギブスサンプリングのアルゴリズム

アルゴリズム：(θ, Σ) のギブスサンプラー

初期化：$\Sigma^{(0)}$ を適当な値（例：標本共分散行列）に設定する．

イテレーション $s = 1, 2, \ldots, S$**：**

1. $\Lambda_n^{(s)} = \left(\Lambda_0^{-1} + n\left(\Sigma^{(s-1)}\right)^{-1}\right)^{-1}$，$\boldsymbol{\mu}_n^{(s)} = \Lambda_n^{(s)}\left(\Lambda_0^{-1}\boldsymbol{\mu}_0 + n\left(\Sigma^{(s-1)}\right)^{-1}\bar{\boldsymbol{y}}\right)$ を計算する．
2. $\boldsymbol{\theta}^{(s)} \sim \text{MVN}\left(\boldsymbol{\mu}_n^{(s)}, \Lambda_n^{(s)}\right)$ をサンプリングする．
3. $S_\theta^{(s)} = \sum_{i=1}^{n}\left(\boldsymbol{y}_i - \boldsymbol{\theta}^{(s)}\right)\left(\boldsymbol{y}_i - \boldsymbol{\theta}^{(s)}\right)^\top$ を計算する．
4. $\Sigma^{(s)} \sim \text{inverse-Wishart}\left(\nu_0 + n,\ \left(S_0 + S_\theta^{(s)}\right)^{-1}\right)$ をサンプリングする．

結果：サンプル列 $\{(\boldsymbol{\theta}^{(1)}, \Sigma^{(1)}), \ldots, (\boldsymbol{\theta}^{(S)}, \Sigma^{(S)})\}$ がバーンイン後に $(bm\theta, \Sigma)$ の同時事後分布から近似的に得られる．

ポイント

なぜギブスサンプラーは動くか（直感）：

- Σ を固定すれば $\boldsymbol{\theta}$ の分布は MVN → 正確にサンプリングできる．
- $\boldsymbol{\theta}$ を固定すれば Σ の分布は inverse-Wishart → Wishart サンプラーの逆行列

で正確にサンプリングできる.

- 交互に繰り返せば，マルコフ連鎖の定常分布が $(\boldsymbol{\theta}, \Sigma)$ の同時事後分布になる（詳細は第 6 章）.

5.3 R での実装

```
# データ：n x p 行列 Y
# 事前分布のパラメータ
mu0 <- c(50, 50)            # 事前平均ベクトル
L0 <- matrix(c(625,312.5,312.5,625), 2, 2)  # 事前共分散行列
nu0 <- 4                    # 事前自由度
S0 <- matrix(c(625,312.5,312.5,625), 2, 2)  # 事前スケール行列

# 十分統計量
n <- nrow(Y)
ybar <- colMeans(Y)         # 標本平均ベクトル

# 初期値
Sigma <- cov(Y)

# ギブスサンプラー
THETA <- SIGMA <- NULL
for (s in 1:5000) {
  # theta のサンプリング
  Ln <- solve(solve(L0) + n * solve(Sigma))
  mun <- Ln %*% (solve(L0) %*% mu0 + n * solve(Sigma) %*% ybar)
  theta <- mvrnorm(1, mun, Ln)

  # Sigma のサンプリング
  Stheta <- (t(Y) - theta) %*% t(t(Y) - theta)  # 平方和行列
  Sigma <- solve(rwish(nu0 + n, solve(S0 + Stheta)))

  THETA <- rbind(THETA, theta)
  SIGMA <- rbind(SIGMA, c(Sigma))
}
```

5.4　読解例（Hoff 本の例）

例：読解力のデータ（$n = 22$，$p = 2$）

22 名の生徒に対して，2 つのテスト（時間 1 と時間 2）のスコアが記録されている．

事前分布の設定：

$$\boldsymbol{\mu}_0 = \begin{pmatrix} 50 \\ 50 \end{pmatrix}, \quad \Lambda_0 = \begin{pmatrix} 625 & 312.5 \\ 312.5 & 625 \end{pmatrix}, \quad \nu_0 = 4, \quad S_0 = \begin{pmatrix} 625 & 312.5 \\ 312.5 & 625 \end{pmatrix}.$$

データの要約：

$$\bar{\boldsymbol{y}} = \begin{pmatrix} 47.18 \\ 53.77 \end{pmatrix}, \qquad S_{\bar{y}} = \begin{pmatrix} 87.0 & 56.9 \\ 56.9 & 75.1 \end{pmatrix}.$$

事後分布（MCMC 結果）：

$$E[\theta_1 \mid \boldsymbol{Y}] \approx 47.5, \quad E[\theta_2 \mid \boldsymbol{Y}] \approx 53.5, \quad E[\rho \mid \boldsymbol{Y}] \approx 0.70.$$

データからは 2 つのテストに正の相関（$\rho \approx 0.70$）があることが示唆された．

ポイント

ギブスサンプラーを用いれば，$\theta_1 - \theta_2$ の事後分布や $P(\theta_1 < \theta_2 \mid \boldsymbol{Y})$ なども，サンプルから直接計算できる．
$s = 1, \ldots, S$ のサンプルを使って

$$P(\theta_1 < \theta_2 \mid \boldsymbol{Y}) \approx \frac{1}{S} \sum_{s=1}^{S} \mathbf{1}\left[\theta_1^{(s)} < \theta_2^{(s)}\right].$$

6　7.5 欠損データと代入法（Missing Data and Imputation）

6.1　欠損データの問題設定

現実のデータでは，観測されなかった値（**欠損値**）が含まれる．観測できた部分を $\boldsymbol{y}_{\text{obs}}$，欠損部分を $\boldsymbol{y}_{\text{miss}}$ とする．

ベイズ的アプローチでは，$\boldsymbol{y}_{\text{miss}}$ を**未知パラメータ**と同様に扱い，$(\boldsymbol{\theta}, \Sigma, \boldsymbol{y}_{\text{miss}})$ の同時事後分布を考える．

6.2　MVN の条件付き分布

多変量正規分布の条件付き分布

$\boldsymbol{Y} \sim \mathrm{MVN}(\boldsymbol{\theta}, \Sigma)$ を観測部分と欠損部分に分割する：

$$\boldsymbol{Y} = \begin{pmatrix} \boldsymbol{Y}_1 \\ \boldsymbol{Y}_2 \end{pmatrix}, \quad \boldsymbol{\theta} = \begin{pmatrix} \boldsymbol{\theta}_1 \\ \boldsymbol{\theta}_2 \end{pmatrix}, \quad \Sigma = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix}.$$

$\boldsymbol{Y}_2$ を観測した条件での $\boldsymbol{Y}_1$ の条件付き分布は

$$\boldsymbol{Y}_1 \mid \boldsymbol{Y}_2 = \boldsymbol{y}_2 \;\sim\; \mathrm{MVN}\big(\boldsymbol{\theta}_1 + \Sigma_{12}\Sigma_{22}^{-1}(\boldsymbol{y}_2 - \boldsymbol{\theta}_2),\;\; \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}\big).$$

計算補足：条件付き分布の導出（概略）

$\boldsymbol{Y}_1$ と $\boldsymbol{Y}_2$ の同時密度から，$\boldsymbol{Y}_2 = \boldsymbol{y}_2$ を固定して $\boldsymbol{Y}_1$ についての条件付き密度を求める．

補助変数 $\boldsymbol{Z} = \boldsymbol{Y}_1 - \Sigma_{12}\Sigma_{22}^{-1}\boldsymbol{Y}_2$ を考えると，$\boldsymbol{Z}$ と $\boldsymbol{Y}_2$ が独立で $\boldsymbol{Z} \sim \mathrm{MVN}(\boldsymbol{\theta}_1 - \Sigma_{12}\Sigma_{22}^{-1}\boldsymbol{\theta}_2,\ \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21})$ であることが示せる．

したがって $\boldsymbol{Y}_2 = \boldsymbol{y}_2$ で条件付けると $\boldsymbol{Z}$ の分布はそのままで，

$$\boldsymbol{Y}_1 = \boldsymbol{Z} + \Sigma_{12}\Sigma_{22}^{-1}\boldsymbol{y}_2$$

より上の結論が得られる．

6.3　欠損値のギブスサンプリング

欠損値のサンプリングをギブスサンプラーに組み込む：

欠損値を含むギブスサンプラー

各イテレーションで以下を繰り返す：

1. **欠損値のサンプリング：**各 i について欠損成分 $\boldsymbol{y}_{i,\mathrm{miss}}$ を条件付き分布

   $$\boldsymbol{y}_{i,\mathrm{miss}} \mid \boldsymbol{y}_{i,\mathrm{obs}},\, \boldsymbol{\theta},\, \Sigma \;\sim\; \mathrm{MVN}(\cdots)$$

   からサンプリングする（上の条件付き MVN 公式を使う）．
2. **$\boldsymbol{\theta}$ のサンプリング：**完全なデータ $\boldsymbol{Y}$ で $\boldsymbol{\theta} \mid \boldsymbol{Y}, \Sigma$ からサンプリング．
3. **Σ のサンプリング：**$\Sigma \mid \boldsymbol{Y}, \boldsymbol{\theta}$ からサンプリング．

ポイント

欠損値のサンプリングは「データ拡大（data augmentation）」と呼ばれる一般的な技法である．欠損値が「観測されなかっただけのパラメータ」として扱われ，事後分布から直接引き出せるため，推論の不確実性を正しく伝播できる．

例：Pima インディアン女性の健康データ

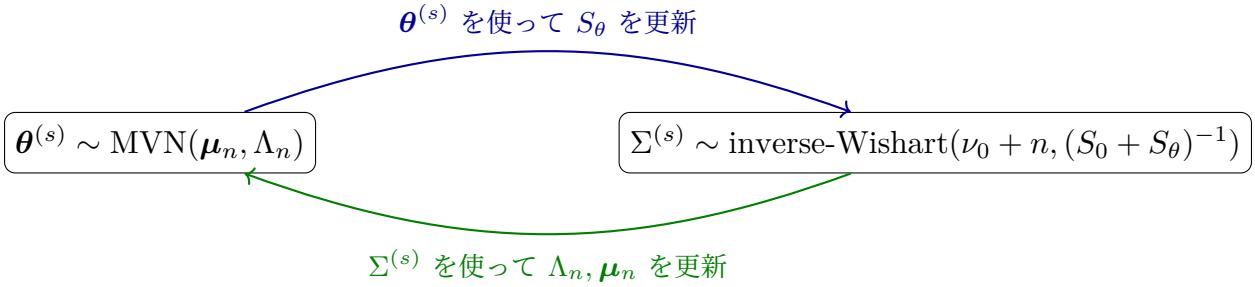
Pima インディアン女性 200 名のデータで，BMI（Y_1）・血糖値（Y_2）・糖尿病遺伝因子（Y_3）など複数の健康指標が記録されているが，いくつかの観測値が欠損している．

上記のギブスサンプラーを使うと，欠損値を適切に補完しながら $(\boldsymbol{\theta}, \Sigma)$ を推論できる．特に「欠損値は MAR（Missing At Random）」という仮定のもとで，欠損値の不確実性を込みにした事後分布が得られる（単純な補完よりも推論が正確になる）．

7　まとめ

第 7 章のまとめ

1. **多変量正規分布**：$\boldsymbol{Y} \sim \mathrm{MVN}(\boldsymbol{\theta}, \Sigma)$．密度は $(2\pi)^{-p/2}|\Sigma|^{-1/2}\exp\{-\frac{1}{2}(\boldsymbol{y}-\boldsymbol{\theta})^\top\Sigma^{-1}(\boldsymbol{y}-\boldsymbol{\theta})\}$．
2. **$\boldsymbol{\theta}$ の事後分布**（Σ 既知）：$\boldsymbol{\theta} \mid \boldsymbol{Y}, \Sigma \sim \mathrm{MVN}(\boldsymbol{\mu}_n, \Lambda_n)$．精度行列が加算 $\Lambda_n^{-1} = \Lambda_0^{-1} + n\Sigma^{-1}$，事後平均は重み付き平均 $\boldsymbol{\mu}_n = \Lambda_n(\Lambda_0^{-1}\boldsymbol{\mu}_0 + n\Sigma^{-1}\bar{\boldsymbol{y}})$．
3. **Σ の事後分布**（$\boldsymbol{\theta}$ 既知）：$\Sigma \mid \boldsymbol{Y}, \boldsymbol{\theta} \sim \text{inverse-Wishart}(\nu_0 + n, (S_0 + S_\theta)^{-1})$．自由度に n，スケール行列に $S_\theta = \sum(\boldsymbol{y}_i - \boldsymbol{\theta})(\boldsymbol{y}_i - \boldsymbol{\theta})^\top$ を加えるだけ．
4. **ギブスサンプラー**：$\boldsymbol{\theta}$ と Σ を交互にサンプリング．MCMC として同時事後分布 $p(\boldsymbol{\theta}, \Sigma \mid \boldsymbol{Y})$ に収束する．
5. **欠損値の処理**：MVN の条件付き分布を使い，欠損値をギブスサンプラーに組み込む（データ拡大）．


$\boldsymbol{\theta}^{(s)}$ を使って S_θ を更新
$\boldsymbol{\theta}^{(s)} \sim \mathrm{MVN}(\boldsymbol{\mu}_n, \Lambda_n)$
$\Sigma^{(s)} \sim \text{inverse-Wishart}(\nu_0 + n, (S_0 + S_\theta)^{-1})$
$\Sigma^{(s)}$ を使って $\Lambda_n, \boldsymbol{\mu}_n$ を更新