Hoff 第 8 章

# Group Comparisons and Hierarchical Modeling

（グループ比較と階層モデル）ゼミ資料

## 1　この章のモチベーション

この章のテーマは**複数のグループの平均の比較**である．

- **2 グループ**（8.1 節）：2 つの平均を「平均」と「差」で表し直す．
- **多グループ**（8.2–8.4 節）：グループ平均たちの「全体の平均」と「バラつき」も正規分布でモデル化する．グループ内のバラつきのモデルと合わせて**階層正規モデル**になる．
- **分散も階層化**（8.5 節）：グループごとに分散も違ってよいように拡張する．

**ポイント**

章全体を通じたキーワードは**「グループ間で情報を共有する」**こと．「全グループを完全に別物として扱う」と「全グループを同一視する」の両極端の間で，データに応じて連続的に情報を借りる．その結果として**縮小推定**（shrinkage）が起こる．

# 2　2 つのグループの比較（8.1 節）

## 2.1　古典的なやり方：$t$ 検定と $p$ 値

**例：2 校の数学の点数**

米国の都市部の公立高校 2 校から，10 年生をそれぞれ $n_1 = 31$ 人，$n_2 = 28$ 人無作為に選んでテストした．標本平均は $\bar{y}_1 = 50.81$，$\bar{y}_2 = 46.15$ で，差は 4.66.

この差が標本のばらつきに比べて大きいかを見るため，$t$ 統計量を計算すると

$$t = \frac{\bar{y}_1 - \bar{y}_2}{s_p\sqrt{1/n_1 + 1/n_2}} = 1.74, \qquad s_p^2 = \frac{(n_1-1)s_1^2 + (n_2-1)s_2^2}{n_1 + n_2 - 2}.$$

2 校が同じ正規分布なら $t$ は自由度 57 の $t$ 分布に従い，両側 $p$ 値は $p = 0.087$.

**注意**

$p$ 値は「$\theta_1 = \theta_2$ である確率」**ではない**．「2 校が同じ分布だと仮定したとき，実験前に $|t| \geq 1.74$ となるデータを引く確率」である．

### $p$ 値によるモデル選択の問題点

よく教えられる手順は次のとおり：

- $p < 0.05$ なら「2 校は別物」として $\hat{\theta}_1 = \bar{y}_1$，$\hat{\theta}_2 = \bar{y}_2$.
- $p > 0.05$ なら「2 校は同じ」として $\hat{\theta}_1 = \hat{\theta}_2 =$ 全員の平均.

これは $\hat{\theta}_1 = w\bar{y}_1 + (1-w)\bar{y}_2$ と書いたとき，

$$w = 1 \ \ (p < 0.05), \qquad w = \frac{n_1}{n_1 + n_2} \ \ (p > 0.05)$$

と **0 か 1 かの極端な切り替え**をしていることになる．

- 今回は $p = 0.087$ なので「同じ」扱いになるが，差がありそうな証拠もある．
- 逆に，標本にたまたま数人の成績上位者が混ざれば $p = 0.04$ になり，今度は 2 校を完全に別々に推定する．他校のデータを全く使わないのは非効率．

**ポイント**

本当は $w$ を**連続的に**動かし，サンプルサイズ $n_1, n_2$，ばらつき $\sigma^2$，2 校が似ているという事前情報などに応じて決めたい．グループ間で情報を共有するベイズ解析は，まさにそういう推定量を与える．

## 2.2 ベイズモデル：平均と差でパラメータ化する

**2 グループのモデル**

$$
\begin{aligned}
Y_{i,1} &= \mu + \delta + \epsilon_{i,1}, \\
Y_{i,2} &= \mu - \delta + \epsilon_{i,2}, \qquad \{\epsilon_{i,j}\} \overset{\text{i.i.d.}}{\sim} \text{Normal}(0, \sigma^2).
\end{aligned}
$$

$\theta_1 = \mu + \delta$, $\theta_2 = \mu - \delta$ なので

$$
\mu = \frac{\theta_1 + \theta_2}{2} \ (\text{2 校の平均}), \qquad \delta = \frac{\theta_1 - \theta_2}{2} \ (\text{差の半分}).
$$

**事前分布**（独立）：$\mu \sim \text{Normal}(\mu_0, \gamma_0^2)$, $\delta \sim \text{Normal}(\delta_0, \tau_0^2)$, $\sigma^2 \sim \text{inverse-gamma}(\nu_0/2,\ \nu_0\sigma_0^2/2)$.

**完全条件付き分布**

**$\mu, \delta, \sigma^2$ の完全条件付き分布**

$$
\begin{aligned}
\{\mu \mid \boldsymbol{y}_1, \boldsymbol{y}_2, \delta, \sigma^2\} &\sim \text{Normal}(\mu_n, \gamma_n^2), \\
\gamma_n^2 &= \left[1/\gamma_0^2 + (n_1+n_2)/\sigma^2\right]^{-1}, \\
\mu_n &= \gamma_n^2\left[\mu_0/\gamma_0^2 + \textstyle\sum_i (y_{i,1} - \delta)/\sigma^2 + \sum_i (y_{i,2} + \delta)/\sigma^2\right], \\
\{\delta \mid \boldsymbol{y}_1, \boldsymbol{y}_2, \mu, \sigma^2\} &\sim \text{Normal}(\delta_n, \tau_n^2), \\
\tau_n^2 &= \left[1/\tau_0^2 + (n_1+n_2)/\sigma^2\right]^{-1}, \\
\delta_n &= \tau_n^2\left[\delta_0/\tau_0^2 + \textstyle\sum_i (y_{i,1} - \mu)/\sigma^2 - \sum_i (y_{i,2} - \mu)/\sigma^2\right], \\
\{\sigma^2 \mid \boldsymbol{y}_1, \boldsymbol{y}_2, \mu, \delta\} &\sim \text{inverse-gamma}(\nu_n/2,\ \nu_n\sigma_n^2/2), \\
\nu_n &= \nu_0 + n_1 + n_2, \\
\nu_n\sigma_n^2 &= \nu_0\sigma_0^2 + \textstyle\sum_i (y_{i,1} - [\mu+\delta])^2 + \sum_i (y_{i,2} - [\mu-\delta])^2.
\end{aligned}
$$

**導出**

教科書では演習問題になっている．$\delta$ について確かめる．$\delta$ を含む因子だけを集めると

$$p(\delta \mid \cdots) \propto \exp\left\{-\frac{(\delta-\delta_0)^2}{2\tau_0^2}\right\} \prod_i \exp\left\{-\frac{(y_{i,1}-\mu-\delta)^2}{2\sigma^2}\right\} \prod_i \exp\left\{-\frac{(y_{i,2}-\mu+\delta)^2}{2\sigma^2}\right\}.$$

$z_{i,1} = y_{i,1} - \mu$，$z_{i,2} = -(y_{i,2} - \mu)$ とおくと，どちらも「$\delta$ を平均とし分散 $\sigma^2$ の正規分布からの観測」と同じ形になる（$(y_{i,2} - \mu + \delta)^2 = (z_{i,2} - \delta)^2$）．すると $n_1 + n_2$ 個の観測 $z$ と正規事前分布の組み合わせなので，5.2 節（分散既知の正規モデル）の結果がそのまま使えて，精度 $1/\tau_n^2 = 1/\tau_0^2 + (n_1 + n_2)/\sigma^2$，平均 $\delta_n = \tau_n^2[\delta_0/\tau_0^2 + \sum z_{i,1}/\sigma^2 + \sum z_{i,2}/\sigma^2]$ を得る．$\mu$ も同様（$y_{i,1} - \delta$ と $y_{i,2} + \delta$ を「$\mu$ を平均とする観測」とみる）．

**ポイント**

**極端な値を入れて納得する：**

- $\nu_0 = 0$ なら $\sigma_n^2 = \dfrac{\sum(y_{i,1} - [\mu + \delta])^2 + \sum(y_{i,2} - [\mu - \delta])^2}{n_1 + n_2}$ ——$\mu, \delta$ が既知のときのプールした分散推定量．
- $\mu_0 = \delta_0 = 0$，$\gamma_0^2 = \tau_0^2 = \infty$ なら $\mu_n = \dfrac{\sum(y_{i,1} - \delta) + \sum(y_{i,2} + \delta)}{n_1 + n_2}$，$\delta_n = \dfrac{\sum(y_{i,1} - \mu) - \sum(y_{i,2} - \mu)}{n_1 + n_2}$ で，$\mu_n, \delta_n$ を代入し合うと $\bar{y}_1 = \mu_n + \delta_n$，$\bar{y}_2 = \mu_n - \delta_n$．

## 2.3　数学の点数データの解析

### 事前分布の設定

テストは全国平均 50，標準偏差 10 になるよう標準化されている．

| パラメータ | 設定 | 理由 |
|---|---|---|
| $\mu_0, \gamma_0^2$ | $50,\ 25^2 = 625$ | 全国平均．やや拡散的に |
| $\sigma_0^2, \nu_0$ | $10^2 = 100,\ 1$ | 全国の分散（学校内の分散としては過大）．弱く |
| $\delta_0$ | $0$ | $\theta_1 > \theta_2$ と $\theta_2 > \theta_1$ を同程度に信じる |
| $\tau_0^2$ | $25^2 = 625$ | 点数は 0〜100 なので $\lvert\delta\rvert < 50$．十分拡散的 |

**結果**

Gibbs サンプラーを 5,000 回まわすと：

- $\mu, \delta$ の事後分布は事前分布よりずっと集中する（教科書 Figure 8.2）.
- 2 校の平均点の差 $2\delta$ の事後 95% 区間は $(-0.61, 9.98)$．0 を含むが,
- $\Pr(\theta_1 > \theta_2 \mid \boldsymbol{y}_1, \boldsymbol{y}_2) = \Pr(\delta > 0 \mid \boldsymbol{y}_1, \boldsymbol{y}_2) \approx 0.96$（事前確率は 0.50）．学校 1 の母平均の方が高いという**かなりの証拠**がある.

**注意**

$\Pr(\theta_1 > \theta_2 \mid \boldsymbol{y}) \approx 0.96$ を「学校 1 から無作為に選んだ生徒が学校 2 の生徒より高得点である確率」と混同しないこと．後者は**事後予測分布**から求める量で, $\Pr(\tilde{Y}_1 > \tilde{Y}_2 \mid \boldsymbol{y}_1, \boldsymbol{y}_2) \approx 0.62$ にすぎない.「平均の比較」と「個人の比較」は別物である（11 章の $\theta_2$ と $\tilde{\beta}_2$ の区別と同じ構造）.

# 3　多グループの比較：交換可能性と階層モデル（8.2 節）

## 3.1　階層データ（多段階データ）

8.1 節のデータは，2002 年の教育縦断調査（ELS）の一部である．ELS には**学校の集団**と，**各学校の中の生徒の集団**がある．このように集団が入れ子になったデータを**階層データ・多段階データ**（multilevel）と呼ぶ.

- 複数の病院の中の患者
- 動物の集団の中の遺伝子
- 国の中の地域の中の郡の中の人

最も単純な 2 段階の場合，グループ $j$ の $i$ 番目のデータを $y_{i,j}$ と書く.

## 3.2 交換可能性から階層モデルを導く

**交換可能性（第 2 章の復習）**

$p(y_1, \ldots, y_n) = p(y_{\pi_1}, \ldots, y_{\pi_n})$ が任意の並べ替え $\pi$ について成り立つとき，$Y_1, \ldots, Y_n$ は**交換可能**という．すべての $n$ で交換可能なら，**de Finetti の定理**により

$$\phi \sim p(\phi), \qquad \{Y_1, \ldots, Y_n \mid \phi\} \overset{\text{i.i.d.}}{\sim} p(y \mid \phi)$$

と表せる（固定だが未知の母集団の特徴 $\phi$ を条件とした i.i.d. 標本）．

この定理を **2 回**使う：

1. **グループ内**：同じ学校の生徒の点数は，互いに独立とは扱いたくない（他の生徒の点数から，その学校の水準について情報が得られるはず）．しかし「学校 $j$ からの無作為標本」以上の情報がなければ**交換可能**とみなせる．$\Rightarrow \{Y_{1,j}, \ldots, Y_{n_j,j} \mid \phi_j\} \overset{\text{i.i.d.}}{\sim} p(y \mid \phi_j)$.
2. **グループ間**：学校ごとのパラメータ $\phi_1, \ldots, \phi_m$ も独立とは扱いたくない（他校の値から $\phi_m$ について情報が得られるはず）．しかし学校自体がより大きな学校の集団からの標本なら，**交換可能**とみなせる．$\Rightarrow \{\phi_1, \ldots, \phi_m \mid \psi\} \overset{\text{i.i.d.}}{\sim} p(\phi \mid \psi)$.

**階層モデルの 3 つの分布**

$$\begin{aligned}
\{y_{1,j}, \ldots, y_{n_j,j} \mid \phi_j\} &\overset{\text{i.i.d.}}{\sim} p(y \mid \phi_j) && \text{（グループ内の標本変動）} \\
\{\phi_1, \ldots, \phi_m \mid \psi\} &\overset{\text{i.i.d.}}{\sim} p(\phi \mid \psi) && \text{（グループ間の標本変動）} \\
\psi &\sim p(\psi) && \text{（事前分布）}
\end{aligned}$$

**注意**

$p(y \mid \phi)$ と $p(\phi \mid \psi)$ はどちらも**対象の集団の中でのばらつき**を表す**標本抽出分布**である（前者は生徒間，後者は学校間）．一方 $p(\psi)$ は**固定された未知量についての情報**を表す**事前分布**．データから推定されるのは $p(y \mid \phi)$ と $p(\phi \mid \psi)$ のほうで，$p(\psi)$ はデータから推定しない．$p(\phi \mid \psi)$ を「事前分布」と呼ぶ文献も多いが，概念的には区別すべきである．

# 4　階層正規モデル（8.3 節）

**階層正規モデル**

$$\phi_j = \{\theta_j, \sigma^2\}, \quad p(y \mid \phi_j) = \text{Normal}(\theta_j, \sigma^2) \qquad \text{（グループ内モデル）} \qquad (8.1)$$
$$\psi = \{\mu, \tau^2\}, \quad p(\theta_j \mid \psi) = \text{Normal}(\mu, \tau^2) \qquad \text{（グループ間モデル）} \qquad (8.2)$$

**事前分布**（半共役）：

$$1/\sigma^2 \sim \text{gamma}(\nu_0/2,\ \nu_0\sigma_0^2/2),$$
$$1/\tau^2 \sim \text{gamma}(\eta_0/2,\ \eta_0\tau_0^2/2),$$
$$\mu \sim \text{Normal}(\mu_0, \gamma_0^2).$$

グループ内の分散 $\sigma^2$ は**全グループ共通**と仮定している（8.5 節で外す）．

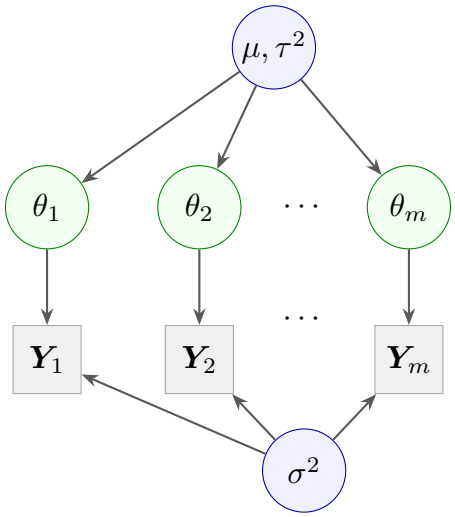



図 1：階層正規モデルのグラフ表現（教科書 Figure 8.3）．青：全体のパラメータ，緑：グループ固有のパラメータ，灰：観測データ．

## 4.1　事後分布の分解

同時事後分布は次のように分解できる：

$$p(\theta_1,\dots,\theta_m,\mu,\tau^2,\sigma^2 \mid \boldsymbol{y}_1,\dots,\boldsymbol{y}_m) \propto p(\mu)\,p(\tau^2)\,p(\sigma^2) \;\times\; \Big\{\prod_{j=1}^{m} p(\theta_j \mid \mu,\tau^2)\Big\} \times \Big\{\prod_{j=1}^{m}\prod_{i=1}^{n_j} p(y_{i,j} \mid \theta_j,\sigma^2)\Big\}. \tag{8.3}$$

最後の括弧は**条件付き独立性**による：$\theta_j,\sigma^2$ が与えられれば $Y_{1,j},\dots,Y_{n_j,j}$ は独立で，$\mu,\tau^2$ には依存しない．図 1 で $(\mu,\tau^2)$ から $\boldsymbol{Y}_j$ への経路は必ず $\theta_j$ を通る——$(\mu,\tau^2)$ は $\boldsymbol{Y}_j$ に $\theta_j$ **を通じて間接的にしか**影響しない．

**ポイント**

完全条件付き分布は，(8.3) から**そのパラメータを含む因子だけを拾えば**求まる．そして拾った因子は，どれも第 5・6 章の「1 標本の正規モデル」と全く同じ形をしている．新しい計算はほとんど要らず，**記号の読み替え**だけで済む．

## 4.2　完全条件付き分布（8.3.1 節）

| パラメータ | (8.3) から拾う因子 | 第 6 章での対応 | 分布 |
|---|---|---|---|
| $\mu$ | $p(\mu)\prod_j p(\theta_j \mid \mu,\tau^2)$ | $\theta_j$ をデータ，$\mu$ を母平均とみる | 正規 |
| $\tau^2$ | $p(\tau^2)\prod_j p(\theta_j \mid \mu,\tau^2)$ | $\theta_j$ をデータ，$\tau^2$ を母分散とみる | 逆ガンマ |
| $\theta_j$ | $p(\theta_j \mid \mu,\tau^2)\prod_i p(y_{i,j} \mid \theta_j,\sigma^2)$ | $p(\theta_j \mid \mu,\tau^2)$ を事前分布とみる | 正規 |
| $\sigma^2$ | $p(\sigma^2)\prod_j\prod_i p(y_{i,j} \mid \theta_j,\sigma^2)$ | $m$ グループ分の残差を使う | 逆ガンマ |

**$\mu$ と $\tau^2$ の完全条件付き分布**

$$\{\mu \mid \theta_1,\dots,\theta_m,\tau^2\} \sim \text{Normal}\left(\frac{m\bar{\theta}/\tau^2+\mu_0/\gamma_0^2}{m/\tau^2+1/\gamma_0^2},\ \left[m/\tau^2+1/\gamma_0^2\right]^{-1}\right),$$

$$\{1/\tau^2 \mid \theta_1,\dots,\theta_m,\mu\} \sim \text{gamma}\left(\frac{\eta_0+m}{2},\ \frac{\eta_0\tau_0^2+\sum_j(\theta_j-\mu)^2}{2}\right).$$

$\theta_1, \ldots, \theta_m$ が「正規母集団からの i.i.d. 標本」，$\mu, \tau^2$ が「その母平均・母分散」という第 6 章と全く同じ状況なので，結果も記号を読み替えただけである．

**$\theta_j$ の完全条件付き分布**

$$\{\theta_j \mid y_{1,j}, \ldots, y_{n_j,j}, \mu, \tau^2, \sigma^2\} \sim \text{Normal}\left( \frac{n_j \bar{y}_j / \sigma^2 + \mu/\tau^2}{n_j/\sigma^2 + 1/\tau^2},\ \left[n_j/\sigma^2 + 1/\tau^2\right]^{-1} \right).$$

$\mu, \tau^2, \sigma^2, \boldsymbol{y}_j$ を条件にすると，$\theta_j$ は他の $\theta_k$ や他グループのデータと**独立**．図 1 で $\theta_j$ から $\theta_k$ への経路は必ず $(\mu, \tau^2)$ か $\sigma^2$ を通るためである．数学的には，$p(\theta_j \mid \mu, \tau^2)$ を「事前分布」とみた 1 標本の正規モデル（5.2 節）と同じ．

**$\sigma^2$ の完全条件付き分布**

$$\{1/\sigma^2 \mid \boldsymbol{\theta}, \boldsymbol{y}_1, \ldots, \boldsymbol{y}_m\} \sim \text{gamma}\left( \frac{\nu_0 + \sum_j n_j}{2},\ \frac{\nu_0 \sigma_0^2 + \text{SSR}}{2} \right),$$

ただし $\text{SSR} = \sum_{j=1}^{m} \sum_{i=1}^{n_j} (y_{i,j} - \theta_j)^2$.

$\sum\sum (y_{i,j} - \theta_j)^2$ は全グループの残差平方和なので，この分布は**プールした分散推定値**のまわりに集中する．

# 5　例：米国の公立高校の数学の点数（8.4 節）

## 5.1　データの特徴

ELS の 100 校（いずれも 10 年生が 400 人以上の都市部の大規模公立高校）のデータ．学校ごとの標本平均は最低 36.6，最高 65.0 と幅が大きい．

**例：極端な平均はサンプルの少ない学校から出る**

標本平均とサンプルサイズの関係を見ると（教科書 Figure 8.5），**極端な標本平均の学校はサンプルサイズが小さい**傾向がある（平均が最高の学校はサンプルサイズが最小）．

**理由：**仮に全校の真の平均が同じ $\theta_0$ でも，

$$E[\bar{Y}_j \mid \theta_0, \sigma^2] = \theta_0, \qquad \text{Var}[\bar{Y}_j \mid \sigma^2] = \sigma^2/n_j$$

なので，$n_j$ が小さい学校ほど $\bar{y}_j$ が $\theta_0$ から上にも下にも大きく外れやすい．階層データではよくある現象である．

## 5.2　事前分布と Gibbs サンプラー（8.4.1 節）

| パラメータ | 設定 | 理由 |
|---|---|---|
| $\sigma_0^2, \nu_0$ | 100, 1 | 全国の分散 100 は学校内＋学校間なので，学校内は高々 100 |
| $\tau_0^2, \eta_0$ | 100, 1 | 学校間の分散も 100 を超えないはず |
| $\mu_0, \gamma_0^2$ | 50, 25 | $\mu \in (40, 60)$ の事前確率が約 95% |

**Gibbs サンプラー（階層正規モデル）**

現在値 $\{\theta_1^{(s)}, \ldots, \theta_m^{(s)}, \mu^{(s)}, \tau^{2(s)}, \sigma^{2(s)}\}$ から：

1. $\mu^{(s+1)} \sim p(\mu \mid \theta_1^{(s)}, \ldots, \theta_m^{(s)}, \tau^{2(s)})$
2. $\tau^{2(s+1)} \sim p(\tau^2 \mid \theta_1^{(s)}, \ldots, \theta_m^{(s)}, \mu^{(s+1)})$
3. $\sigma^{2(s+1)} \sim p(\sigma^2 \mid \theta_1^{(s)}, \ldots, \theta_m^{(s)}, \boldsymbol{y}_1, \ldots, \boldsymbol{y}_m)$
4. 各 $j$ について $\theta_j^{(s+1)} \sim p(\theta_j \mid \mu^{(s+1)}, \tau^{2(s+1)}, \sigma^{2(s+1)}, \boldsymbol{y}_j)$

更新の**順番はどうでもよい**．大事なのは，各パラメータを他のパラメータの**最新の値**で条件付けて更新すること．

### MCMC の診断

- **定常性**：サンプル列を 10 等分して箱ひげ図を並べる（教科書 Figure 8.6）．定常なら各区間の分布は同じはず．中央値や四分位範囲が一方向に動いていれば，もっと長く回す必要がある．今回は問題なし．
- **混ざり具合**：

| | $\mu$ | $\sigma^2$ | $\tau^2$ |
|---|---|---|---|
| lag-1 自己相関 | 0.15 | 0.053 | 0.312 |
| 有効サンプルサイズ | 3706 | 4499 | 2503 |
| モンテカルロ標準誤差 | 0.009 | 0.04 | 0.09 |
| 事後平均 | 48.12 | 84.85 | 24.84 |

モンテカルロ標準誤差（事後標準偏差 $/\sqrt{\text{有効サンプルサイズ}}$）は事後平均の大きさに比べて十分小さい．$\theta_j$ たちの有効サンプルサイズは 3,627〜5,927，モンテカルロ標準誤差は 0.02〜0.05.

## 5.3　事後要約と縮小推定（8.4.2 節）

$\mu, \sigma, \tau$ の事後平均は 48.12，9.21，4.97．したがって

- 学校**内**の点数の約 95% は互いに $4 \times 9.21 \approx 37$ 点以内,
- 学校**平均**の約 95% は互いに $4 \times 4.97 \approx 20$ 点以内.

**縮小（shrinkage）**

$\mu, \tau^2, \sigma^2$ とデータを条件とした $\theta_j$ の期待値は，$\bar{y}_j$ と $\mu$ の加重平均：

$$E[\theta_j \mid \boldsymbol{y}_j, \mu, \tau, \sigma] = \frac{\bar{y}_j\, n_j/\sigma^2 + \mu/\tau^2}{n_j/\sigma^2 + 1/\tau^2} = w_j\, \bar{y}_j + (1 - w_j)\, \mu, \qquad w_j = \frac{n_j}{n_j + \sigma^2/\tau^2}.$$

$\theta_j$ の推定値が $\bar{y}_j$ から $\mu$ の方へ $n_j$ に応じた分だけ引き寄せられる．これを**縮小**と呼ぶ.

事後平均 $\sigma^2 \approx 84.85$，$\tau^2 \approx 24.84$ を代入すると $\sigma^2/\tau^2 \approx 3.42$ で，$\bar{y}_j$ にかかる重み $w_j$ はサンプルサイズとともに次のように変わる（パラメータの不確かさを無視した近似）：

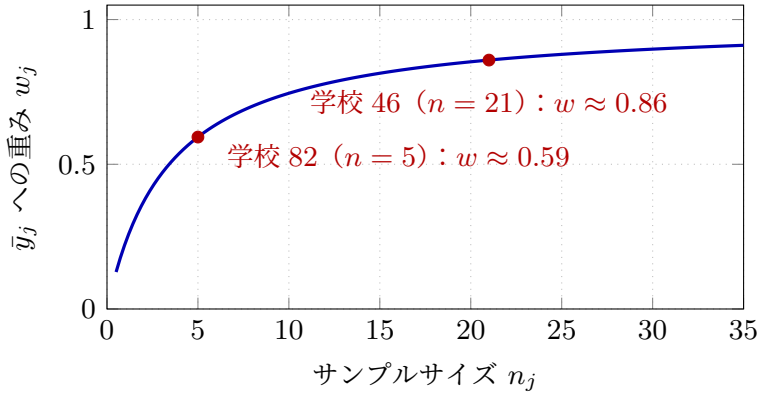



図 2：$w_j = n_j/(n_j + \sigma^2/\tau^2)$，$\sigma^2/\tau^2 = 84.85/24.84 \approx 3.42$.

- $\bar{y}_j$ と $\hat{\theta}_j = E[\theta_j \mid \boldsymbol{y}_1, \ldots, \boldsymbol{y}_m]$ の関係は，**傾きが 1 より小さい直線**にほぼ乗る（高い $\bar{y}_j$ は少し低く，低い $\bar{y}_j$ は少し高く推定される）．
- **サンプルの少ない学校ほど強く縮小**され，多い学校はほとんど縮小されない（教科書 Figure 8.8）．自分のデータが多ければ，他校から「借りる」情報は少なくて済む．

## 5.4　順位の逆転：学校 46 と学校 82

**例：どちらの学校が低いか**

どちらも標本平均が下位 10% の学校である．

| | サンプルサイズ | 標本平均 $\bar{y}_j$ | 事後平均 $E[\theta_j \mid \boldsymbol{y}]$ |
|---|---|---|---|
| 学校 46 | 21 | 40.18 | 41.31 |
| 学校 82 | 5 | 38.76 | 42.53 |

標本平均では学校 82 の方が低いのに，**事後平均では学校 82 の方が高い**．順位が逆転している．

**図 2 の重みで確かめる：**$E[\mu \mid \boldsymbol{y}] \approx 48.11$ として

$$\text{学校 82}：0.594 \times 38.76 + 0.406 \times 48.11 \approx 42.6,$$
$$\text{学校 46}：0.860 \times 40.18 + 0.140 \times 48.11 \approx 41.3,$$

と教科書の事後平均をほぼ再現できる．サンプルの少ない学校 82 の方が，全体平均へ大きく引き寄せられている．

**なぜこれが妥当か：**

- 学校 82 で最低点の生徒が欠席していたら，$\bar{y}_{82}$ は 38.76 → 41.99 と 3 点以上変わる．
- 学校 46 で同じことが起きても，$\bar{y}_{46}$ は 40.18 → 40.9 と 0.75 点程度しか変わらない．
- つまり学校 82 の低い平均は「本当に $\theta_{82}$ が低い」とも「たまたま 5 人のうち数人が成績下位だった」とも説明できるが，学校 46 ではサンプルが多いので後者では説明しにくい．

**ポイント**

「学校 46 の生徒の方が平均点は高かったのに，順位が下なのは不公平」と感じるかもしれない．しかし階層モデルは「$\theta_{46}$ が極端に低いという**証拠の量**の方が，$\theta_{82}$ についての証拠より多い」という客観的事実を反映している．

**バスケットボールの例：**フリースローを 3 本中 3 本決めた控え選手（成功率 100%）と，成功率 87% のベテランがいれば，コーチは必ずベテランを選ぶ．控え選手の真の成功率が 100% 近いとは考えにくいからである．

# 6　平均と分散の両方の階層モデル（8.5 節）

## 6.1　グループごとの分散を許す

平均がグループごとに違うなら，分散も違ってよいはず．グループ $j$ の分散を $\sigma_j^2$ として $Y_{1,j},\ldots,Y_{n_j,j} \overset{\text{i.i.d.}}{\sim} \text{Normal}(\theta_j,\sigma_j^2)$ とすると，$\theta_j$ の完全条件付き分布は $\sigma^2$ を $\sigma_j^2$ に置き換えるだけ：

$$\{\theta_j \mid \boldsymbol{y}_j,\sigma_j^2,\mu,\tau^2\} \sim \text{Normal}\left(\frac{n_j\bar{y}_j/\sigma_j^2+\mu/\tau^2}{n_j/\sigma_j^2+1/\tau^2},\ \left[n_j/\sigma_j^2+1/\tau^2\right]^{-1}\right).$$

$\sigma_j^2$ のモデルとして

$$1/\sigma_1^2,\ldots,1/\sigma_m^2 \overset{\text{i.i.d.}}{\sim} \text{gamma}(\nu_0/2,\ \nu_0\sigma_0^2/2) \tag{8.4}$$

とすれば，第 6 章と同様に

$$\{1/\sigma_j^2 \mid \boldsymbol{y}_j,\theta_j\} \sim \text{gamma}\left(\frac{\nu_0+n_j}{2},\ \frac{\nu_0\sigma_0^2+\sum_i(y_{i,j}-\theta_j)^2}{2}\right).$$

**ポイント**

$\nu_0, \sigma_0^2$ **を固定すると何がまずいか：**(8.4) はただの事前分布になり，$p(\sigma_m^2 \mid \sigma_1^2, \ldots, \sigma_{m-1}^2) = p(\sigma_m^2)$．つまり他の学校の分散から学んだことが $\sigma_m^2$ の推定に使われない．グループ $m$ のサンプルが少なく，他の $\sigma_j^2$ がある値の周りに集中していれば，その情報を使いたい．

$\Rightarrow$ $\nu_0, \sigma_0^2$ **も推定するパラメータにする**．すると (8.4) は事前分布ではなく，**分散の学校間のばらつきを表す標本抽出モデル**になる（平均における $\mu, \tau^2$ と同じ役割）．

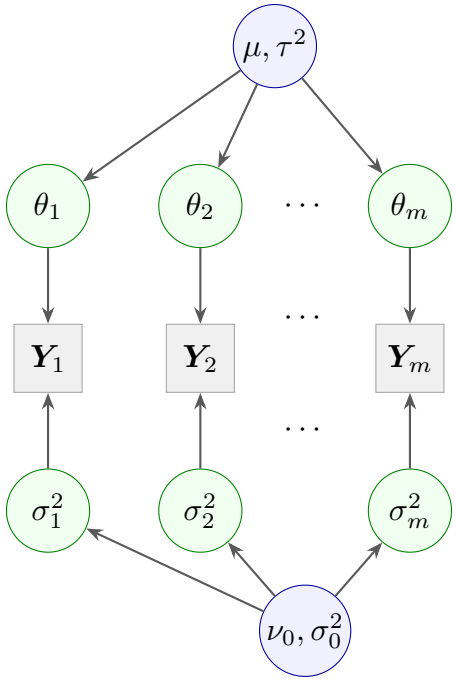



図 3：平均と分散の両方が異質な階層正規モデル（教科書 Figure 8.10）．

## 6.2 $\nu_0$ と $\sigma_0^2$ の完全条件付き分布

$\mu, \tau^2$ の完全条件付き分布は前節と変わらない．新たに必要なのは $\sigma_0^2$ と $\nu_0$．

**$\sigma_0^2$ の完全条件付き分布**

事前分布 $\sigma_0^2 \sim \text{gamma}(a, b)$ のもとで

$$\{\sigma_0^2 \mid \sigma_1^2, \ldots, \sigma_m^2, \nu_0\} \sim \text{gamma}\left(a + \frac{1}{2}m\nu_0,\ \ b + \frac{1}{2}\nu_0 \sum_{j=1}^{m} \frac{1}{\sigma_j^2}\right).$$

**導出**

(8.4) の gamma 密度を $\sigma_0^2$ の関数として見ると，各 $j$ について $\big(\nu_0\sigma_0^2/2\big)^{\nu_0/2}\exp\{-\frac{\nu_0\sigma_0^2}{2}\cdot\frac{1}{\sigma_j^2}\} \propto (\sigma_0^2)^{\nu_0/2}\exp\{-\sigma_0^2\cdot\frac{\nu_0}{2\sigma_j^2}\}$．$m$ 個かけて事前分布 $(\sigma_0^2)^{a-1}e^{-b\sigma_0^2}$ をかけると

$$(\sigma_0^2)^{a+m\nu_0/2-1}\exp\Big\{-\sigma_0^2\Big(b+\tfrac{\nu_0}{2}\textstyle\sum_j 1/\sigma_j^2\Big)\Big\},$$

これは上の gamma 分布の核である．

$a, b$ が小さいとき，条件付き平均 $\approx m/\sum_j(1/\sigma_j^2)$，つまり $\sigma_1^2,\dots,\sigma_m^2$ の**調和平均**になる．

### $\nu_0$ の完全条件付き分布

$\nu_0$ には簡単な共役事前分布がない．そこで $\nu_0$ **を正の整数に制限**し，幾何分布 $p(\nu_0)\propto e^{-\alpha\nu_0}$（$\nu_0=1,2,\dots$）を事前分布にすると

$$p(\nu_0\mid\sigma_0^2,\sigma_1^2,\dots,\sigma_m^2)\propto\left(\frac{(\nu_0\sigma_0^2/2)^{\nu_0/2}}{\Gamma(\nu_0/2)}\right)^m\left(\prod_{j=1}^m\frac{1}{\sigma_j^2}\right)^{\nu_0/2-1}\exp\Big\{-\nu_0\Big(\alpha+\frac{1}{2}\sigma_0^2\sum_j\frac{1}{\sigma_j^2}\Big)\Big\}.$$

**ポイント**

きれいな分布ではないが，$\nu_0=1,2,\dots,\nu_{\max}$ の各値でこの（正規化されていない）確率を計算し，その比率で 1 つ選べばサンプリングできる（**離散近似**，6.2 節と同じ発想）．数値的には対数で計算し，最大値を引いてから指数をとるとオーバーフローしない．

## 6.3　数学の点数データの再解析（8.5.1 節）

事前分布は前節と同じ設定に加えて $\alpha=1$，$a=1$，$b=100$．Gibbs サンプラーを 5,000 回まわす．

| $\nu_0$ の値 | 意味 |
|---|---|
| $\nu_0 = \infty$ | 全グループの分散が等しい（8.3 節のモデル） |
| $\nu_0 = 1$ | 分散はバラバラで，ほとんど情報を共有しない |
| **事後：14〜15 付近に集中** | **どちらの極端でもない，中程度の共有** |

推定された $\sigma_1^2, \ldots, \sigma_m^2$ の分布を使って，極端な標本分散がグループ間の中心に向かって縮小される．平均のときと同様，**サンプルの少ない学校ほど分散も強く縮小**される（教科書 Figure 8.12）．

## 7　議論と文献（8.6 節）

- ベイズ階層モデルの基礎は Lindley and Smith (1972)．グループ平均を全体平均へ縮小する発想は，教育テストの文脈で Kelley (1927) にさかのぼる．
- 統計学では，この種の推定の利点は **Stein 効果**（Stein, 1956, 1981）と呼ばれる．推定量は一般に $\hat{\theta}_j = w_j \bar{y}_j + (1 - w_j)\bar{y}$ の形で，$w_j$ は $n_j, \sigma^2, \tau^2$ に依存する．
- **経験ベイズ**：$\sigma^2, \tau^2$ をデータから推定して $\hat{\theta}_j$ の式に代入する方法（Efron and Morris, 1973）．ベイズとほぼ同じ推定値を与えるが，$\sigma^2, \tau^2$ **の不確かさを無視している**．

**注意**

**用語の混乱：**$y_{i,j} = \theta_j + \epsilon_{i,j}$，$\theta_j = \mu + \gamma_j$ という単純な階層モデルでも，$\theta_j$（や $\gamma_j$）は推定法によって「固定効果」とも「変量効果」とも呼ばれる．また $\theta_j$ の分布がしばしば「事前分布」と呼ばれるが，これは事前情報と母集団分布の区別をあいまいにする（Gelman and Hill, 2007）．

**分散の階層化：**あまり一般的ではないが，グループ内分散が共通だと誤って仮定すると，不適切な情報のプールや，不適切な量の縮小につながりうる．

# 8　まとめ

**第 8 章のまとめ**

1. $p$ 値によるモデル選択は「完全に別物」か「完全に同じ」かの**両極端**しか選べない．ベイズ解析ではグループ間で**連続的に**情報を共有できる．
2. 2 グループは $\theta_1 = \mu + \delta$，$\theta_2 = \mu - \delta$ とパラメータ化し，Gibbs で推定する．「平均の比較 $\Pr(\theta_1 > \theta_2)$」と「個人の比較 $\Pr(\tilde{Y}_1 > \tilde{Y}_2)$」は別物．
3. de Finetti の定理を**グループ内とグループ間の 2 回**使うと，階層モデル（グループ内の標本抽出モデル，グループ間の標本抽出モデル，事前分布）が導かれる．
4. **階層正規モデル**の完全条件付き分布は，どれも第 5・6 章の 1 標本正規モデルの**記号の読み替え**で得られる．
5. 推定値は $\bar{y}_j$ から全体平均 $\mu$ の方へ縮小される．重み $w_j = n_j/(n_j + \sigma^2/\tau^2)$ より，**サンプルの少ないグループほど強く縮小**される．その結果，標本平均と事後平均で順位が逆転することもある（学校 46 と 82）．
6. 分散もグループごとに変えて $\nu_0, \sigma_0^2$ を推定すれば，分散についても情報を共有し縮小できる．数学の点数では $\nu_0 \approx 14$〜$15$ で，「全部同じ」と「全部バラバラ」の中間．
7. この章の階層モデルは，第 11 章で「平均」を「回帰係数」に一般化した**階層回帰モデル**へ拡張される．