Hoff 第 11 章

Linear and Generalized Linear Mixed Effects Models

（線形・一般化線形混合効果モデル）ゼミ資料

1　この章のモチベーション

第 8 章では，複数のグループ（学校など）それぞれに複数の観測があるデータに対して**階層モデル**を導入した．そこでは

- グループ内：$Y_{i,j} \sim \text{Normal}(\theta_j, \sigma^2)$（グループ内のバラつき）
- グループ間：$\theta_1, \ldots, \theta_m \sim \text{Normal}(\mu, \tau^2)$（グループ平均のバラつき）

という 2 段構えで，グループごとの**平均**を推定した．

この章の問い：グループごとに違うのが「平均」だけでなく，**変数間の関係（回帰係数）**だったらどうするか？

答えは素直で，第 8 章の階層モデルの「平均」を「回帰係数ベクトル」に置き換えればよい．

	第 8 章（階層正規モデル）	第 11 章（階層回帰モデル）
グループ内	$Y_{i,j} \sim \text{Normal}(\theta_j, \sigma^2)$	$Y_{i,j} \sim \text{Normal}(\boldsymbol{\beta}_j^\top \boldsymbol{x}_{i,j}, \sigma^2)$
グループ間	$\theta_j \sim \text{Normal}(\mu, \tau^2)$	$\boldsymbol{\beta}_j \sim \text{MVN}(\boldsymbol{\theta}, \Sigma)$
グループ固有の量	平均 θ_j（スカラー）	回帰係数 $\boldsymbol{\beta}_j$（p 次元）
使う道具	5・6 章（正規，Gibbs）	7 章（多変量正規）＋ 9 章（回帰）

さらに後半では，グループ内モデルを正規回帰から**一般化線形モデル**（ポアソン回帰など）

に替えた**一般化線形混合効果モデル**を扱う．そこでは第 10 章の **Metropolis 法**と Gibbs サンプラーを組み合わせて推定する．

ポイント

第 11 章は新しい道具をほとんど導入しない．第 7 章（多変量正規・逆ウィシャート），第 8 章（階層モデル），第 9 章（ベイズ回帰），第 10 章（Metropolis–Hastings）を**組み合わせる章**である．各ステップが「どの章のどの結果か」を意識して読むと見通しがよい．

2　階層回帰モデル（11.1 節）

2.1　動機づけ：数学の点数と SES

例：米国の公立高校の数学の点数（8.4 節の続き）

100 校の 10 年生の数学の点数に加えて，各生徒の**社会経済的地位（SES）**（親の収入・学歴から算出）が記録されている．「SES が高い生徒ほど点数が高いか？　その関係は学校ごとに違うか？」を調べたい．

前処理：SES を**学校ごとに中心化**する（各学校で SES の平均が 0 になるよう引く）．すると回帰直線

$$\text{点数} \approx \beta_{1,j} + \beta_{2,j} \times \text{SES}$$

の切片 $\beta_{1,j}$ が「学校 j の平均点」，傾き $\beta_{2,j}$ が「学校 j 内での SES の効果」と解釈できる．

まず各校で最小二乗回帰をしてみると（教科書 Figure 11.1）：

- 大半の学校で傾きは正（SES が高いほど点数が高い）だが，**負の傾きの学校もある**．
- **サンプルサイズが大きい学校**の推定値は全体平均の近くに集まり，**極端な推定値**はほとんどが**サンプルサイズの小さい学校**から出ている．

ポイント

これは 8.4 節と同じ現象である：サンプルが少ないほど，たまたま偏ったデータを引いて極端な推定値が出やすい．対策も 8 章と同じで，**グループ間で情報を共有する階**

層モデルによって小さい学校の推定値を安定させる（縮小推定）.

2.2 モデルの定式化

階層正規回帰モデル

グループ内モデル（学校 j の中での点数のバラつき）：

$$Y_{i,j} = \boldsymbol{\beta}_j^\top \boldsymbol{x}_{i,j} + \epsilon_{i,j}, \qquad \{\epsilon_{i,j}\} \overset{\text{i.i.d.}}{\sim} \text{Normal}(0, \sigma^2). \tag{11.1}$$

ベクトル・行列で書けば $\boldsymbol{Y}_j \sim \text{MVN}(X_j\boldsymbol{\beta}_j,\, \sigma^2 I)$. ここで X_j は $n_j \times p$ の計画行列. $\boldsymbol{\beta}_1, \ldots, \boldsymbol{\beta}_m, \sigma^2$ が与えられれば $\boldsymbol{Y}_1, \ldots, \boldsymbol{Y}_m$ は条件付き独立.

グループ間モデル（回帰係数の学校間のバラつき）：

$$\boldsymbol{\beta}_1, \ldots, \boldsymbol{\beta}_m \overset{\text{i.i.d.}}{\sim} \text{MVN}(\boldsymbol{\theta}, \Sigma). \tag{11.2}$$

事前分布（すべて半共役）：

$$\begin{aligned}
\boldsymbol{\theta} &\sim \text{MVN}(\boldsymbol{\mu}_0, \Lambda_0), \\
\Sigma &\sim \text{inverse-Wishart}(\eta_0, S_0^{-1}), \\
\sigma^2 &\sim \text{inverse-gamma}(\nu_0/2,\, \nu_0\sigma_0^2/2).
\end{aligned}$$

数学の点数の例では $\boldsymbol{x}_{i,j} = (1, \text{SES}_{i,j})^\top$, $p = 2$ である.

グラフ表現

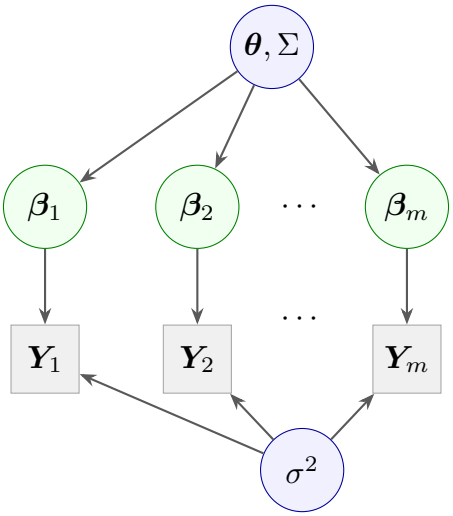


図 1：階層正規回帰モデルのグラフ表現（教科書 Figure 11.2）．青：全体のパラメータ，緑：グループ固有のパラメータ，灰：観測データ．

注意

$\boldsymbol{\beta}_j \sim \mathrm{MVN}(\boldsymbol{\theta}, \Sigma)$ は「固定された未知量 $\boldsymbol{\beta}_j$ への不確かさ」を表す**事前分布ではない**．これは「学校という集団の中で回帰係数がどうバラつくか」を表す**標本抽出モデル**である．推定すべき固定された未知パラメータは $\boldsymbol{\theta}$ と Σ のほうである．

2.3　なぜ「混合効果モデル」と呼ぶのか

グループ間モデルを $\boldsymbol{\beta}_j = \boldsymbol{\theta} + \boldsymbol{\gamma}_j$，$\boldsymbol{\gamma}_1, \ldots, \boldsymbol{\gamma}_m \overset{\text{i.i.d.}}{\sim} \mathrm{MVN}(\mathbf{0}, \Sigma)$ と書き直してグループ内モデルに代入すると

$$Y_{i,j} = \underbrace{\boldsymbol{\theta}^\top \boldsymbol{x}_{i,j}}_{\text{固定効果}} + \underbrace{\boldsymbol{\gamma}_j^\top \boldsymbol{x}_{i,j}}_{\text{変量効果}} + \epsilon_{i,j}.$$

名前	記号	意味
固定効果（fixed effect）	$\boldsymbol{\theta}$	全グループ共通の係数
変量効果（random effect）	$\boldsymbol{\gamma}_j$	グループごとにランダムに変わる係数のズレ

固定効果と変量効果を**混ぜて**含むので**線形混合効果モデル**（linear mixed effects model）と呼ばれる．

ポイント

一般には $Y_{i,j} = \boldsymbol{\theta}^\top \boldsymbol{x}_{i,j} + \boldsymbol{\gamma}_j^\top \boldsymbol{z}_{i,j} + \epsilon_{i,j}$ と，固定効果と変量効果で**別の説明変数**を使ってよい．ただし「学校の規模」のような**グループ内で一定の変数**は $\boldsymbol{z}_{i,j}$ に入れない．グループ内で値が変わらないので，グループ固有の係数を推定する情報がデータにないからである（$\boldsymbol{x}_{i,j}$ のほうには入れられる）．

補足：変量効果はグループ内の相関を生む

$\boldsymbol{\beta}_j$ を積分消去すると（$\boldsymbol{\beta}_j$ を条件にしないと），グループ j の観測ベクトルは

$$\boldsymbol{Y}_j \sim \mathrm{MVN}\big(X_j \boldsymbol{\theta},\ X_j \Sigma X_j^\top + \sigma^2 I\big)$$

に従う．非対角成分 $X_j \Sigma X_j^\top$ があるので，**同じグループの観測どうしは相関する**．「同じ学校の生徒は似ている」という構造を，変量効果が自動的に表現している．（$\boldsymbol{Y}_j = X_j\boldsymbol{\theta} + X_j\boldsymbol{\gamma}_j + \boldsymbol{\epsilon}_j$ で，$\boldsymbol{\gamma}_j$ と $\boldsymbol{\epsilon}_j$ が独立な多変量正規なので，和もそれぞれの分散を足した多変量正規になる．）

3　完全条件付き分布（11.2 節）

推定したいのは同時事後分布

$$p(\boldsymbol{\beta}_1, \ldots, \boldsymbol{\beta}_m, \boldsymbol{\theta}, \Sigma, \sigma^2 \mid X_1, \ldots, X_m, \boldsymbol{y}_1, \ldots, \boldsymbol{y}_m).$$

パラメータは多いが，半共役事前分布を使えば**すべての完全条件付き分布が標準的な分布**になり，Gibbs サンプラーで近似できる．しかも，それぞれは**以前の章で導いた結果の使い回し**である．

パラメータ	完全条件付き分布	依存するもの	元ネタ
$\boldsymbol{\beta}_j$	多変量正規	$\boldsymbol{y}_j, X_j, \sigma^2, \boldsymbol{\theta}, \Sigma$	9.2.1 節（ベイズ回帰）
$\boldsymbol{\theta}$	多変量正規	$\boldsymbol{\beta}_1, \ldots, \boldsymbol{\beta}_m, \Sigma$	第 7 章（多変量正規の平均）
Σ	逆ウィシャート	$\boldsymbol{\beta}_1, \ldots, \boldsymbol{\beta}_m, \boldsymbol{\theta}$	第 7 章（多変量正規の共分散）
σ^2	逆ガンマ	全データ，$\boldsymbol{\beta}_1, \ldots, \boldsymbol{\beta}_m$	9.2.1 節（回帰の誤差分散）

3.1　$\boldsymbol{\beta}_j$ の完全条件付き分布

$\boldsymbol{\theta}, \Sigma, \sigma^2$ を条件にすると，各 $\boldsymbol{\beta}_j$ は**互いに独立**になる（図 1 で，$\boldsymbol{\beta}_j$ どうしをつなぐ経路は $\boldsymbol{\theta}, \Sigma$ を通るものしかない）．$\boldsymbol{\beta}_j$ から見ると，これは**「事前平均 $\boldsymbol{\theta}$，事前分散 Σ」の普通の 1 グループの回帰問題**である．

$\boldsymbol{\beta}_j$ の完全条件付き分布

$\{\boldsymbol{\beta}_j \mid \boldsymbol{y}_j, X_j, \sigma^2, \boldsymbol{\theta}, \Sigma\} \sim \mathrm{MVN}(\boldsymbol{m}_j, V_j)$，ただし

$$V_j = \left(\Sigma^{-1} + X_j^\top X_j / \sigma^2\right)^{-1},$$
$$\boldsymbol{m}_j = V_j\left(\Sigma^{-1}\boldsymbol{\theta} + X_j^\top \boldsymbol{y}_j / \sigma^2\right).$$

導出

$\boldsymbol{\beta}_j$ を含む因子だけを取り出すと

$$p(\boldsymbol{\beta}_j \mid \cdots) \propto \underbrace{\exp\Big\{-\tfrac{1}{2\sigma^2}\|\boldsymbol{y}_j - X_j\boldsymbol{\beta}_j\|^2\Big\}}_{\text{グループ内モデル}} \times \underbrace{\exp\Big\{-\tfrac{1}{2}(\boldsymbol{\beta}_j - \boldsymbol{\theta})^\top \Sigma^{-1}(\boldsymbol{\beta}_j - \boldsymbol{\theta})\Big\}}_{\text{グループ間モデル}}$$

$$\propto \exp\Big\{-\tfrac{1}{2}\boldsymbol{\beta}_j^\top \big(\Sigma^{-1} + X_j^\top X_j/\sigma^2\big)\boldsymbol{\beta}_j + \boldsymbol{\beta}_j^\top \big(\Sigma^{-1}\boldsymbol{\theta} + X_j^\top \boldsymbol{y}_j/\sigma^2\big)\Big\}.$$

$\exp\{-\frac{1}{2}\boldsymbol{\beta}^\top A\boldsymbol{\beta} + \boldsymbol{\beta}^\top \boldsymbol{b}\}$ は $\mathrm{MVN}(A^{-1}\boldsymbol{b},\, A^{-1})$ の核なので（第 7 章），上の結果を得る．

ポイント

縮小推定としての解釈：最小二乗推定量 $\hat{\boldsymbol{\beta}}_j^{\mathrm{OLS}} = (X_j^\top X_j)^{-1} X_j^\top \boldsymbol{y}_j$ を使うと $X_j^\top \boldsymbol{y}_j = (X_j^\top X_j)\hat{\boldsymbol{\beta}}_j^{\mathrm{OLS}}$ なので

$$\boldsymbol{m}_j = \Big(\underbrace{\Sigma^{-1}}_{\text{全体の精度}} + \underbrace{X_j^\top X_j/\sigma^2}_{\text{データの精度}}\Big)^{-1}\big(\Sigma^{-1}\,\boldsymbol{\theta} + (X_j^\top X_j/\sigma^2)\,\hat{\boldsymbol{\beta}}_j^{\mathrm{OLS}}\big).$$

つまり条件付き事後平均は，全体平均 $\boldsymbol{\theta}$ と学校ごとの OLS 推定値の**精度による加重平均**である．データが少ない学校（$X_j^\top X_j$ が小さい）ほど $\boldsymbol{\theta}$ 側に強く引き寄せられる——これが 5.3 節・8 章で見た「事前平均とデータの加重平均」の多変量版である．

3.2 $\boldsymbol{\theta}$ と Σ の完全条件付き分布

$\boldsymbol{\beta}_1, \ldots, \boldsymbol{\beta}_m$ は「平均 $\boldsymbol{\theta}$，分散 Σ の多変量正規母集団からの i.i.d. 標本」なので，第 7 章の多変量正規モデルの結果がそのまま使える（データ $\boldsymbol{y}_i$ の役を $\boldsymbol{\beta}_j$ が演じる）．

$\boldsymbol{\theta}$ の完全条件付き分布

$\{\boldsymbol{\theta} \mid \boldsymbol{\beta}_1, \ldots, \boldsymbol{\beta}_m, \Sigma\} \sim \mathrm{MVN}(\boldsymbol{\mu}_m, \Lambda_m)$，ただし

$$\Lambda_m = \big(\Lambda_0^{-1} + m\Sigma^{-1}\big)^{-1}, \qquad \boldsymbol{\mu}_m = \Lambda_m\big(\Lambda_0^{-1}\boldsymbol{\mu}_0 + m\Sigma^{-1}\bar{\boldsymbol{\beta}}\big), \qquad \bar{\boldsymbol{\beta}} = \frac{1}{m}\sum_{j=1}^{m}\boldsymbol{\beta}_j.$$

精度は「事前の精度 Λ_0^{-1} ＋ データの精度 $m\Sigma^{-1}$」，平均は事前平均 $\boldsymbol{\mu}_0$ と標本平均 $\bar{\boldsymbol{\beta}}$ の精度加重平均（第 7 章と同じ構造）．

Σ の完全条件付き分布

$$\{\Sigma \mid \boldsymbol{\theta}, \boldsymbol{\beta}_1, \ldots, \boldsymbol{\beta}_m\} \sim \text{inverse-Wishart}\big(\eta_0 + m,\ [S_0 + S_\theta]^{-1}\big),$$

ただし

$$S_\theta = \sum_{j=1}^{m} (\boldsymbol{\beta}_j - \boldsymbol{\theta})(\boldsymbol{\beta}_j - \boldsymbol{\theta})^\top.$$

自由度は「事前の η_0 ＋ 標本数 m」，平方和行列は「事前の S_0 ＋ 標本の平方和 S_θ」.

注意

S_θ は $\boldsymbol{\theta}$ に依存するので，Gibbs サンプラーで $\boldsymbol{\theta}$ を更新するたびに**計算し直す**必要がある.

3.3 σ^2 の完全条件付き分布

σ^2 は全グループ共通の誤差分散なので，**全グループの残差**から情報を得る.

σ^2 の完全条件付き分布

$$\{\sigma^2 \mid \cdots\} \sim \text{inverse-gamma}\left(\frac{\nu_0 + \sum_j n_j}{2},\ \frac{\nu_0 \sigma_0^2 + \text{SSR}}{2}\right),$$

ただし

$$\text{SSR} = \sum_{j=1}^{m} \sum_{i=1}^{n_j} \big(y_{i,j} - \boldsymbol{\beta}_j^\top \boldsymbol{x}_{i,j}\big)^2.$$

5.3 節の σ^2 の更新（「事前の平方和＋データの平方和」）と同じ形．SSR も $\boldsymbol{\beta}_j$ に依存するので，毎スキャン計算し直す.

Gibbs サンプラー（線形混合効果モデル）

現在値 $(\boldsymbol{\beta}_1^{(s)}, \ldots, \boldsymbol{\beta}_m^{(s)}, \boldsymbol{\theta}^{(s)}, \Sigma^{(s)}, \sigma^{2(s)})$ から：

1. 各 $j = 1, \ldots, m$ について $\boldsymbol{\beta}_j^{(s+1)} \sim \text{MVN}(\boldsymbol{m}_j, V_j)$
2. $\boldsymbol{\theta}^{(s+1)} \sim \text{MVN}(\boldsymbol{\mu}_m, \Lambda_m)$（新しい $\boldsymbol{\beta}$ を使う）
3. S_θ を計算し直して $\Sigma^{(s+1)} \sim \text{inverse-Wishart}(\eta_0 + m, [S_0 + S_\theta]^{-1})$
4. SSR を計算し直して $\sigma^{2(s+1)} \sim \text{inverse-gamma}(\cdots)$

4　数学の点数データの事後解析（11.3 節）

4.1　事前分布の設定（単位情報事前分布の考え方）

第 9 章の**単位情報事前分布**（unit information prior）と同じ発想で，「偏りはないが弱い」事前情報を表すようにデータから中心を決める．

ハイパーパラメータ	設定値	意図
$\boldsymbol{\mu}_0$（$\boldsymbol{\theta}$ の事前平均）	100 校の OLS 推定値の平均	偏りのない中心
Λ_0（$\boldsymbol{\theta}$ の事前分散）	OLS 推定値の標本共分散	広め（弱い情報）
S_0（Σ の平方和行列）	OLS 推定値の標本共分散	
η_0（Σ の自由度）	$p+2=4$	拡散的だが $E[\Sigma]=S_0$
σ_0^2	グループ内標本分散の平均	
ν_0	1	弱い情報

例えば傾き θ_2 の事前 95% 区間は $(-3.86, 8.60)$ と非常に広い．

ポイント

$\eta_0 = p+2$ とするのは，逆ウィシャート分布の期待値が $E[\Sigma] = S_0/(\eta_0 - p - 1)$ なので，$\eta_0 = p+2$ のときちょうど $E[\Sigma] = S_0$ になり，かつ自由度が最小限で分布が拡散的になるからである（第 7 章）．

4.2　結果

Gibbs サンプラーを 10,000 スキャン回し，10 スキャンごとに保存して 1,000 個のサンプルを得た．自己相関は十分小さい（lag-10 の自己相関は θ_1：-0.024，θ_2：0.038）．

例：傾き：θ_2 と $\tilde{\beta}_2$ の違い

- θ_2（**学校の傾きの母平均**）の事後 95% 区間は $(1.83, 2.96)$．事前区間 $(-3.86, 8.60)$ から大きく情報が更新された．θ_2 **が負である可能性はほぼない**．
- しかしこれは「学校の傾きの**平均**が正」というだけで，「どの学校でも傾きが正」という意味ではない．
- そこで**新しく抽出した学校の傾き** $\tilde{\beta}_2$ の事後予測分布を考える．各スキャン s で $\tilde{\boldsymbol{\beta}}^{(s)} \sim \text{MVN}(\boldsymbol{\theta}^{(s)}, \Sigma^{(s)})$ を引けばサンプルが得られる．
- $\tilde{\beta}_2$ の分布は θ_2 の分布よりずっと広い（学校間の異質性 Σ を反映）．

$$\Pr(\tilde{\beta}_2 < 0 \mid \boldsymbol{y}_1, \ldots, \boldsymbol{y}_m, X_1, \ldots, X_m) \approx 0.07$$

——小さいが無視できない確率で，傾きが負の学校もありうる．

量	何についての不確かさか	分布の幅
θ_2	「学校の傾きの母平均」という固定値の推定の不確かさ	狭い
$\tilde{\beta}_2$	上に加えて，学校ごとのバラつき（Σ）	広い

ポイント

縮小の効果：100 校の回帰直線の事後期待値（教科書 Figure 11.3 右）を，最初の OLS の直線（Figure 11.1 左）と比べると，極端な直線が全体平均に向かって引き寄せられ，**負の傾きの学校がほとんどなくなっている**．情報共有によって，サンプルの少ない学校の極端な推定が抑えられた．

5　一般化線形混合効果モデル（11.4 節）

5.1　モデル

グループ内のデータが二値やカウントのとき，正規モデルは不適切で，ロジスティック回帰やポアソン回帰（第 10 章の一般化線形モデル）を使いたい．それを階層化したのが**一般化線形混合効果モデル**（GLMM）である．

一般化線形混合効果モデル

$$\boldsymbol{\beta}_1, \ldots, \boldsymbol{\beta}_m \overset{\text{i.i.d.}}{\sim} \mathrm{MVN}(\boldsymbol{\theta}, \Sigma), \qquad p(\boldsymbol{y}_j \mid X_j, \boldsymbol{\beta}_j, \gamma) = \prod_{i=1}^{n_j} p(y_{i,j} \mid \boldsymbol{\beta}_j^\top \boldsymbol{x}_{i,j},\, \gamma).$$

異なるグループの観測も条件付き独立．$p(y \mid \boldsymbol{\beta}^\top \boldsymbol{x}, \gamma)$ は平均が $\boldsymbol{\beta}^\top \boldsymbol{x}$ を通じて決まる密度で，γ は分散やスケールを表す追加パラメータ．

- 正規モデル：$p(y \mid \boldsymbol{\beta}^\top \boldsymbol{x}, \gamma) = \mathrm{dnorm}(y,\, \boldsymbol{\beta}^\top \boldsymbol{x},\, \gamma^{1/2})$（$\gamma$ は分散）
- ポアソンモデル：$p(y \mid \boldsymbol{\beta}^\top \boldsymbol{x}) = \mathrm{dpois}(y,\, e^{\boldsymbol{\beta}^\top \boldsymbol{x}})$（$\gamma$ なし）

5.2 Metropolis–Gibbs アルゴリズム（11.4.1 節）

線形混合効果モデルでは全パラメータの完全条件付き分布が標準的だったが，非正規の GLMM では $\boldsymbol{\theta}$ **と** Σ **だけが標準的**で，$\boldsymbol{\beta}_j$ の完全条件付き分布は標準的な分布にならない（ポアソン尤度 $\times$ 正規密度は既知の分布の形にならない）．そこで**使える所は Gibbs，使えない所は Metropolis** で更新する（第 10 章 10.5 節の考え方）．

$(\boldsymbol{\theta}, \Sigma)$：Gibbs ステップ

$\boldsymbol{\theta}$ と Σ の完全条件付き分布は $\boldsymbol{\beta}_1, \ldots, \boldsymbol{\beta}_m$ にしか依存しない（図 1 を参照）．したがって $p(y \mid \boldsymbol{\beta}^\top \boldsymbol{x})$ **が正規でもポアソンでも関係なく**，11.2 節と全く同じ多変量正規分布と逆ウィシャート分布から引ける．

$\boldsymbol{\beta}_j$：Metropolis ステップ

$\boldsymbol{\beta}_j$ の Metropolis ステップ

1. 提案：$\boldsymbol{\beta}_j^* \sim \mathrm{MVN}(\boldsymbol{\beta}_j^{(s)},\, V_j^{(s)})$
2. 受理確率の比を計算：

$$r = \frac{p(\boldsymbol{y}_j \mid X_j, \boldsymbol{\beta}_j^*)\; p(\boldsymbol{\beta}_j^* \mid \boldsymbol{\theta}^{(s)}, \Sigma^{(s)})}{p(\boldsymbol{y}_j \mid X_j, \boldsymbol{\beta}_j^{(s)})\; p(\boldsymbol{\beta}_j^{(s)} \mid \boldsymbol{\theta}^{(s)}, \Sigma^{(s)})}$$

3. $u \sim \mathrm{uniform}(0, 1)$ を引き，$u < r$ なら $\boldsymbol{\beta}_j^{(s+1)} = \boldsymbol{\beta}_j^*$，そうでなければ $\boldsymbol{\beta}_j^{(s+1)} = \boldsymbol{\beta}_j^{(s)}$

ポイント

比 r の中身：r は $\boldsymbol{\beta}_j$ の完全条件付き分布（目標分布）の密度比である．$\boldsymbol{\beta}_j$ に関係する因子は「グループ j の尤度」と「グループ間モデル」の 2 つだけで，他のグループのデータや σ^2 などは分子分母で約分されて消える．提案分布が現在値を中心とする正規分布で**対称**なので，Hastings の補正項 $J(\boldsymbol{\beta}^{(s)} \mid \boldsymbol{\beta}^*)/J(\boldsymbol{\beta}^* \mid \boldsymbol{\beta}^{(s)})$ は 1 になり，純粋な Metropolis 法の比でよい（10.4 節）．

提案分散の選び方：$V_j^{(s)}$ を $\Sigma^{(s)}$ の定数倍にするとよく混ざることが多い．ただし定数は試行錯誤で決める（大きすぎると棄却ばかり，小さすぎると少しずつしか動かない）．

Metropolis–Hastings アルゴリズム（GLMM）

スキャン s の現在値から：

1. $\boldsymbol{\theta}^{(s+1)}$ を完全条件付き分布から引く（Gibbs）．
2. $\Sigma^{(s+1)}$ を完全条件付き分布から引く（Gibbs）．
3. 各 $j \in \{1, \ldots, m\}$ について
   （a）新しい値 $\boldsymbol{\beta}_j^*$ を提案する．
   （b）適切な確率で $\boldsymbol{\beta}_j^{(s+1)}$ を $\boldsymbol{\beta}_j^*$ または $\boldsymbol{\beta}_j^{(s)}$ にする（Metropolis）．

γ がある場合は，完全条件付き分布が標準的なら Gibbs，そうでなければ Metropolis で更新する．

6　腫瘍の位置データの解析（11.4.2 節）

例：マウスの腸の腫瘍（Haigis et al., 2004）

腸に腫瘍ができやすい実験用マウス 21 匹について，腸を 20 区間に分け，各区間の腫瘍の数を数えた．知りたいのは「**腫瘍の発生率が腸の位置に沿ってどう変わるか**」である．

観察：平均より一貫して少ないマウス・一貫して多いマウスがいる ⇒ 同じマウスの中の観測は似ている ⇒ **マウスをグループとする階層モデル**が適切．

6.1 モデル

マウス j の位置 $x \in \{0.05, 0.10, \ldots, 0.95\}$ での腫瘍数を $Y_{x,j}$ として

$$Y_{x,j} \sim \text{Poisson}\big(e^{f_j(x)}\big), \qquad f_j(x) = \beta_{1,j} + \beta_{2,j}x + \beta_{3,j}x^2 + \beta_{4,j}x^3 + \beta_{5,j}x^4.$$

- カウントデータなので**対数リンクのポアソン回帰**.
- f_j は位置に沿って滑らかに変わる関数で，**4 次多項式**で表す（$p = 5$，$\boldsymbol{x}_i = (1, x_i, x_i^2, x_i^3, x_i^4)^\top$）．平均腫瘍数の対数に 2 次・3 次・4 次の多項式を当てはめると，2 次・3 次では当てはまりが悪く，4 次でよく当てはまったため（教科書 Figure 11.4）.
- グループ間モデルは $\boldsymbol{\beta}_1, \ldots, \boldsymbol{\beta}_{21} \overset{\text{i.i.d.}}{\sim} \text{MVN}(\boldsymbol{\theta}, \Sigma)$．$\Sigma$ を推定することで，マウス内の観測の依存関係を表現・記述できる.

6.2 事前分布（単位情報事前分布）

パラメータが多く明示的な事前情報もないので，データから弱く中心化する.

1. 各マウスで $\log(y_{i,j} + 1/n)$ を $\boldsymbol{x}_i$ に回帰して，仮の推定値 $\tilde{\boldsymbol{\beta}}_j$ を得る（$+1/n$ は $y = 0$ で $\log 0$ にならないための工夫．ポアソン回帰の最尤推定でもよい）.
2. $\boldsymbol{\mu}_0 = \frac{1}{m}\sum_j \tilde{\boldsymbol{\beta}}_j$，$\Lambda_0 = S_0 = \tilde{\boldsymbol{\beta}}_j$ たちの標本共分散.
3. $\eta_0 = p + 2 = 7$（$E[\Sigma] = S_0$ だが拡散的）.

6.3 MCMC の実行と診断

- 提案分布は試行錯誤の結果 $\text{MVN}(\boldsymbol{\beta}_j^{(s)}, \Sigma^{(s)}/2)$．**受理率は約 31%**.
- 50,000 スキャン回し，10 スキャンごとに保存 $\Rightarrow$ 各パラメータ 5,000 サンプル.
- **有効サンプルサイズ**：Σ の要素は Σ_{11}（約 950）以外すべて 1,000 以上，$\boldsymbol{\theta}$ の 5 成分は $(674, 1003, 1092, 1129, 1145)$.
- 例えば $E[\theta_1 \mid \boldsymbol{y}]$ のモンテカルロ標準誤差は，θ_1 の事後標準偏差の $1/\sqrt{674} \approx 1/25.96$ 倍．もっと小さくしたければ，さらに長く回せばよい.

6.4　結果：3 段階の不確かさ

教科書 Figure 11.5 は，各位置 x での 3 つの量の事後分布の 2.5%，50%，97.5% 点を描いている．右に行くほど帯が広くなる．

パネル	量	含まれる不確かさ
左	$\exp(\boldsymbol{\theta}^\top \boldsymbol{x})$	① 固定だが未知の $\boldsymbol{\theta}$ の推定の不確かさ
中	$\exp(\boldsymbol{\beta}^\top \boldsymbol{x})$（新しいマウス）	① ＋ ② マウス間の異質性（Σ）
右	$\{Y \mid \boldsymbol{x}\}$（新しいマウスの観測数）	① ＋ ② ＋ ③ 期待値の周りのポアソン変動

もしマウス間の異質性がなければ（$\Sigma = 0$），すべての $\boldsymbol{\beta}_j = \boldsymbol{\theta}$ となり，左と中のパネルは同じになる．

ポイント

どの帯を使うかは目的しだい：

- 「$\boldsymbol{\theta}$ という固定値についての不確かさ」を述べたいだけ ⇒ 左のパネル
- 「**新しいマウスの観測される腫瘍数**を予測したい」⇒ 右のパネル

不確かさの源泉を分けて理解することは，推論や意思決定に直結する．これは 11.3 節の θ_2 と $\tilde{\beta}_2$ の区別と同じ考え方である．

7　議論：階層モデルの MCMC の混ざりにくさ（11.5 節）

注意

階層モデルの MCMC は**混ざりが悪く**なりやすい．原因は，パラメータ間の相関が強いのに Gibbs で 1 つずつ更新すること．例えば $\boldsymbol{\theta}$ と $\boldsymbol{\beta}_j$ は正に相関しているので：

1. ある反復で $\boldsymbol{\theta}$ が極端な値を取る

2. それに引っ張られて $\boldsymbol{\beta}_j$ も極端な値に更新される（グループ内データが少ないと特に）
3. その $\boldsymbol{\beta}_j$ に引っ張られて，次の反復の $\boldsymbol{\theta}$ も極端になる

という連鎖で，高い自己相関が生じる．

対策としては，Gibbs サンプラーの更新の仕方を工夫する方法（Gelman et al., 2004, 15.4 節）や，モデルの**再パラメータ化**（Gelfand et al., 1995；Papaspiliopoulos et al., 2007）がある．

8　まとめ

第 11 章のまとめ

1. **階層回帰モデル**は，グループ内を回帰モデル，グループ間の回帰係数のバラつきを $\boldsymbol{\beta}_j \sim \mathrm{MVN}(\boldsymbol{\theta}, \Sigma)$ で表す．第 8 章の階層モデルの「平均」を「回帰係数ベクトル」に一般化したもの．
2. $\boldsymbol{\beta}_j = \boldsymbol{\theta} + \boldsymbol{\gamma}_j$ と書くと**固定効果** $\boldsymbol{\theta}$ と**変量効果** $\boldsymbol{\gamma}_j$ を含むので**線形混合効果モデル**と呼ばれる．変量効果はグループ内の相関を生む．
3. 半共役事前分布のもとで，完全条件付き分布は $\boldsymbol{\beta}_j$：多変量正規（9 章），$\boldsymbol{\theta}$：多変量正規（7 章），Σ：逆ウィシャート（7 章），σ^2：逆ガンマ（9 章）となり，Gibbs サンプラーで推定できる．$\boldsymbol{\beta}_j$ の事後平均は $\boldsymbol{\theta}$ と OLS 推定値の精度加重平均（縮小推定）．
4. 「母平均 θ_2」と「新しいグループの値 $\tilde{\beta}_2$」は別物．後者はグループ間の異質性を含むので分布が広い．
5. **一般化線形混合効果モデル**では $\boldsymbol{\beta}_j$ の完全条件付き分布が標準的でないため，$(\boldsymbol{\theta}, \Sigma)$ は Gibbs，$\boldsymbol{\beta}_j$ は Metropolis で更新する **Metropolis–Gibbs アルゴリズム**を使う．
6. 予測の帯は「パラメータの不確かさ」「グループ間の異質性」「観測のノイズ」が積み重なって広がる．目的に応じて適切な帯を使う．
7. 階層モデルの MCMC はパラメータ間の相関で混ざりにくくなりうる．