補足資料

十分統計量（Sufficient Statistic）

ゼミ資料

1　直感的な動機

データ $y_1, y_2, y_3 = 3, 5, 7$ から母平均 θ を推定したいとする．
このとき，3 つの数字を全部記録しておく必要があるだろうか？

正規モデル $y_i \sim \mathrm{Normal}(\theta, \sigma^2)$ では，θ に関する情報はすべて**標本平均** $\bar{y} = 5$ に集約されている．データの順番や個々の値は θ の推定に追加の情報をもたらさない．

この「情報の集約」を正確に表現したのが**十分統計量**の概念である．

2　一般的な定義

十分統計量（Sufficient Statistic）

統計量 $T(y_1, \ldots, y_n)$ が θ の**十分統計量**であるとは，

$$p(y_1, \ldots, y_n \mid T(y_1, \ldots, y_n) = t,\ \theta) \text{ が } \theta \text{ に依存しない}$$

ことをいう．つまり，T の値を知った後では，生データを追加で見ても θ についての情報が増えない．

この定義は直感と対応している：

- T に θ の情報がすべて入っている $\Rightarrow$ T を固定すると，残りのデータのバラつきは θ と無関係 $\Rightarrow$ 条件付き分布が θ に依存しない

3　因数分解定理（確認に使う定理）

定義を直接確認するのは難しいため，実用的には次の定理を使う．

Fisher–Neyman の因数分解定理

$T(y_1, \ldots, y_n)$ が θ の十分統計量である $\iff$ 同時密度（または確率質量関数）が

$$p(y_1, \ldots, y_n \mid \theta) = g\big(T(y_1, \ldots, y_n),\ \theta\big) \times h(y_1, \ldots, y_n)$$

と因数分解できる．ここで g は T と θ のみに依存し，h は θ に依存しない．

ポイント

確認の手順：同時密度を書き下して，「θ を含む部分」と「θ を含まない部分」に分けられるか確かめる．θ を含む部分がデータに依存する形が T になっている．

なぜ因数分解定理が定義と同値なのか

同値を示すには 2 方向を示す必要がある．

■方向 1：因数分解できる $\Rightarrow$ 定義を満たす　$p(y_1, \ldots, y_n|\theta) = g(T, \theta) \times h(y)$ と分解できるとして，条件付き分布を計算する：

$$p(y \mid T = t, \theta) = \frac{p(y,\ T = t \mid \theta)}{p(T = t \mid \theta)}.$$

分子は $T(y) = t$ を満たすとき $p(y|\theta) = g(t, \theta) \times h(y)$.
分母は $T = t$ になるデータを全部足し合わせたものなので，

$$p(T = t \mid \theta) = \sum_{\{y:\, T(y) = t\}} g(t, \theta) \times h(y) = g(t, \theta) \times \sum_{\{y:\, T(y) = t\}} h(y).$$

割り算すると $g(t, \theta)$ が約分されて，

$$p(y \mid T = t, \theta) = \frac{g(t, \theta) \times h(y)}{g(t, \theta) \times \displaystyle\sum_{\{y:\, T(y) = t\}} h(y)} = \frac{h(y)}{\displaystyle\sum_{\{y:\, T(y) = t\}} h(y)}.$$

θ が消えた．これがまさに定義の内容である．

ポイント

核心は「$g(t,\theta)$ が分子と分母で同じ値なので約分できる」こと．
θ の情報は全部 T に乗っており，T を固定したら θ が消えるという構造が，計算の上で直接見えている．

■方向 2：定義を満たす ⇒ 因数分解できる　T が十分統計量（定義を満たす）とする．すなわち $p(y \mid T=t,\theta) = q(y \mid t)$（$\theta$ に依存しない）と書ける．

尤度を次のように分解する：

$$p(y \mid \theta) = p(y \mid T = T(y),\, \theta) \times p(T = T(y) \mid \theta).$$

第 1 因子は定義より $q(y \mid T(y))$（θ に依存しない）なので，

$$h(y) = q(y \mid T(y)), \qquad g(T(y),\, \theta) = p(T = T(y) \mid \theta)$$

とおけば，

$$p(y \mid \theta) = g(T(y),\, \theta) \times h(y)$$

という因数分解が得られる．　□

4　例で確認する

例：二項モデル：$T = \sum y_i$

$y_1, \ldots, y_n \overset{\text{i.i.d.}}{\sim} \text{Bernoulli}(\theta)$ のとき，同時確率質量関数は

$$p(y_1, \ldots, y_n|\theta) = \prod_{i=1}^{n} \theta^{y_i}(1-\theta)^{1-y_i} = \theta^{\sum y_i}(1-\theta)^{n-\sum y_i}.$$

因数分解すると

$$= \underbrace{\theta^{\sum y_i}(1-\theta)^{n-\sum y_i}}_{g(T,\theta),\ T=\sum y_i} \times \underbrace{1}_{h(y_1,\ldots,y_n)}.$$

h が定数なので，$T = \sum y_i$ が十分統計量である．

直感：「1 が何回出たか」さえ知れば，どの順番で出たかは θ の推定に関係ない．

例：ポアソンモデル：$T = \sum y_i$

$y_1, \ldots, y_n \overset{\text{i.i.d.}}{\sim} \text{Poisson}(\theta)$ のとき，

$$p(y_1, \ldots, y_n|\theta) = \prod_{i=1}^{n} \frac{\theta^{y_i} e^{-\theta}}{y_i!} = \underbrace{e^{-n\theta}\, \theta^{\sum y_i}}_{g(T,\,\theta)} \times \underbrace{\prod_{i=1}^{n} \frac{1}{y_i!}}_{h(y_1,\ldots,y_n)} .$$

よって $T = \sum y_i$ が十分統計量.

例：正規モデル：$T = (\bar{y},\, s^2)$

$y_1, \ldots, y_n \overset{\text{i.i.d.}}{\sim} \text{Normal}(\theta, \sigma^2)$（$\sigma^2$ 既知）のとき，

$$p(y_1, \ldots, y_n|\theta) \propto \exp\left\{ -\frac{\sum (y_i - \theta)^2}{2\sigma^2} \right\}.$$

指数部分を展開すると

$$\sum (y_i - \theta)^2 = \sum y_i^2 - 2\theta \sum y_i + n\theta^2,$$

なので

$$p(y_1, \ldots, y_n|\theta) = \underbrace{\exp\left\{ \frac{\theta \sum y_i}{\sigma^2} - \frac{n\theta^2}{2\sigma^2} \right\}}_{g(\sum y_i,\, \theta)} \times \underbrace{\exp\left\{ -\frac{\sum y_i^2}{2\sigma^2} \right\}}_{h(y_1,\ldots,y_n)}.$$

よって $T = \sum y_i$（あるいは同値な $\bar{y}$）が十分統計量.
σ^2 も未知のときは $T = (\sum y_i,\, \sum y_i^2)$，すなわち $(\bar{y},\, s^2)$ が 2 次元の十分統計量になる.

5　指数型分布族との関係

3.3 節で学んだ指数型分布族 $p(y|\phi) = h(y)c(\phi)e^{\phi\, t(y)}$ において，因数分解定理を適用すると：

$$p(y_1, \ldots, y_n|\phi) = \underbrace{c(\phi)^n \exp\Big\{\phi \sum t(y_i)\Big\}}_{g(\sum t(y_i),\, \phi)} \times \underbrace{\prod_{i=1}^{n} h(y_i)}_{h(y_1, \ldots, y_n)}.$$

指数型分布族における十分統計量

1 次元指数型分布族では，$T = \sum_{i=1}^{n} t(y_i)$ が ϕ の十分統計量である．

これは 3 つのモデルに一致する：

モデル	$t(y)$	十分統計量 T	同値な統計量
二項	y	$\sum y_i$	（1 の個数）
ポアソン	y	$\sum y_i$	$\bar{y}$（標本平均）
正規（σ^2 既知）	y	$\sum y_i$	$\bar{y}$
正規（σ^2 未知）	$(y,\, y^2)$	$(\sum y_i,\, \sum y_i^2)$	$(\bar{y},\, s^2)$

6　ベイズ推論との関係

十分統計量が重要なのは，ベイズ推論でも事後分布が十分統計量のみに依存するからである：

$$p(\phi \mid y_1, \ldots, y_n) \propto p(\phi) \times p(y_1, \ldots, y_n|\phi) = p(\phi) \times g(T, \phi) \times h(y_1, \ldots, y_n).$$

h は ϕ に依存しないので，

$$p(\phi \mid y_1, \ldots, y_n) \propto p(\phi) \times g(T, \phi).$$

ポイント

事後分布は生データ $(y_1, \ldots, y_n)$ ではなく，**十分統計量 T だけに依存する**．
つまり，ベイズ更新において「情報の圧縮」が保証されている．共役事前分布のハイパーパラメータの更新則が T だけを使うシンプルな形になるのも，この構造が根拠になっている．

7　まとめ

十分統計量のまとめ

1. **定義**：T を知った後に生データを見ても θ の情報が増えない $\Leftrightarrow$ T を条件付けた生データの分布が θ に依存しない.
2. **確認方法**：因数分解定理 — 同時密度が $g(T,\theta) \times h(y)$ と分解できれば T が十分統計量.
3. **指数型分布族**：$p(y|\phi) = h(y)c(\phi)e^{\phi t(y)}$ では $T = \sum t(y_i)$ が自動的に十分統計量になる.
4. **ベイズ推論**：事後分布は十分統計量のみに依存するので，データを T に圧縮してから更新すれば十分である.